자동차안전학회지 제??권 제?호 20??년, pp. ??~?? http://data.doi.or.kr/10.22680/kasa202?.??.?.???

고속도로 사고의 인명피해 관련 요인과 상호작용 분석

이승보*·이성재*·박지영**·김수지***·심지섭****·고은정****

Factors and Interactions Associated with Casualty Occurrence in Expressway Crashes

Seungbo Lee*·Seongjae Lee*·Jiyoung Park**·Suji Kim***·Jisup Shim****·Eunjeong Ko****

ABSTRACT This study examined factors associated with casualty occurrence in expressway crashes and their interactions using 83,297 crash records from South Korea between 2011 and 2019. Based on fourteen predictors describing crash circumstances and road environments, XGBoost and SHAP were first applied to identify influential factors and candidate interactions. These candidate interactions were then tested using multivariable logistic regression, along with the estimation of adjusted odds ratios, while negative binomial regression was employed to compare the directions of associations for casualty counts. A descriptive analysis of mainline crashes by distance to the nearest estimated tollgate was also conducted. The results showed that stopped vehicles, trailers, vans/buses, insufficient following distance, drowsy driving and inattention were associated with higher odds of casualty occurrence, whereas crashes at tollgates and ramps were associated with lower odds. Of the 24 candidate interactions, 13 remained statistically significant after Benjamini–Hochberg correction ($q < 0.05$), including interactions between tollgate location and passenger cars and between inattention and mainline location. Moreover, all 47 dummy variables that were statistically significant in both regression models showed consistent directions of association. These findings support examining joint crash characteristics while distinguishing predictive contributions from regression associations. The findings are observational, and candidate screening and regression testing used overlapping observations.

Key Words : Expressway crash(고속도로 교통사고), Casualty(인명피해), XGBoost-SHAP(XGBoost-SHAP), Risk factor(위험요인), Interaction effect(상호작용 효과)

1. 서 론

교통량과 사고 발생 건수 간의 관계는 도로 유형과 사고 특성에 따라 상이하게 나타나는 것으로 보고되었다[1]. 고속도로 탑승자의 상해 심각도와 교통량·속도 간의 관련성이 보고되었으며[2], 방호울타리 충돌 이후의 이차충돌과 고속도로 일차·이차사고의 피해 특성에 관한 연구가 수행되었다[3,4]. 중증 교통손상은 상당한 의료·사회적 비용을 수반하므로[5], 고속도로 안전관리에서는 사고 발생 건수와 함께 사고

* 한남대학교 경영정보학과, 학사과정
(20212007@m365.hnu.ac.kr)
*** 국토연구원, 부연구위원
** 한남대학교 AI데이터사이언스학과, 석사과정
**** 한남대학교 빅데이터응용학과, 조교수
(eunjeong.ko@hnu.kr)

가 어떠한 조건에서 인명피해로 이어지는지를 검토할 필요가 있다.

교통사고의 유형 및 인명피해 심각도와 운전자, 차량, 도로·환경 특성 간의 관련성이 보고되었다[6,7]. 국내 고속도로의 사고 규모를 구조방정식모형으로 분석한 연구에서도 복합적인 요인 간 관계가 검토되었다[8]. 개별 범주의 관련성은 다른 조건과의 결합에 따라 달라질 수 있으므로, 인명피해 발생과 관련된 요인을 분석할 때에는 주효과와 함께 요인 간 상호작용을 고려할 필요가 있다.

로지스틱 회귀를 비롯한 통계모형은 사고 특성과 인명피해 심각도 간의 관련성을 추정하는 데 활용되어 왔다[7,9]. 이항 로지스틱 회귀에서는 오즈비(Odds Ratio, OR)를 통해 다른 변수를 통제한 범주별 관련성을 제시하고 회귀계수의 통계적 유의성을 검정할 수 있다. 다만 비선형 관계와 상호작용을 분석하려면 해당 항을 모형에 명시적으로 설정해야 하므로, 다수의 범주가 존재하는 자료에서 사전에 특정하지 않은 결합 양상을 탐색하는 데에는 제약이 있다.

XGBoost와 같은 트리 기반 부스팅 모형은 다수의 결정트리를 순차적으로 결합하여 예측함수를 학습한다[10]. 교통사고 심각도 연구에서는 XGBoost와 Random Forest 등을 적용하고 SHAP을 이용하여 예측에 기여하는 요인을 해석하였다[11,12]. SHAP(SHapley Additive exPlanations)은 개별 예측값을 변수별 기여도로 분해하며[13], 트리 모형에서는 변수 간 국소적 상호작용 기여도도 산출할 수 있다[14]. 도로환경과 사고 간의 비선형 관계 및 상호작용을 분석한 연구도 보고되었다[15]. 다만 예측 기여도의 크기와 회귀계수의 통계적 유의성은 구분하여 해석할 필요가 있다.

Ko와 Jang은 순서형 로지스틱 회귀모형과 랜덤 포레스트를 병행하여 고속도로 사고 심각도를 분석하였다[16]. 본 연구는 2011~2019년의 고속도로 사고자료를 대상으로 XGBoost와 SHAP을 이용하여 인명피해 발생 관련 요인과 상호작용 후보를 탐색한 후, 주효과를 포함한 로지스틱 회귀모형과 다중검정 보정을 통해 후보별 통계적 근거를 검토하였다. 또한 사고당 사상자 수에 대한 음이항 회귀를 적용하여 관련성의 방향을 비교하고, 영업소 인접 본선의 거리별 인명피해 발생률을 보조적으로 분석하였다. 이 절차는 예측 기여도와 회귀모형의 연관성 추정 결과를 구분하여 제시하는 데 목적이 있다.

본 논문의 구성은 다음과 같다. 2장에서는 연구 범위와 분석자료를 설명하고, 3장에서는 변수 선정과 탐색 및 후속 통계 분석 절차를 제시한다. 다음으로, 4장에서는 주요 영향요인과 상호작용 분석 결과를 제시한다. 마지막으로 5장에서는 연구 결과를 종합하고, 연구의 한계 및 향후 연구 방향을 논의한다.

2. 연구 범위 및 분석자료 설명

본 연구는 국내 고속도로에서 발생한 교통사고를 대상으로 사고 및 교통환경 특성과 인명피해 발생 간의 관계를 분석하고 주요 위험요인을 파악하였다. 이를 위해 사고 발생 위치를 확인할 수 있는 전국 고속도로 구간을 분석 대상으로 설정하고, 사고 발생 지점을 본선부, 램프부, 영업소, 터널부, 휴게소 등으로 구분하였다. 분석 기간은 2011~2019년으로 설정하였으며, 해당 기간의 자료를 통합하여 기록된 사고 특성과 인명피해 발생 간의 관련성을 분석하였다. 분석자료는 연도별 자료를 통합한 후 결측값을 처리하고 변수 및 범주 표기의 일관성을 검토하여 구축하였으며, 총 83,297건의 사고자료를 최종 분석

대상으로 선정하였다.

이와 같이 구축된 분석자료를 바탕으로 사고별 인명피해 발생 여부를 구분하고 이를 종속변수(Dependent variable)로 설정하였다. 구체적으로, 사고 1건당 사망자, 중상자 및 경상자의 합계가 1명 이상인 경우를 인명피해 사고(1), 인명피해가 발생하지 않은 경우를 대물피해 사고(0)로 정의하였다. 이에 따라 전체 83,297건 가운데 인명피해 사고는 8,993건(10.80%), 대물피해 사고는 74,304건(89.20%)으로 나타났다. 다음으로, 독립변수(Independent variables)는 인명피해 발생과 관련된 요인을 분석하기 위해 기록된 사고 특성과 도로·주행 환경 정보를 중심으로 구성하였다. 이러한 기준을 통해 18개 후보 변수를 도출하였으며, 사고 상황, 운전자 및 차량, 도로 및 주행 환경 요인을 반영하는 총 14개 변수를 최종 선정하였다. 구체적으로, 사고 상황 관련 변수에는 주사고원인, 교통장애요인, 사고직전차량조작 등을 포함하였으며, 운전자 및 차량 관련 변수에는 운전자상태, 연령구분, 원인차차종, 차종구분 등을 포함하였다. 도로 및 주행환경 관련 변수에는 발생지점, 사고 시 도로환경, 절성토구분, 평면선형, 조명시설을 포함하였으며, 날씨와 노면상태는 전반적인 주행여건의 영향을 통제하기 위한 제어변수(Control variables)로 설정하였다. 분석에 사용된 변수의 세부적인 통계 특성은 <Table 1>에서 제시된다.

Table 1. Variable definitions and descriptive statistics

Category	Variable	Description	Number (Count)	Percentage (%)
Dependent variable	Casualty occurrence	Property-damage-only	74,304	89.20
		Casualty	8,993	10.80
Independent variables	Primary cause	Speeding	20,952	25.15
		Inattention	18,405	22.10
		Drowsy driving	10,653	12.79
		Road debris	8,308	9.97
		Tire failure	3,078	3.70
		Single-vehicle fire	1,884	2.26
		Insufficient safe distance	1,811	2.17
		Improper overtaking	1,452	1.74
		Road condition	1,114	1.34
		Pothole	986	1.18
		Improper loading	979	1.18
		Animal intrusion	960	1.15
		Other	11,200	13.45
		Vehicle, other	541	0.65
		Vehicle defect, other	509	0.61
		Unspecified	465	0.56
	Traffic obstruction	No obstruction	80,492	96.63
		Stopped vehicle	1,506	1.81
		Congestion	887	1.06
		Other	412	0.49
	Crash location	Mainline	57,381	68.89
		Ramp	12,285	14.75
		Tollgate	8,946	10.74
		Tunnel	3,388	4.07
		Rest area	1,177	1.41

		Other	120	0.14
	Driver condition	Normal	75,930	91.16
		Fatigue	4,434	5.32
		Drinking	2,066	2.48
		Other	867	1.04
	Road condition at crash	Normal	66,534	79.88
		Slippery surface	11,117	13.35
		Fallen object	2,291	2.75
		Pothole	1,317	1.58
		Sight obstruction	852	1.02
		Other	1,186	1.42
	At-fault vehicle type	Passenger car	53,066	63.71
		Truck	20,280	24.35
		Trailer	4,672	5.61
		Van/bus	4,373	5.25
		Special vehicle	550	0.66
		Other	356	0.43
	Weather	Clear	51,752	62.13
		Rain	17,090	20.52
		Cloudy	11,135	13.37
		Snow	2,926	3.51
		Other	394	0.47
	Lighting facility	Not applicable (daytime)	43,215	51.88
		On	24,560	29.48
		None	12,682	15.23
		Off	2,840	3.41
	Road surface	Dry	61,323	73.62
		Wet	21,382	25.67
		Snow-covered	469	0.56
		Other	123	0.15
	Driver age	40~49	16,290	19.56
		50~59	15,165	18.21
		30~39	13,370	16.05
		20~29	8,267	9.92
		60 and above	6,705	8.05
		Under 20	4,708	5.65
		Unknown	18,792	22.56
	Pre-crash maneuver	Driving in lane	68,090	81.74
		Excessive steering	10,226	12.28
		Lane change	1,649	1.98
		Other	3,332	4.00
	Vehicle class	Medium	28,103	33.74
		Small	18,896	22.69
		Large	10,922	13.11
		SUV	9,770	11.73
		Mini	3,452	4.14
		General freight	3,406	4.09
		Box truck	1,028	1.23
		Unknown	7,539	9.05
		Other	181	0.22
	Cut/fill section	Flat	41,484	49.80
		Fill 2~5 m	9,854	11.83

		Fill 5 m or more (combined)	9,456	11.35
		Cut under 10 m	5,765	6.92
		Cut 10 m or more	4,306	5.17
		Fill under 2 m	4,199	5.04
		Unknown	8,233	9.88
	Horizontal alignment	Straight	56,956	68.38
		Left curve	11,077	13.30
		Right curve	10,807	12.97
		Unknown	4,457	5.35

주: 성토고 5m 이상 범주는 원자료의 5m 이상 15m 미만 8,164건과 15m 이상 1,292건을 통합한 9,456건이다. 미상·기타 범주는 각 변수의 마지막에 배치하였다.

3. 연구방법론

3.1. 분석 절차 및 개요

본 연구는 기록된 고속도로 사고에서 인명피해 발생 여부와 관련된 범주 및 상호작용을 분석하기 위해 탐색과 통계적 검토를 순차적으로 수행하였다. 탐색 단계에서는 XGBoost와 SHAP을 이용하여 예측 기여도와 상호작용 후보를 산출하였다. 후속 단계에서는 전체 표본의 다변량 로지스틱 회귀를 통해 주효과와 후보별 상호작용항을 검정하고, 음이항 회귀를 이용하여 사고당 사상자 수에 대한 관련성의 방향을 비교하였다. 이와 별도로 영업소 인접 본선의 거리별 인명피해 발생률을 기술적으로 비교하였다. 탐색과 회귀 추정에 사용된 관측치가 중복되므로 후속 검정은 독립 표본에 의한 재현 검증과 구분한다.

3.2. 변수 선별

기록된 사고 특성과 도로·주행 환경 변수 중 분석에 활용할 변수를 선정하기 위해, 후보 변수 간 연관성과 종속변수와의 연관성을 검토하였다. 후보 변수 간 높은 연관성은 정보의 중복으로 인해 모형 추정의 안정성을 저하시킬 수 있으므로, 분석에 앞서 변수 간 연관성을 확인하였다. 일반적으로 연속형 변수(Continuous variable) 간 연관성은 상관계수를 이용하여 평가하지만, 본 연구의 독립변수는 모두 범주형 변수(Categorical variable)로 구성되어 있어 상관계수를 직접 적용하기 어렵다. 이에 범주형 변수 간 연관성을 측정할 수 있는 Cramér's V를 활용하였다. 다만, Cramér's V는 표본 크기가 작고 범주 수가 많을수록 연관성을 과대 추정할 가능성이 있으므로, 본 연구에서는 이러한 편향을 보정한 편향 보정 Cramér's V(Bias-corrected Cramér's V)를 적용하였다[17].

후보 변수 간 편향 보정 Cramér's V가 0.6 이상인 경우 종속변수와의 연관성이 상대적으로 낮은 변수를 제외하고, 남은 변수는 종속변수와의 편향 보정 Cramér's V가 높은 순으로 정렬하여 상위 14개를 유지하였다. 이러한 절차를 통해 18개 후보 중 14개 변수를 선정하였다. 예측모형에는 전체 범주에 대한 86개 원-핫 더미를 사용하였다. 추론용 회귀모형에서는 각 변수의 최빈 범주를 기준으로 제외하고 완전분리 범주에 대응하는 더미 열을 추가로 제거하여 71개 더미와 절편을 사용하였다. 분산팽창계수(Variance Inflation Factor, VIF)는 최빈 기준범주를 제외한 72개 더미 행렬에서 산출하였으며, 완전분리

더미를 제외하는 회귀 추정과 구분하였다. 변수 선별은 전체 자료에서 수행되었으므로 예측 성능을 해석할 때 그 영향을 고려한다.

3.3. XGBoost-SHAP 기반 위험요인 탐색

XGBoost는 결정트리를 순차적으로 결합하는 그래디언트 부스팅 알고리즘으로, 정규화와 희소자료 처리 기능을 제공한다[10]. 본 연구에서는 검증자료를 이용한 조기 종료(Early stopping)를 적용하였으며, 최대 깊이 6, 학습률 0.05, 표본 추출 비율 0.8, 변수 추출 비율 0.8, 자식 노드의 최소 가중치 합 5를 사용하였다.

교통사고 심각도 연구에서는 집단 불균형을 고려한 분류 방법이 검토되어 왔다[18]. 본 연구에서는 다수 집단을 무작위로 추출하는 언더샘플링을 적용하여 각 시드에서 두 집단을 각각 8,993건으로 구성한 17,986건을 개발자료 14,388건과 평가자료 3,598건으로 층화 분할하였다. 개발자료 중 2,159건은 조기 종료 검증에, 나머지 12,229건은 모형 적합에 사용하였다. 시드 42~46의 반복 홀드아웃 성능을 평균으로 제시하고 주요 지표의 표준편차를 함께 보고하였다. 대표 균형 분할에서는 XGBoost와 L2 규제 로지스틱 회귀에 동일한 86개 더미와 분할을 적용하여 예측 성능을 비교하였다. 이 로지스틱 회귀는 전체 자료의 71개 더미와 절편으로 OR를 추정하는 비규제 모형과 구분한다. 클래스 가중치를 적용한 불균형 XGBoost도 보조적으로 평가하였다. 불균형 모형의 임계값 0.61은 평가자료에서 F1-score를 최대화하도록 선택되었으므로 해당 성능은 독립적인 임계값 검증 성능으로 해석하지 않는다. Precision–Recall 성능은 average precision(AP)으로 산출하였다.

SHAP은 개별 예측값과 기준 예측값의 차이를 변수별 기여도로 분해한다[13]. 일반 SHAP 분포 그림은 대표 시드 42의 균형자료 17,986건에서 산출하였으며, 이 자료에는 학습·검증·평가 관측치가 모두 포함된다. 한편 SHAP과 회귀계수의 방향 비교에는 평가자료 3,598건에서 해당 범주가 30건 이상 관측되어 평균 SHAP 방향을 산출할 수 있는 비기준 범주를 사용하였다. 따라서 분포 그림의 표본과 방향 비교의 표본을 구분하여 해석한다.

상호작용 후보는 대표 균형 평가자료에서 무작위로 추출한 2,000건을 이용하여 선정하였다. 기준 A는 전체 추출 표본에서 SHAP 상호작용 절댓값의 평균을, 기준 B는 두 범주가 동시에 관측된 표본에서 대칭 성분을 합산한 상호작용 절댓값의 평균을 사용하였다. 기준 B는 동시 관측이 30건 이상인 쌍에 적용하였으며, 동일 변수에서 파생된 더미쌍은 제외하였다. 각 기준의 상위 15쌍을 합쳐 중복된 6쌍을 제외한 24쌍을 후속 검정 대상으로 선정하였다. 모형 구현에는 Python의 xgboost와 shap 패키지를 이용하였다.

3.4. 후속 통계 분석

SHAP 상호작용 값은 예측모형의 변수 쌍별 기여도를 나타내며, 로지스틱 회귀의 상호작용항은 다른 주효과를 통제한 추가적인 로그오즈를 나타낸다. 두 지표는 정의와 비교 기준이 다르므로, SHAP 순위에 따른 후보 선정과 회귀계수의 유의성 검정을 구분하였다.

후속 통계 분석은 변수 수준과 범주 수준으로 구분하여 수행하였다. 먼저 변수 수준에서는 카이제곱 검정을 통해 14개 독립변수와 인명피해 발생 여부 간 연관성의 통계적 유의성을 검정하고, 연관성의 크기는 Cramér's V를 이용하여 평가하였다. 범주 수준에서는 전체 83,297건의 자료에 다변량 로지스틱 회귀모형을 적용하여 범주별 오즈비(Odds Ratio, OR), 95% 신뢰구간, p값을 추정하였다. 로지스틱 회귀모형은 식 (1)과 같으며, 각 변수에서 관측 빈도가 가장 높은 범주를 기준범주로 설정하였다. 특정 범주에서 인명피해 사고가 한 건도 관측되지 않은 경우에는 완전분리(Complete separation)로 인해 회귀계수를 안정적으로 추정하기 어려우므로, 해당 범주에 대응하는 더미 열을 제외하되 관측 행은 유지하였다. 포트홀 986건의 더미 열을 제외한 결과, 주사고원인의 기준 코딩에는 과속과 포트홀이 함께 포함된다.

$$logit(P(Y=1)) = \beta_0 + \sum_j \beta_j x_j \qquad (1)$$

여기서, Y는 인명피해 발생 여부를 나타내는 이항 종속변수로, 인명피해가 발생한 경우 1, 발생하지 않은 경우 0의 값을 갖는다. x_j는 14개 독립변수에서 만들어진 j번째 더미변수이며, β_j는 해당 변수의 회귀계수이다. 회귀계수를 지수화한 $OR = \exp(\beta_j)$는 다른 변수의 영향을 통제한 상태에서 해당 범주의 인명피해 발생 오즈가 기준범주의 몇 배인지를 나타낸다.

아울러 로지스틱 회귀분석에서 관찰된 관련성의 방향이 사고당 사상자 수를 대상으로 한 분석에서도 동일한지 비교하였다. 이를 위해 사고 1건당 사상자 수를 종속변수로 하는 음이항 회귀모형을 적용하여 발생률비(Incidence rate ratio, IRR)를 추정하였으며, 이에 대한 모형은 식 (2)와 같다.

$$\ln(\mu_i) = \beta_0 + \sum_j \beta_j x_{ij}, Var(Y_i|x_i) = \mu_i + \alpha\mu_i^2 \qquad (2)$$

여기서, 식 (2)의 μ_i는 해당 사고의 설명변수가 주어졌을 때의 기대 사상자 수이다. Y_i는 사고 i에서 사상자 수를 나타내는 확률변수이며, x_{ij}는 사고 i의 j번째 더미변수이다. 회귀계수를 지수화한 $\exp(\beta_j)$는 발생률비(Incidence Rate Ratio, IRR)로, 다른 변수의 영향을 통제한 상태에서 해당 범주의 예상 사상자 수가 기준범주의 몇 배인지를 나타낸다. α는 조건부 분산이 평균을 초과하는 정도를 나타내는 과산포 모수로, α가 0이면 포아송 모형에 해당하며 값이 클수록 과산포의 정도가 증가한다[19]. 본 연구에서는 포아송 적합값에 기초한 과산포 모수 추정값이 양수로 나타나 음이항 회귀모형을 적용하였다.

각 상호작용 후보에 대해 71개 주효과 더미와 절편을 포함한 로지스틱 회귀모형에 두 더미의 곱항 하나를 추가하였다. 식 (3)의 상호작용 계수에 대한 Wald 검정을 수행하고, 선정된 24개 후보 집합 내 다중검정을 고려하여 각 Wald 검정 p값에 Benjamini–Hochberg의 거짓발견률(False Discovery Rate, FDR) 보정 절차를 적용하고 보정 p값을 q값으로 표기하였다[20]. 전체 회귀 표본에서 두 조건이 동시에 관측된

사고가 100건 미만인 후보는 제외하도록 설정하였으며, 선정된 24쌍은 모두 이 기준을 충족하였다.

$$logit(P(Y=1)) = \beta_0 + \sum_j \beta_j x_j + \gamma(x_A \times x_B) \qquad (3)$$

여기서 x_A와 x_B는 상호작용을 검정할 두 더미변수이며, γ는 두 조건이 동시에 성립할 때 주효과 모형에 추가되는 로그오즈를 나타내는 상호작용 계수이다.

분석방법 간 방향 비교는 SHAP 방향을 산출할 수 있는 비기준 범주에서 SHAP–로지스틱 부호 일치율을, 두 회귀모형에서 공통으로 유의한 범주에서 로지스틱–음이항 부호 일치율을 각각 산출하였다. 음이항 회귀모형의 과산포 모수는 포아송 적합값을 이용하여 잔차제곱에서 적합값을 뺀 값의 합을 적합값 제곱합으로 나누는 모멘트 방식으로 추정한 후, 해당 값을 고정한 GLM 음이항 모형을 적합하였다. 따라서 음이항 회귀모형에서 제시된 추정 결과는 고정된 α를 전제로 한다. 모형의 구현에는 Python의 statsmodels와 scikit-learn 패키지를 이용하였다.

3.5. 영업소 인접 본선의 거리별 발생률 보조 분석

영업소 범주와 인명피해 발생의 관련성이 인접 본선에서도 관측되는지 살펴보기 위해 거리별 발생률을 보조적으로 분석하였다. 이정이 있는 영업소 사고를 노선명 그룹별로 정렬하고 인접 이정 차이가 0.7km를 초과하면 다른 군집으로 구분하였다. 사고가 5건 이상인 군집의 이정 중앙값을 영업소 위치로 추정하고, 동일 노선명 그룹의 본선 사고에서 가장 가까운 추정 영업소까지의 이정 차이를 계산하였다. 거리 구간은 0~0.5, 0.5~1, 1~2, 2~3, 3~5, 5~10, 10km 이상으로 구분하였으며, 각 유한 구간은 하한을 포함하고 상한을 제외하였다. 거리별 인명피해 발생률과 이항 비율의 Wilson 95% 신뢰구간을 산출하였다[21]. 이 분석은 주행 방향·경로와 다른 공변량을 통제하지 않은 기술적 비교이다.

4. 분석 결과

4.1. 변수 선별 및 예측 성능

본 절에서는 변수 선별 결과와 탐색 단계에 적용한 모형의 예측 성능을 제시한다. 먼저, 전체 후보 변수에 대해 편향 보정 Cramér's V를 이용하여 후보 변수 간 연관성과 종속변수와의 관련성을 검토하였다. 그 결과, 주야구분은 조명시설과 높은 관련성을 보였으며(V=0.710), 주말여부(V=0.020), 포장구분(V=0.010), 성별(V=0.009)은 종속변수와의 관련성이 낮게 나타났다. 이에 따라 4개 변수를 제외한 총 14개 변수를 최종 분석변수로 선정하였다. 원-핫 인코딩 후 산출한 VIF는 최대 5.46, 평균 1.48로 나타났으며, 10을 초과하는 더미변수는 확인되지 않았다.

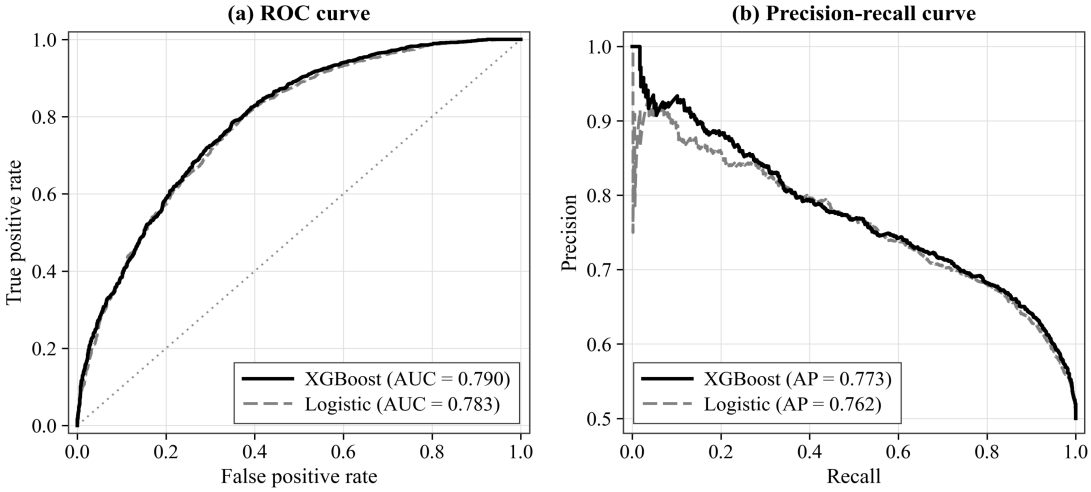
다음으로, 인명피해 사고와 대물피해 사고의 수를 동일하게 구성한 언더샘플링 자료를 이용하여 XGBoost 모형을 5회 반복 평가한 결과, 평균 Accuracy는 0.709, Precision은 0.689, Recall은 0.762, F1-score는 0.724, ROC-AUC는 0.785, AP는 0.766으로 나타났다. ROC-AUC의 표준편차는 0.005, F1-score는 0.004, Recall은 0.008로 나타나 반복에 따른 예측 성능의 변동은 크지 않았다. 또한 보조적인 예측 성능을 검토한 결과, 전체 불균형 자료에 클래스 가중치를 적용한 XGBoost는 ROC-AUC가 0.777로 유

사한 수준이었으나 Precision과 F1-score는 각각 0.262와 0.352로 낮게 나타났다. 아울러, 동일한 균형자료 분할에서 XGBoost와 로지스틱 회귀모형을 비교한 결과, ROC-AUC는 각각 0.790과 0.783, AP는 각각 0.773과 0.762로 유사한 수준이었으며, XGBoost가 두 지표에서 소폭 높은 값을 보였다. <Table 2>에는 모형별 성능을, <Fig. 1>에는 대표 시드 42 균형 평가자료의 ROC 및 Precision-Recall 곡선을 제시하였다. 5시드 평균과 대표 분할 결과를 구분하며, 평가 표본의 인명피해 비율이 달라지는 경우 Precision·F1·AP를 직접 비교하여 불균형 처리 방식의 우열을 판단하지 않는다.

Table 2. Predictive performance by model configuration

Model	Accuracy	Precision	Recall	F1	ROC-AUC	AP
XGBoost (balanced, mean of 5 seeds)	0.709	0.689	0.762	0.724	0.785	0.766
Logistic (balanced, representative split)	0.710	0.687	0.772	0.727	0.783	0.762
XGBoost (balanced, representative split)	0.713	0.696	0.759	0.726	0.790	0.773
XGBoost(imbalanced + weighted, threshold 0.61)	0.787	0.262	0.535	0.352	0.777	0.310

Fig. 1. ROC and precision-recall curves for the balanced evaluation set



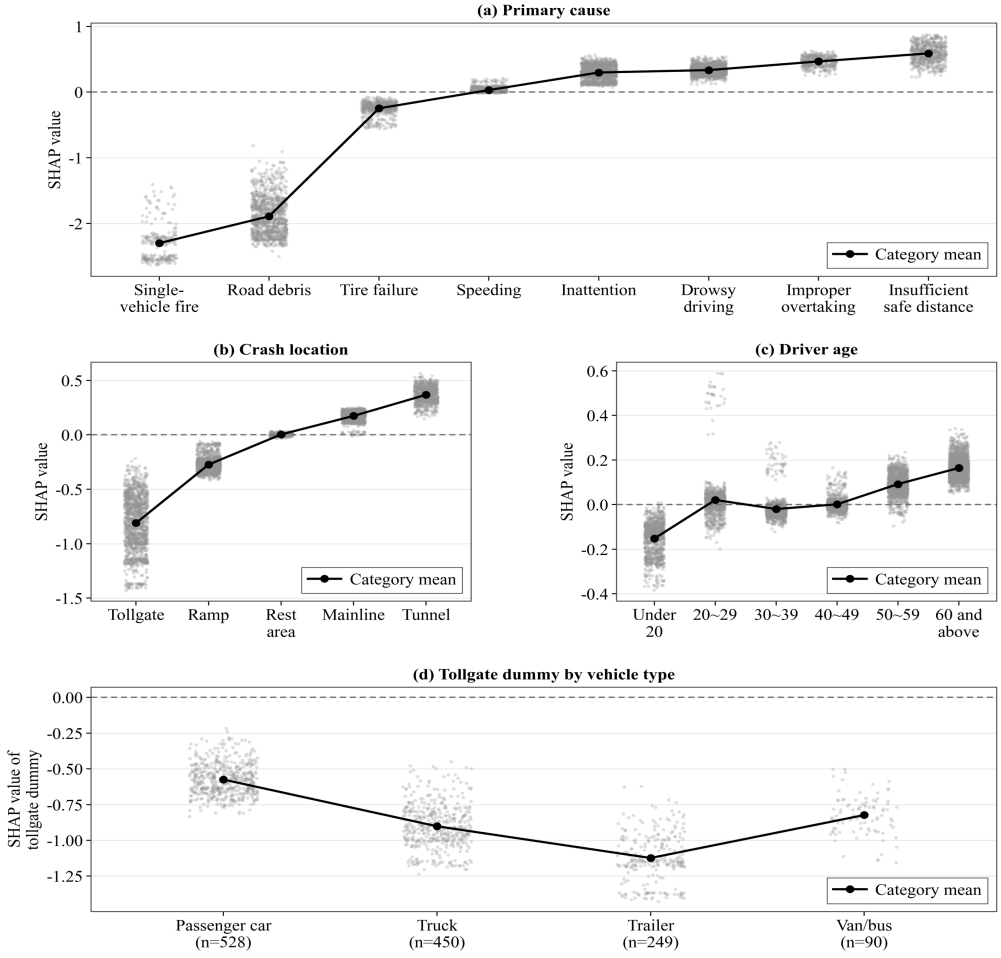
4.2. SHAP 기반 주요 위험요인 및 상호작용 분석

<Fig. 2>의 일반 SHAP 분포에서는 주사고원인과 발생지점의 범주에 따라 예측 기여도의 차이가 나타났다. 단독차량화재와 노면잡물은 인명피해 발생 예측값을 낮추는 방향으로, 주시태만·졸음·추월불량·안전거리 미확보는 높이는 방향으로 나타났다. 발생지점에서는 영업소와 램프가 음(-), 본선과 터널이 양(+)의 기여를 보였다. 그림에 제시한 영업소 사고의 네 차종에서 영업소 더미의 평균 SHAP은 모두 음수였으며 그 크기는 차종에 따라 달랐다. 이는 예측모형의 조건별 기여도 차이를 나타내며 인과적 보호효과나 회귀 상호작용의 유의성을 의미하지 않는다.

일반 SHAP 분포와 별도로 산출한 상호작용 지표를 이용하여 후보 쌍을 선정하였다. 3.3절에서 정의한 기준 A와 B의 각 상위 15쌍 가운데 6쌍이 중복되어 총 24쌍을 후속 검정에 사용하였다. 두 기준에

서 공통으로 선정된 영업소-승용 등의 조합을 포함하되, 기여도 순위 자체를 통계적 유의성으로 해석하지 않았다.

Fig. 2. Category-specific SHAP distributions in the representative balanced sample (n=17,986): (a) primary cause, (b) crash location, (c) driver age, and (d) SHAP values of the tollgate indicator among tollgate crashes, stratified by vehicle type. Connected circles indicate category means.



4.3. 통계적 검정

변수 수준의 카이제곱 검정 결과, 분석에 포함된 14개 독립변수 모두 인명피해 발생 여부와 통계적으로 유의한 연관성을 보였다(p<0.001). 이러한 연관성이 다른 변수들의 영향을 고려한 경우에도 유지되는지 확인하기 위해 다변량 로지스틱 회귀분석을 수행하였다. 전체 83,297건의 사고자료를 대상으로 분석한 결과, 절편만 포함한 모형과 적합모형의 로그우도로 계산한 McFadden's pseudo R^2는 0.148로 나타났으며[22], 독립변수들에서 파생된 총 71개 더미변수 중 51개에서 통계적으로 유의한 연관성이 확인되었다(p<0.05). 이는 단변량 분석에서 유의한 연관성을 보인 변수들이 다른 요인을 동시에 고려한 다변량 분석에서는 범주에 따라 상이한 통계적 유의성을 나타냄을 보여준다. 반면, 주사고원인의 포트홀 범주에 해당하는 986건의 사고에서는 인명피해가 발생하지 않아 회귀계수 추정 과정에서 완전분리 문제가 발생할 수 있으므로 해당 더미 열만 제외하고 986개 관측 행은 유지하였다. 이에 따라 주사고원

인의 기준효과에는 과속과 포트홀이 함께 코딩된다. 주요 범주의 오즈비(OR)와 95% 신뢰구간(CI)은 <Table 3>에 제시된다.

Table 3. Odds ratios of factors associated with casualty occurrence

Factor	OR	95% CI	Factor	OR	95% CI
Stopped vehicle (no obstruction)	3.45	3.08–3.87	Tollgate (mainline)	0.12	0.11–0.14
Trailer (passenger car)	2.70	2.18–3.34	Ramp (mainline)	0.30	0.27–0.33
Insufficient safe distance (pooled reference)	2.07	1.82–2.36	Road debris (pooled reference)	0.10	0.08–0.12
Van/bus (passenger car)	1.89	1.72–2.09	Single-vehicle fire (pooled reference)	0.05	0.03–0.07
Lane change (driving in lane)	1.63	1.43–1.85	Snow (clear)	0.51	0.42–0.63
Drowsy driving (pooled reference)	1.57	1.43–1.72	Wet (dry)	0.82	0.72–0.94
Inattention (pooled reference)	1.54	1.42–1.66	No lighting (daytime)	1.24	1.16–1.32

Note: For primary cause, the reference coding combines speeding and pothole observations because the pothole dummy was omitted while its 986 observations were retained.

정차차량(OR=3.45), 트레일러(2.70), 안전거리 미확보(2.07), 승합(1.89), 화물(1.72), 차로변경(1.63), 졸음(1.57), 주시태만(1.54)은 기준범주 대비 높은 인명피해 발생 오즈를 보였다. 반면 단독차량화재(0.05), 노면잡물(0.10), 영업소(0.12), 램프(0.30), 눈(0.51), 습기(0.82)는 낮은 오즈를 보였다. 조명시설이 없는 경우의 오즈는 주간보다 높았다(1.24). 주요 오즈비와 95% 신뢰구간은 <Table 3>과 <Fig. 3>에 제시하였다. 주사고원인의 비교 기준은 포트홀 더미 제외에 따른 통합 기준효과이므로 순수한 과속 대비 효과로 해석하지 않는다.

개별 요인의 영향에 이어 요인 간 결합효과를 검토하기 위해 SHAP 분석에서 도출한 24개 상호작용 후보에 대한 통계적 검정을 수행하였다. 각 후보의 상호작용항을 14개 독립변수의 주효과를 포함한 모형에 개별적으로 추가하여 분석한 결과, 다중검정 보정 후 총 13개 조합에서 통계적으로 유의한 상호작용이 확인되었다(q<0.05). 이 중 양(+)의 상호작용 계수를 보인 주요 조합은 영업소-승용, 승합-대형차종, 주시태만-본선이었으며, 두 조건이 동시에 나타날 때 개별 효과의 합으로 예상되는 수준보다 인명피해 발생 로그오즈가 높게 나타났다. 반면, 노면잡물-운행차로주행, 노면잡물-도로환경 정상, 주시태만-영업소, 램프-승용, 안전거리 미확보-승용, 주시태만-핸들과대조작, 과속-본선은 음(-)의 상호작용 계수를 보여 개별 효과의 합으로 예상되는 수준보다 낮은 로그오즈를 나타냈다. 이외에도 영업소-차종구분 미상, 영업소-조명시설 작동, 도로환경 정상-건조 노면에서 유의한 상호작용이 확인되었으나, 미상 범주의 해석 한계 등을 고려하여 이를 일반적인 인과기전으로 확대 해석하지 않았다. 유의한 상호작용 조합의 계수·q값·동시 발생 건수는 <Table 4>에 제시된다.

Fig. 3. Adjusted odds ratios and 95% confidence intervals for the 20 categories shown in the forest plot

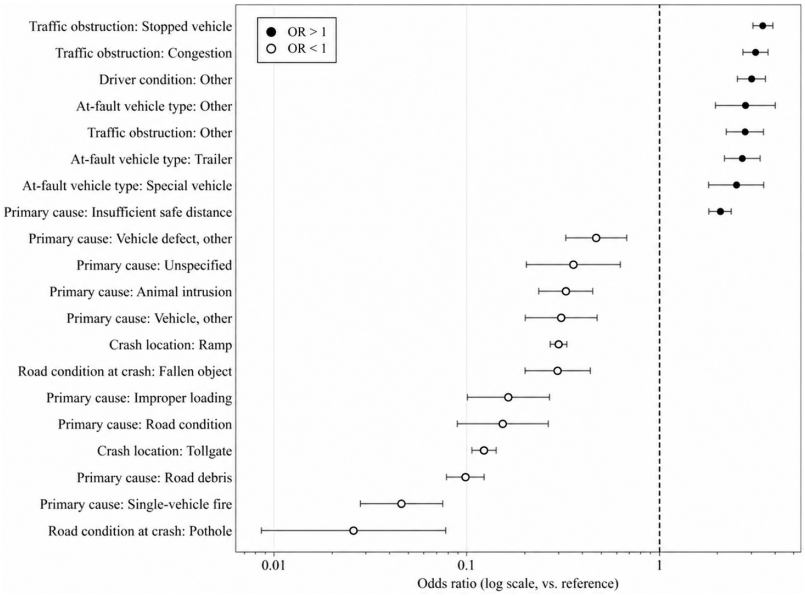


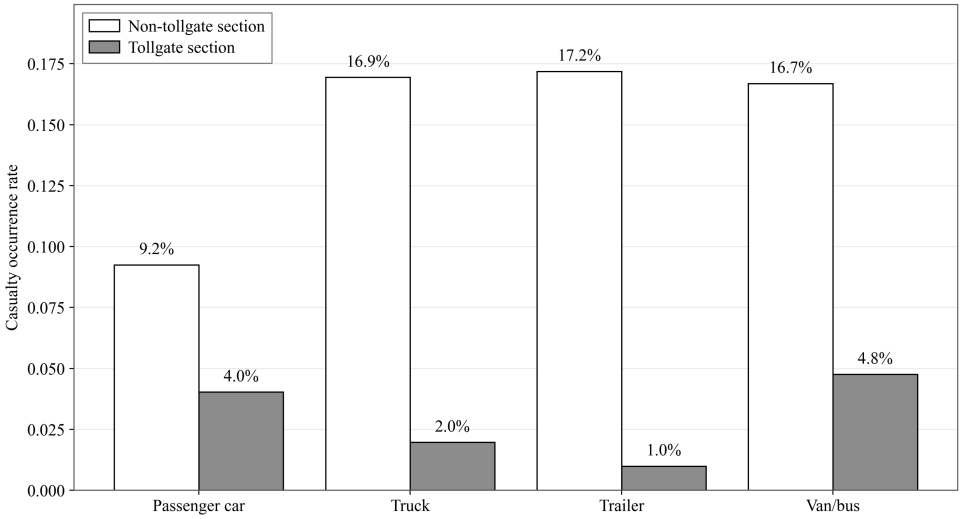
Table 4. Significant interaction effects after BH-FDR correction

Interaction pair	Coefficient (log-odds)	FDR q	Co-occurrence (n)
Road debris × Driving in lane	−1.640	<0.001	8,025
Road debris × Normal road condition	−1.522	<0.001	5,987
Tollgate × Passenger car	+1.361	<0.001	3,201
Tollgate × Unknown vehicle class	−1.198	<0.001	2,056
Van/bus × Large vehicle class	+0.964	<0.001	987
Inattention × Tollgate	−0.935	<0.001	4,311
Ramp × Passenger car	−0.468	<0.001	8,090
Inattention × Mainline	+0.439	<0.001	11,105
Normal road condition × Dry surface	+0.405	0.025	56,191
Tollgate × Lighting on	−0.405	0.009	3,531
Insufficient safe distance × Passenger car	−0.402	0.002	1,084
Inattention × Excessive steering	−0.328	<0.001	2,467
Speeding × Mainline	−0.255	0.002	13,022

주요 상호작용 조합의 인명피해 발생 특성을 살펴보면, 원인차 차종이 승합이고 차종구분이 대형인 사고 987건의 인명피해 발생률은 28.3%로, 전체 사고의 평균 발생률인 10.8%보다 높게 나타났다. 영업소 여부에 따른 차종별 인명피해 발생률을 비교한 결과(Fig. 4), 영업소 외 구간에서는 트레일러(17.2%), 화물(16.9%), 승합(16.7%)이 승용(9.2%)보다 높은 발생률을 보였다. 반면, 영업소 구간에서는 승용(4.0%), 승합(4.8%), 화물(2.0%), 트레일러(1.0%)로 비교한 네 차종에서 영업소 외 구간보다 낮은 발생률을 나타냈다. 특히 영업소 구간과 영업소 외 구간 간 인명피해 발생률 차이는 승용보다 승합, 화

물 및 트레일러에서 상대적으로 크게 나타나, 영업소 여부에 따른 인명피해 발생 양상이 차종에 따라 차이를 보였다.

Fig. 4. Casualty occurrence rate by vehicle type at tollgate and non-tollgate sections

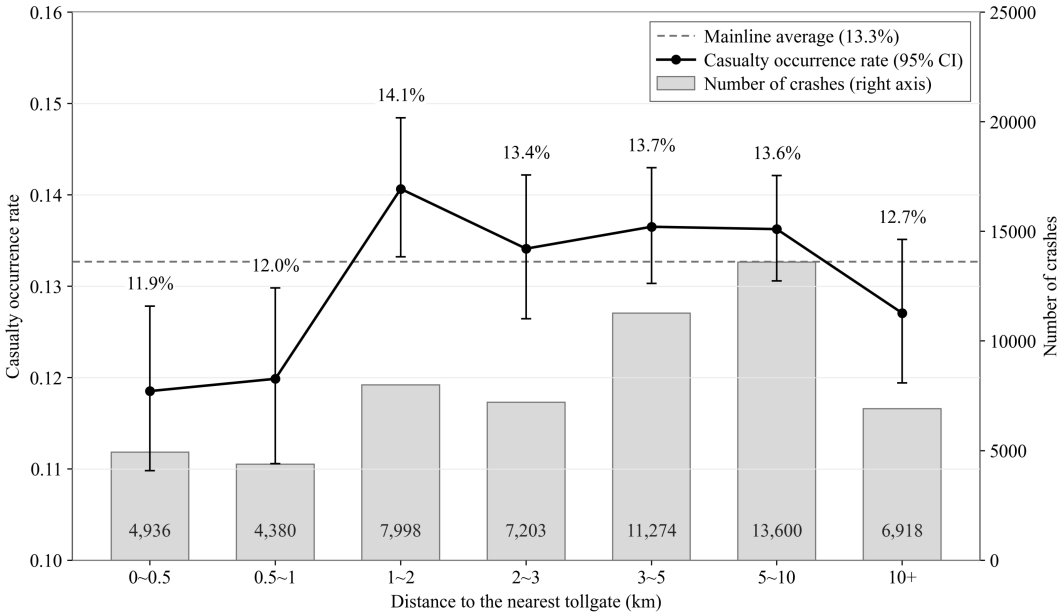


4.4. 영업소(TG) 인접 구간의 인명피해 발생률 비교

영업소 범주의 관련성을 보완적으로 살펴보기 위해 3.5절의 방법에 따라 인접 본선의 거리별 인명피해 발생률을 비교하였다. 46개 노선명 그룹에서 추정한 331개 영업소 위치를 이용하였으며, 이들 그룹에 속하는 본선 사고 56,309건을 최종 분석하였다. 거리는 동일 노선명 그룹에서 사고 이정과 가장 가까운 추정 영업소 이정의 절대 차이로 산정하였다.

영업소에서 1km 미만인 본선 사고의 인명피해 발생률은 11.9~12.0%로, 거리 분석 표본의 평균인 13.3%보다 낮았다. 1~2km 구간에서는 14.1%로 가장 높았으며, 해당 구간의 Wilson 95% 신뢰구간은 1km 미만의 두 구간과 겹치지 않았다. 2~10km에서는 13.4~13.7%, 10km 이상에서는 12.7%로 나타나 거리 증가에 따른 일관된 변화는 확인되지 않았다. 이 결과는 다른 공변량과 교통노출을 통제하지 않은 기술적 비교이므로 인과적 관계나 거리별 사고 발생 위험의 차이로 해석하지 않는다. 거리별 발생률과 사고 건수는 <Fig. 5>에 제시하였다.

Fig. 5. Mainline casualty occurrence rates and crash counts by distance to the nearest estimated tollgate.



4.5. 탐색 결과와 후속 회귀 결과의 비교

평가자료에서 평균 SHAP 방향을 산출할 수 있는 비기준 범주 56개 중 46개(82.1%)는 로지스틱 회귀계수와 부호가 일치하였다. 로지스틱 회귀에서 유의한 41개 범주에서는 34개(82.9%)가 일치하였다. SHAP의 기준 예측값과 회귀의 기준범주는 서로 다르므로 이는 방향의 기술적 비교이며, 효과 크기·인과관계의 동일성이나 모형의 타당성을 입증하지 않는다.

로지스틱 회귀와 음이항 회귀에서는 각각 71개 더미 중 51개와 54개가 유의하였다. 음이항 회귀의 주요 발생률비는 정차차량 2.93(95% CI: 2.60~3.30), 트레일러 2.60(2.09~3.23), 영업소 0.14(0.13~0.16)였다. 두 모형에서 공통으로 유의한 47개 더미의 부호는 모두 일치하였다. 이는 해당 범주의 인명피해 발생 여부와 사고당 사상자 수에 관한 방향 비교이며, 두 모형의 효과 크기가 같다는 의미는 아니다.

상호작용 분석에서는 24개 후보 쌍 중 11개가 다중검정 보정 후 통계적으로 유의하지 않았다. 여기에는 기준 A에서 2위인 주시태만과 승용(q=0.060), 4위인 졸음과 승용(q=0.332), 5위인 본선과 승용(q=0.191)이 포함되었다. 이처럼 SHAP 상호작용 값이 상위에 해당하더라도 통계적 유의성이 확인되지 않은 조합이 존재하였다. 이러한 후속 검정 결과는 유의한 조합을 포함하여 탐색적 분석의 범위에서 해석하였다.

5. 결 론

본 연구는 2011~2019년 고속도로 사고 83,297건에서 인명피해 발생 관련 요인과 상호작용을 분석하였다. XGBoost와 SHAP으로 후보를 탐색한 후 로지스틱 회귀와 다중검정 보정을 통해 통계적 근거를

검토하였다. 음이항 회귀로 사고당 사상자 수에 대한 관련성의 방향을 비교하고, 영업소 인접 본선의 거리별 발생률을 보조적으로 분석하였다.

정차차량, 트레일러와 승합, 안전거리 미확보·졸음·주시태만은 기준범주 대비 높은 인명피해 발생 오즈를 보였으며, 영업소와 램프는 본선보다 낮은 오즈를 보였다. 주사고원인의 기준효과에는 과속과 포트홀이 함께 코딩되었다는 점을 고려해야 한다. SHAP 기반 24개 상호작용 후보 중 13쌍은 BH-FDR 보정 후 유의하였다. SHAP과 로지스틱 회귀의 방향은 비교 가능한 56개 범주 중 46개(82.1%)에서 일치하였고, 로지스틱과 음이항 회귀에서 공통으로 유의한 47개 범주의 방향은 모두 일치하였다. 균형 평가자료의 5회 평균 ROC-AUC와 F1-score는 각각 0.785와 0.724였다.

이러한 결과는 교통안전 관리에서 개별 범주의 관련성과 결합 특성을 함께 검토할 필요성을 시사한다. 정차차량의 높은 오즈와 주시태만–본선의 양(+)의 상호작용은 사고 감지 및 운전자 주의 관리의 우선 검토 근거가 될 수 있다. 영업소에서 1km 미만인 본선의 낮은 발생률은 속도·교통노출 및 다른 공변량을 통제하지 않은 기술적 관측이므로 감속 효과의 근거로 해석하지 않았다. 승합–대형차종의 발생률 28.3%도 전체 표본의 10.8%보다 높았으나, 이를 특정 안전대책의 개입 효과로 해석하려면 추가 연구가 필요하다.

본 연구는 설명가능 기계학습의 예측 기여도와 회귀모형의 통계적 유의성을 구분하여 검토하였다. SHAP 상호작용 기여도가 높은 후보 중에서도 회귀 검정에서 유의하지 않은 조합이 확인되었다. 예측 기여도 순위와 주효과를 통제한 상호작용 검정 결과를 함께 제시하되, 후속 검정과 FDR 보정만으로 후보 선정에 따른 추론 문제가 해소되거나 독립 표본에서의 재현 가능성이 확보되는 것은 아니다.

본 연구는 균형자료의 예측 성능을 실제 인명피해 비율이 10.8%인 자료와 구분하여 해석해야 한다. 사망·중상·경상을 통합한 이항 결과는 심각도 차이를 충분히 반영하지 못하며, 교통량 등 사고 노출 수준도 고려하지 못하였다. 전체 자료의 변수 선별, 탐색·검정 관측치의 중복, 성토 범주 통합과 포트홀 더미 제외에 따른 기준효과도 해석상의 제약이다. 향후 범주 정의와 민감도 분석, 심각도별 모형, 교통노출·도로 기하구조 자료의 결합, 탐색·검정 표본의 분리를 통해 결과의 안정성과 재현 가능성을 검토할 필요가 있다.

사사

This research was supported by the ANCHOR program through the Daejeon ANCHOR Center, funded by the Ministry of Education (MOE) and the Daejeon Metropolitan City, Republic of Korea (2026-ANCHOR-06-013). This research was also supported by the AI Data Science Research Institute of Hannam University.

참고문헌

(1) Høye, A. K. and Hesjevoll, I. S., 2020, “Traffic Volume and Crashes and How Crash and Road Characteristics Affect Their Relationship: A Meta-Analysis,” Accident Analysis and Prevention, Vol. 145, 105668.

(2) Christoforou, Z., Cohen, S. and Karlaftis, M. G., 2010, “Vehicle Occupant Injury Severity on Highways: An Empirical Investigation,” Accident Analysis and Prevention, Vol. 42, No. 6, pp. 1606~1620.

(3) Gabauer, D. J., 2010, “Secondary Collisions Following a Traffic Barrier Impact: Frequency, Factors, and Occupant Risk,” Annals of Advances in Automotive Medicine, Vol. 54, pp. 223~232.

(4) Huang, H., Ding, X., Yuan, C., Liu, X. and Tang, J., 2023, “Jointly Analyzing Freeway Primary and Secondary Crash Severity Using a Copula-Based Approach,” Accident Analysis and Prevention, Vol. 180, 106911.

(5) Riuttanen, A., Karjalainen, E., Jokihaara, J., Huttunen, T. T. and Mattila, V. M., 2024, “Cumulative Costs of Severe Traffic Injuries in Finland: A 2-Year Retrospective Observational Study of 252 Patients,” Scientific Reports, Vol. 14, No. 1, 11078.

(6) Eboli, L., Forciniti, C. and Mazzulla, G., 2020, “Factors Influencing Accident Severity: An Analysis by Road Accident Type,” Transportation Research Procedia, Vol. 47, pp. 449~456.

(7) Wang, J., Lu, H., Sun, Z. and Wang, T., 2020, “Exploring Factors Influencing Injury Severity of Vehicle At-Fault Accidents: A Comparative Analysis of Passenger and Freight Vehicles,” International Journal of Environmental Research and Public Health, Vol. 17, No. 4, 1146.

(8) Lee, J. Y., Chung, J. H. and Son, B., 2008, “Analysis of Traffic Accident Size for Korean Highway Using Structural Equation Models,” Accident Analysis and Prevention, Vol. 40, No. 6, pp. 1955~1963.

(9) Milton, J. C., Shankar, V. N. and Mannering, F. L., 2008, “Highway Accident Severities and the Mixed Logit Model: An Exploratory Empirical Analysis,” Accident Analysis and Prevention, Vol. 40, No. 1, pp. 260~266.

(10) Chen, T. and Guestrin, C., 2016, “XGBoost: A Scalable Tree Boosting System,” Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, pp. 785~794.

(11) Kwon, C. W. and Chang, H. H., 2021, “Comparative Analysis of Traffic Accident Severity of Two-Wheeled Vehicles Using XGBoost,” 한국ITS학회논문지, Vol. 20, No. 4, pp. 1~12.

(12) Lee, S. M., Yoon, B. J. and Lwin, W. Y., 2024, “Studying the Comparative Analysis of Highway Traffic Accident Severity Using the Random Forest Method,” 한국재난정보학회논문집, Vol. 20, No. 1, pp. 156~168.

(13) Lundberg, S. M. and Lee, S. I., 2017, “A Unified Approach to Interpreting Model Predictions,” Advances in Neural Information Processing Systems, Vol. 30, pp. 4765~4774.

(14) Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N. and Lee, S. I., 2020, “From Local Explanations to Global Understanding with Explainable AI for Trees,” Nature Machine Intelligence, Vol. 2, No. 1, pp. 56~67.

(15) Moon, J., Jang, J. and Lee, S., 2025, “서울시 고령운전자의 중상 및 사망사고와 도로환경

의 연관성 분석: 기계학습을 활용한 비선형성과 상호작용효과를 중심으로," 대한교통학회지, Vol. 43, No. 2, pp. 161~180.

(16) Ko, E. J. and Jang, K. T., 2025, "Integrated Statistical and Machine Learning Approach for Freeway Accident Severity Prediction," 안전문화연구, No. 49, pp. 351~367.

(17) Bergsma, W., 2013, "A Bias-Correction for Cramér's V and Tschuprow's T," Journal of the Korean Statistical Society, Vol. 42, No. 3, pp. 323~328.

(18) Jeong, H., Jang, Y., Bowman, P. J. and Masoud, N., 2018, "Classification of Motor Vehicle Crash Injury Severity: A Hybrid Approach for Imbalanced Data," Accident Analysis and Prevention, Vol. 120, pp. 250~261.

(19) Cameron, A. C. and Trivedi, P. K., 2001, "Essentials of Count Data Regression," in Baltagi, B. H. (ed.), A Companion to Theoretical Econometrics, Blackwell, Oxford, pp. 331~348.

(20) Benjamini, Y. and Hochberg, Y., 1995, "Controlling the False Discovery Rate: A Practical and Powerful Approach to Multiple Testing," Journal of the Royal Statistical Society: Series B, Vol. 57, No. 1, pp. 289~300.

(21) Wilson, E. B., 1927, "Probable Inference, the Law of Succession, and Statistical Inference," Journal of the American Statistical Association, Vol. 22, No. 158, pp. 209~212.

(22) McFadden, D., 1974, "Conditional Logit Analysis of Qualitative Choice Behavior," in Zarembka, P. (ed.), Frontiers in Econometrics, Academic Press, New York, pp. 105~142.