순서형 로지스틱 회귀와 랜덤 포레스트를 이용한 고속도로 교통사고 심각도 예측모형 개발

Integrated Statistical and Machine Learning Approach for Freeway Accident Severity Prediction

ISSN: 2586-2685 안전문화연구 49호 351-367 접수일: 2025/11/25 수정일: 2025/12/08 확정일: 2025/12/08 발간일: 2025/12/30
http://doi.org/10.52902/kjsc.2025.49.351 논문투고: fpss.jams.or.kr 사무국연락처: 031-253-7776 사무국핸드폰: 010-2960-7797

고 은 정 (Ko Eun Jeong) 주저자 : 한남대학교 (조교수), 교통공학박사 E-mail : eunjeong.ko@hnu.kr
장 기 태 (Jang Ki Tea) 교신저자 : KAIST (교수), 토목환경공학박사 E-mail : kitae.jang@kaist.ac.kr

☞ 본 연구는 국토교통부 국토교통 DNA플러스 융합기술대학원 육성사업의 연구비 지원(과제번호 RS-2022-00156089)에 의해 수행되었습니다.

국 문 요 약

본 연구는 고속도로 교통사고의 심각도에 영향을 미치는 요인을 규명하고, 예측모형을 구축하여 사고 결과를 정량적으로 분석하는 것을 목적으로 한다. 이를 위해 2010년부터 2019년까지의 고속도로 사고자료를 정제하여 분석용 표준 데이터 셋을 구축하였으며, 종속변수인 사고 심각도를 사망, 부상, 물적 피해로 구분하였다. 분석 방법으로는 통계적 해석력과 비선형 예측력을 함께 확보하기 위해 순서형 로지스틱 회귀모형과 랜덤 포레스트 기법을 병행 활용하였다. 분석 결과, 사고원인, 발생지점, 차량 유형, 운전자 연령, 기상조건 등이 사고 심각도에 유의한 영향을 미치는 요인으로 도출되었다. 특히, 진출입부, 갓길부, 커브구간 등 공간적 요인과 대형차량, 젊은 운전자, 악천후 조건은 사고 심각도를 높이는 핵심 요인으로 확인되었다. 또한, 예측 정확도 비교 결과, 랜덤 포레스트 모형이 회귀모형 보다 높은 분류 성능을 보여, 교통사고 심각도가 복합적 요인 구조에 의해 결정됨을 실증적으로 확인하였다. 본 연구는 고속도로라는 특수한 교통 환경을 대상으로 통계적 접근과 기계학습 기반 분석을 융합함으로써, 사고 심각도에 대한 영향 요인과 예측력을 함께 확보하였다. 이러한 융합적 분석 접근은 기존의 단일 분석 연구가 갖는 한계를 보완하고, 고속도로 사고 특성을 반영한 실증적 분석 틀을 제시한다는 점에서 의의가 있다. 나아가, 본 연구의 결과는 향후 고속도로 안전관리 정책 수립과 사고 위험도 예측체계의 고도화에 기초 자료로 활용될 수 있을 것으로 기대된다.

[주제어] 고속도로 교통사고, 사고 심각도, 순서형 로지스틱 회귀, 랜덤 포레스트, 교통안전

Abstract

This study investigated the key factors influencing the severity of freeway traffic accidents and developed predictive models for quantitative analysis. A standardized dataset from 2010 to 2019 was used, with the accident severity classified into three ordered levels: fatal, injury, and property damage only. An ordinal logistic regression model and a random forest were used in parallel to balance the interpretability and predictive performance. The results suggested that the accident cause, crash location, vehicle type, driver age, and weather conditions significantly affect accident severity. Spatial factors, such as ramps, shoulders, and curved sections, along with the presence of large vehicles, younger drivers, and adverse weather, tended to increase the accident severity. Moreover, the random forest model achieved higher predictive accuracy than the regression model, confirming that the accident severity results from complex, nonlinear interactions among multiple factors. The explanatory and predictive understanding of accident severity was enhanced by integrating statistical and machine-learning approaches within the context of highway environments. The proposed hybrid framework overcomes the limitations of traditional single-model analyses and offers an empirical foundation for developing data-driven highway safety management and accident severity prediction systems.

[Keywords] Freeway traffic accident, Accident severity, Ordinal logistic regression, Random forest, Traffic safety

Ⅰ. 서 론

최근 들어 교통량의 지속적인 증가와 자동차 이용의 확산은 교통 체계 전반의 부담을 가중시키며, 복잡하고 불안정한 주행 환경을 초래하고 있다(Høye & Hesjevoll, 2020). 이러한 환경적 변화는 사고 발생의 가능성을 높일 뿐만 아니라, 사고 발생 시 피해 규모를 확대시키는 주요 요인으로 작용할 수 있다. 이처럼 교통사고의 위험과 잠재적 피해가 증가함에 따라, 사고 발생에 영향을 미치는 요인과 사고 결과를 규명하려는 다양한 연구들이 수행되어 왔다(Jeong et al., 2022).

그중에서도 고속도로는 일반도로보다 높은 주행 속도, 차종 간 속도 차, 높은 대형차량의 통행 비율 등으로 인해 특정 조건에서 상대적으로 교통류의 불안정성이 높아질 수 있으며, 사고 발생 시 대규모 피해로 이어질 가능성이 높아질 수 있다(Christoforou et al., 2010; Lee et al., 2021). 또한, 고속도로는 회피 공간이 제한되고 단일 사고가 2차 사고나 연쇄추돌로 확산될 수 있는 구조적 특성을 지니고 있어, 동일한 사고라도 피해 수준이 크게 달라질 수 있다(Gabauer, 2010; Huang et al., 2023). 그럼에도 불구하고 기존 연구의 상당수는 단순한 사고 발생 가능성에 초점을 두었기 때문에, 위험의 본질을 설명하는 데에는 상대적으로 한계가 있었다. 그러나, 실제 교통사고로 인한 사회·경제적 부담은 사고 건수보다 사망·중상과 같은 고 심각도(High-severity) 사고의 비중에 의해 더 크게 좌우된다는 점을 고려할 때(Lee et al., 2011; Riuttanen et al., 2024), 고속도로 사고 연구에서 심각도에 대한 분석은 필수적이다.

관련하여 수행된 일부 연구들은 주로 특정 도로 조건, 기상 환경, 혹은 운전자 행태와 같은 개별 요인이 사고에 미치는 영향을 규명하는 데 초점을 두었다(Musa et al., 2020; Pińskwar et al., 2023; Yang et al., 2025). 그러나 사고 심각도는 다양한 요인이 복합적으로 작용한 결과로 나타나기 때문에(Eboli et al., 2020; Park et al., 2013; Wang et al., 2020), 이를 설명하기 위해서는 개별 변수의 효과뿐 아니라 변수 간의 구조적 관계와 상호작용을 함께 고려할 수 있는 분석 체계가 필요하다. 따라서 고속도로 사고 심각도 분석을 위해서는 개별 요인의 단순 비교를 넘어 이러한 요인들 간의 구조적 관계를 동시에 고려할 수 있는 통합적 접근이 요구된다. 이러한 요구에 따라 본 연구에서는 사고 심각도에 영향을 미치는 요인들을 운전자요인, 차량요인, 도로 및 환경요인 등 요인군별로 구분하여 하위모형을 구축함으로써 요인군 간 구조적 차이를 비교하고, 동시에 변수 간 관계와 상호작용을 탐색할 수 있는 분석 체계를 적용하였다. 구체적으로, 순서형 로지스틱 회귀모형(Ordinal logistic regression)을 활용하여 사고 심각도의 순위 구조(사망>부상>물적 피해)를 반영한 영향 요인의 방향성과 통계적 유의성을 검토하였다(Lee et al., 2020).

또한 변수 간 상호작용과 비선형적 패턴을 반영할 수 있는 랜덤 포레스트(Random forest)를 활용하여 통계 모형을 보완하였다. 기존의 랜덤 포레스트 기반 고속도로 사고 심각도 분석 연구들이 변수 중요도 도출에 중점을 두고 단일 예측모형을 적용한 데 비해, 본 연구는 순서형 로지스틱 회귀와 랜덤 포레스트를 결합한 보완적 분석 체계를 제시한 점에서 차별성을 가진다. 순서형 로지스틱 회귀모형은 사고 심각도의 서열 구조를 반영한 요인별 구조적 영향 해석을 가능하게 하며, 랜덤 포레스트는 모형의 통계 모형이 포착하기 어려운 패턴을 보완하며 일반화 성능을 평가할 수 있도록 한다. 이와같이 두 기법은 각각 해석 중심의 구조적 분석과 예측 중심의 탐색적 분석을 담당하며, 상호 보완적인 역할을 수행한다.

이러한 방향을 토대로, 본 연구는 2010~2019년 전국 고속도로에서 발생한 대규모 사고자료를 활용하여 운전자, 차량, 도로, 환경 요인을 포괄하는 사고 심각도 모형을 구축하였다. 본 연구는 기존 연구들이 주로 단일 분석기법 또는 특정 요인군에 초점을 맞추었던 것과 달리, 통계적 모형과 기계학습 기반 모형을 병행하여 사고 심각도에 대한 구조적 영향과 예측 성능을 함께 검토하는 데 목적이 있다. 이를 통해 각 요인이 사고 심각도에 미치는 영향이 통계적으로 유의한지 확인하고, 두 접근법의 예측력과 설명력을 비교함으로

써 분석 관점의 상보성을 평가하고자 한다. 또한 각 요인군별 하위모형을 구축하여 전체모형과 비교함으로써 요인군 간 구조적 차이가 존재하는지도 실증적으로 검토하였다. 이러한 연구 설계는 고속도로 사고 심각도의 결정요인을 다층적으로 분석할 수 있는 기반을 제공하며, 구조적 해석과 예측 기반 분석을 통합적으로 활용할 수 있는 실증적 분석 체계를 제시한다는 점에서 기존 연구와 차별성을 갖는다.

본 논문의 구성은 다음과 같다. 2장에서는 연구에 활용된 자료와 변수 구성을 설명한다. 3장에서는 사고 심각도 예측을 위한 분석 방법론을 제시하고 순서형 로지스틱 회귀모형과 랜덤 포레스트 모형의 구축 절차를 기술한다. 다음으로, 4장에서는 두 모형을 적용한 분석 결과를 제시하고, 예측 성능을 비교한다. 마지막으로, 5장에서는 주요 분석 결과를 요약하고, 고속도로 교통사고 심각도 저감을 위한 정책적 시사점과 향후 연구 방향을 제시한다.

Ⅱ. 연구 범위 및 분석자료 설명

2.1. 연구 범위

본 연구는 고속도로 교통사고의 심각도에 영향을 미치는 주요 요인을 규명하고, 사고 결과를 예측하기 위한 통계 및 기계학습 기반의 모형을 구축하였다. 연구의 공간적 범위는 국내 고속도로 구간 중 본선부, 진출입부, 갓길부, 터널부 및 기타 부속 구간을 포함하여, 사고의 원인과 발생 위치 유형에 따라 분석 대상을 구분하였다. 시간적 범위는 2010~2019년 사고 데이터를 분석 범위로 설정하였으며, 이를 통해, 연도별 통계 편차를 완화하고 장기적인 추세를 반영하고자 하였다.

2.2. 분석자료 설명

연구에 활용된 데이터는 경찰청의 고속도로 교통사고 기록에 대한 원시자료를 기반으로 하였다. 총 10개 연도 데이터를 병합하는 과정에서 연도별 데이터의 항목 구성과 변수명이 상이한 문제를 해소하기 위해 변수명을 통일하고, 기록 누락, 결측치, 비정상 값 등을 제거한 후 범주형 변수의 코드 불일치를 점검하여 데이터의 일관성을 확보하였다. 결측치는 사고 위치, 사고원인, 사고유형 등 핵심 변수에서 정보가 완전히 누락된 사례를 우선적으로 제외하였으며, 이상치는 물리적으로 불가능한 값을 기준으로 제거하였다. 또한 범주형 변수의 경우 연도별 코드 체계가 상이한 항목에 대해 동일 기준으로 재분류하여 범주의 일관성을 확보하였다. 데이터 표준화 과정을 통해 최종적으로 구축된 데이터셋은 총 61,272건의 사고 사례로 구성되며, 이 데이터는 고속도로 교통사고의 심각도 수준을 체계적으로 분석하기 위한 기반 자료로 활용되었다. 또한, 분석에 앞서 구축된 데이터의 전체적인 공간 특성을 파악하기 위해 노선명별 사고 분포를 분석하였으며, 주요 노선의 사고 발생 현황은 Table 1과 같다.

본 연구의 종속변수(Dependent variable)는 사고 심각도(Severity level)로 정의되며, 사고 데이터의 희소성을 고려하여 사망자 수, 부상자 수, 물적 피해 발생 여부를 종합해 세 단계의 순서형 범주로 구분하였다(Jeong, 2018a; Jeong et al., 2018b). 구체적으로, 사망사고는 사망자가 1인 이상 발생한 사고를 의미하고, 부상사고는 사망자는 없으나 부상자가 발생한 경우, 물적 피해사고는 인명피해 없이 물적 피해만 발생한 경우로 정의하였다. 이러한 구분을 통해 사고 결과의 심각도를 체계적으로 구분하고, 각 사고 유형별 요인 간 영향력을 비교 분석할 수 있도록 하였다.

다음으로, 사고 심각도에 영향을 미치는 주요 독립변수(Independent variables)는 크게 사고원인을 비

롯하여 운전자 및 차량 특성, 도로 및 환경 특성에 대한 요인으로 구분된다. 이 중 사고원인 변수는 사고의 직접적 발생 메커니즘을 설명하는 핵심 변수로 주된 원인에 따라 운전자요인, 차량요인, 도로요인, 기타로 세분하였다. 여기서 기타는 경찰청 사고 데이터의 기존 분류체계를 그대로 적용한 잔여 범주로, 상위 세 요인에 명확히 속하지 않는 사고원인을 포함한다. 운전자 및 차량 특성과 관련된 변수에는 운전자 연령, 성별, 차종 등이 포함되며, 이는 개인적 특성과 차량 유형의 차이가 사고 심각도에 미치는 영향을 반영한다. 또한, 도로 특성과 관련된 변수에는 조명시설, 평면선형, 종단구배, 작업장 구분, 발생지점 등이 포함되며, 이는 주행 환경과 도로 구조적 조건이 사고 결과의 심각도에 미치는 영향을 평가하기 위해 고려되었다. 요일, 주·야간, 날씨, 노면상태 등의 변수는 일반적인 주행 환경 및 외부 조건을 통제하기 위한 제어 요인으로 포함되었다.

Table 1. Accident statistics for the top 20 freeway routes

Routes	Number (Count)	Percentage (%)	Routes	Number (Count)	Percentage (%)
Gyeongbu	10,099	16.48	Namhae Expressway Branch No.2	841	1.37
Seohaean (West Coast)	5,707	9.31	Suncheon-Wanju	812	1.33
Yeongdong	4,958	8.09	Namhae (Yeongam-Suncheon	792	1.29
Jungbu /Tongyeong-Daejeon	4,886	8.00	Pyeongtaek-Jecheon	774	1.26
Jungbu Naeryuk (Central Inland)	4,473	7.30	Donghae (East Coast)	656	1.07
Jungang	4,389	7.16	88 Olympic	651	1.06
Namhae(Suncheon-Busan)	3,816	6.23	Gwangju-Daegu	610	1.00
Nonsan-Cheonan/ Honam	2,593	4.23	Dangjin-Daejeon	600	0.98
Seoul Outer Ring	1,995	3.26	Second Gyeongin	598	0.98
Nonsan-Cheonan/ Honam	1,440	2.35	Seoul-Yangyang	495	0.81

Table 2는 고속도로 교통사고 사례를 분석한 결과를 보여준다. 분석 결과, 사고의 약 81%가 운전자요인에 의해 발생하였으며, 차량요인(10.6%), 도로요인(4.9%), 기타(3.6%) 순으로 나타났다. 이는 고속도로 사고의 대부분이 운전자의 부주의, 과속, 주시태만 등과 같은 인적 요인에 기인함을 보여준다. 운전자 특성 측면에서 살펴보면, 남성 운전자가 전체의 85.9%를 차지하였고, 40~50대 중장년층이 주요 연령대로 나타났다. 이는 고속도로 운전의 특성상 비율이 높은 인구집단이 사고에 상대적으로 더 많이 노출되어 있음을 의미한다. 한편, 차량 특성별로는 승용차와 화물차의 비중이 높게 나타났으며, 이는 고속도로 교통량 구성에서 두 차종이 지배적인 점유율을 차지하고 있음을 보여준다. 다음으로, 일반적인 사고는 주로 주중, 주간의 직선구간과 건조한 노면에서 발생하는 경향을 보였는데, 이는 해당 조건에서 교통량과 주행 빈도가 상대적으로 높아, 단위시간 당 노출 기회가 많기 때문으로 해석된다.

Table 2. Descriptive statistics of variables

Category	Variable	Description	Number (Count)	Percentage (%)
Dependent variable	Accident severity	Fatal	1,913	3.12
		Injury	6,341	10.35
		Property damage only	53,018	86.53
Independent variables	Accident cause	Driver	49,564	80.89
		Vehicle	6,502	10.61
		Road	3,030	4.95
		Other	2,176	3.55
	Driver age	Under 20	5,762	9.40
		20~29	10,981	17.92
		30~39	12,161	19.85
		40~49	14,365	23.44
		50~59	12,793	20.88
		60 and above	5,210	8.50
	Driver gender	Male	52,614	85.87
		Female	8,294	13.54
		Unknown	364	0.59
	Vehicle type	Passenger car	38,009	62.03
		Truck	15,902	25.95
		Van/Bus	3,454	5.64
		Special vehicle	3,723	6.08
		Other vehicles	184	0.30
	Lighting facility	Daytime	30,974	50.55
		Lighting installed	18,407	30.04
		No lighting	11,891	19.41
	Road alignment	Straight section	43,022	70.21
		Curved section	18,250	29.79
	Longitudinal slope	Flat gradient	35,310	57.63
		Steep gradient	25,962	42.37
	Work zone classification	Construction	756	1.23
		Non-construction	60,405	98.58
		Other section	111	0.18
	Accident location	Mainline	41,972	68.50
		Ramp	10,476	17.10
		Shoulder	957	1.56
		Tunnel	2,183	3.56
		Other locations	5,684	9.28
	Weather	Clear	35,412	57.79
		Cloudy	8,838	14.42
		Rainy	14,267	23.28
		Snowy	2,460	4.01
		Foggy	248	0.40
		Other weather	47	0.08

	Road surface	Dry	42,759	69.79
		Wet	18,061	29.48
		Snow-covered	352	0.57
		Other conditions	100	0.16
	Day of week	Weekday	43,024	70.22
		Weekend	18,248	29.78
	Day/Night	Daytime	38,989	63.63
		Nighttime	22,283	36.37

Ⅲ. 연구 방법론

3.1. 분석 절차 및 개요

본 연구는 고속도로 교통사고의 심각도 예측모형을 구축하기 위해 통계적 접근과 기계학습적 접근을 병행하는 단계적 분석 절차를 설계하였다. 먼저, 심각도가 범주형이면서 순서형 특성을 동시에 지닌다는 점을 고려하여 통계적 모형으로 순서형 로지스틱 회귀모형을 선정하였다(Asare&Mensah, 2020; Bekelcho et al., 2023). 이 모형은 변수 간의 영향 방향과 유의성을 해석할 수 있어 요인별 사고 심각도 결정 메커니즘을 파악하는 데 유용하다(Jeong et al., 2018a). 그러나, 순서형 로지스틱 모형은 선형성 가정과 변수 간 비선형 관계를 충분히 반영하기 어렵다는 한계가 있다. 이에 본 연구에서는 이를 보완하기 위해 기계학습 기반의 랜덤 포레스트 기법을 병행 적용하였다. 이는 다수의 결정트리를 조합하여 예측의 안정성과 정확도를 향상시키는 앙상블 학습(Ensemble learning) 방식으로, 변수 중요도 도출을 통해 심각도 결정요인을 추가적으로 검증할 수 있다(Salman&Kalakech, 2024).

3.2. 순서형 로지스틱 회귀모형 기반 영향 요인 도출

선형 회귀분석은 종속변수가 연속형(Continuous variable)일 때, 독립변수와의 선형적 관계를 가정하여 하나의 종속변수와 여러 독립변수 간의 상관관계를 분석하는 방법이다(Cox&Pilcher, 1970). 그러나 교통사고 심각도와 같이 이산적(Discrete) 범주로 표현되는 결과 변수에 대해서는 이러한 선형 가정이 적합하지 않다(Ko et al., 2021). 즉, 사고 결과가 사망, 부상, 물적 피해와 같이 서열을 가진 범주형 변수로 구분되는 경우, 선형 회귀는 종속변수의 속성과 맞지 않아 예측값이 실제 범주의 범위를 벗어나거나 해석이 어려운 결과를 산출할 수 있다.

이에 따라, 로지스틱 회귀분석은 이진 또는 이산형 종속변수(Binary/Discrete dependent variable)를 다루기 위한 대안으로 제시되었다. 로지스틱 회귀는 선형 관계 대신 로짓(Logit) 함수를 통해 독립변수의 변화를 확률로 변환함으로써 사건 발생 확률을 0과 1 사이의 값으로 모델링할 수 있다(Cox&Pilcher, 1970). 그러나, 교통사고 심각도처럼 명확한 순서가 존재하는 범주형 종속변수(Ordinal categorical variable)의 경우, 단순 이항 로지스틱 회귀모형으로는 범주 간 서열 정보를 충분히 반영하기 어렵다.

이를 해결하기 위해 본 연구에서는 변수 간 서열 정보를 고려하는 순서형 로지스틱 회귀모형을 적용하였다. 이는 모형은 각 관측치가 특정 수준 이하의 범주에 속할 누적확률(Cumulative probability)에 대한 로짓 변환을 통해, 사고 심각도 수준의 변화를 설명하는 독립변수들의 영향을 추정한다(Fullerton, 2009).

일반적인 순서형 로지스틱 회귀모형은 아래 식 (1)과 같이 표현된다.

$$logit[P(Y \le j)] = \ln(\frac{P(Y \le j)}{1-P(Y \le j)}) = \alpha_j - \beta_1 X_1 - \beta_2 X_2 - ... - \beta_k X_k \ (j = 1,2,...,J-1)$$

(1)

여기서, Y는 사고 심각도 수준(사망, 부상, 물적 피해)을 나타내는 종속변수이며, J는 범주의 개수를 의미한다. 또한, α_j는 범주는 각 심각도 수준 j에 대한 절편(Intercept), β_k는 독립변수 X_k에 대한 회귀계수이다. 해당 모형은 각 범주 간 경계에 대해 동일한 회귀계수를 적용한다는 비례오즈(Proportional odds) 가정을 전제로 한다.

본 연구에서는 위 모형을 활용하여 사망, 부상, 물적 피해 세 수준으로 구분된 사고 심각도를 종속변수로 설정하고, 이를 설명하기 위한 독립변수는 사고원인, 운전자 연령 및 성별, 차종, 날씨, 조명시설, 도로기하구조 등 사고 심각도에 영향을 미칠 수 있는 요인들로 구성하였다. 분석에 앞서, 모형의 안정성과 해석의 타당성을 확보하기 위하여 독립변수 간의 상관관계와 중복성을 검토하였으며, 이를 통해 다중공선성 문제가 발생하지 않도록 변수 구성을 조정하였다. 이후, 모형 추정은 최대우도법(Maximum Likelihood Estimation, MLE)을 통해 수행되었으며, R 통계 소프트웨어의 polr() 함수를 이용하였다.

3.3. 랜덤 포레스트 기반 사고 심각도 예측

결정트리 모형은 연속형 및 범주형 변수를 포함한 복합 자료에서 변수 간의 관계를 규명하고, 예측과 분류를 수행하는 대표적인 비모수적 기법이다(Mienye & Jere, 2024). 트리는 독립변수의 특정 기준값에 따라 데이터를 반복적으로 분할하며, 각 노드마다 가장 불순도를 크게 감소시키는 변수를 선택하여 분류 규칙을 생성한다. 이러한 구조는 변수 간 상호작용과 비선형 관계를 자연스럽게 반영할 수 있는 장점이 있으나, 단일 트리의 경우 훈련 데이터에 과적합되는 경향이 크고, 예측 결과의 안정성이 낮다는 한계를 가진다(Blockeel et al., 2023; Halabaku & Bytyçi, 2024).

이러한 문제점을 보완하기 위해 제안된 기법이 랜덤 포레스트이다. 이는 다수의 결정트리를 조합하여 예측의 안정성과 정확도를 향상시키는 앙상블 학습 기반의 모형으로, 개별 트리가 서로 다른 데이터와 변수 조합을 학습함으로써 예측의 편향을 줄이고 분산을 완화시킨다(Salman & Kalakech, 2024). 이와 같은 방식은 단일 트리에 비해 과적합 위험을 현저히 낮추고, 변수 간 비선형 관계를 효과적으로 포착할 수 있게 한다(Talekar & Agrawal, 2020). 또한, 학습 과정에서 변수별 중요도를 산출할 수 있어, 각 요인이 종속변수의 예측에 기여하는 정도를 정량적으로 평가할 수 있다.

이에 본 연구에서는 순서형 로지스틱 회귀모형이 갖는 선형 가정의 한계를 보완하고, 예측 정확도를 향상시키기 위해 랜덤 포레스트 기반 예측모형을 구축하였으며, 종속변수와 독립변수는 기존과 동일하게 설정하였다. 자료는 학습용(Training set)과 검증용(Test set)으로 분할하였으며, 내부 검증에는 OOB (Out-of-Bag) 오차 추정 방식을 활용하였다. 주요 하이퍼파라미터는 트리의 개수와 최대 트리 깊이로 설정하였으며, 교차검증(Cross validation)을 통해 최적 조합을 탐색하고 변수 중요도를 도출하여 사고 심각도 예측에 작용하는 주요 요인을 도출하였다. 모형의 구현에는 R 통계 소프트웨어의 randomForest() 함수를 이용하였다.

3.4. 랜덤 포레스트 기반 사고 심각도 예측

모형의 예측 성능평가는 혼동 행렬(Confusion matrix)을 기반으로 수행하였다. 혼동 행렬은 분류모형의 성능을 평가하기 위한 대표적인 방법으로, 실제값과 예측값의 일치 여부를 교차표 형태로 나타낸 것이다(Townsend, 1971). 즉, 예측 결과를 정분류(True prediction)와 오분류(False prediction)로 구분하여 각 범주의 분류 정확도를 직관적으로 파악할 수 있도록 한다. 이를 위해 분석자료는 학습용(Training set)과 검증용(Test set)으로 분할하였으며, 검증 단계에서 각 모형의 예측 결과를 기반으로 정확도(Accuracy)를 산출하였다. 정확도는 전체 예측 중 실제값과 일치한 비율을 의미하며, 다음 식 (2)와 같이 계산된다.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

여기서, TP는 True Positive, TN은 True Negative, FP는 False Positive, FN은 False Negative를 각각 의미한다.

본 연구는 이 지표를 활용하여 순서형 로지스틱 회귀모형과 랜덤 포레스트 모형의 예측 성능을 비교하였다. 두 모형의 비교를 통해 통계모형이 가지는 해석적 장점과 기계학습 모형의 비선형 기반 예측력을 상호보완적으로 확인하였으며, 이를 바탕으로 고속도로 교통사고 심각도 예측에 필요한 요인 구조를 다각적으로 분석할 수 있는 분석 프레임워크를 제시하였다.

Ⅳ. 분석 결과

4.1. 순서형 로지스틱 회귀모형 기반 분석 결과

본 절에서는 교통사고 심각도에 영향을 미치는 주요 영향요인에 대한 순서형 로지스틱 회귀분석을 수행하였다. 분석에 앞서, 독립변수 간 중복성을 줄이기 위해 상관계수(> 0.7)를 기준으로 다중공선성 가능성을 검토하였으며, 그 결과 조명시설 변수와 상관성이 높은 주·야간 변수와 날씨 변수와 상관성이 높은 노면상태 변수는 분석에서 제외되었다. 또한, 각 독립변수가 사고 심각도 수준 전반에 걸쳐 동일한 영향을 미친다고 가정하기 위해 모델 구축 전, 비례오즈(Proportional odds) 가정을 적용하였으며, Brant 검정을 통해 해당 가정의 충족 여부를 확인하였다(Brant, 1990). 이후, 적합된 순서형 로지스틱 회귀모형의 추정 결과는 Table 3에 제시하였다. 먼저, 모형의 적합도 검정 결과, 전체 모형은 통계적으로 유의하였으며(X^2=5108.6, p<0.001), McFadden's pseudo R^2=0.089로 나타나, 모형의 설명력은 양호한 수준으로 확인되었다(McFadden, 1980).

이러한 모형 결과를 바탕으로 살펴본 변수의 영향은 다음과 같다. 사고원인별로는 도로요인(β=2.214, p<0.01)과 차량요인(β=1.428, p<0.01)이 기준범주인 운전자요인보다 높은 사고 심각도를 보였다. 이는 도로 구조적 결함이나 차량 이상이 개입될 경우, 단순 접촉사고보다 중상 또는 사망으로 이어질 가능성이 크다는 점을 시사한다. 다음으로, 운전자 특성에서는 20대(β=0.206, p<0.01)와 30대(β=0.168, p<0.01) 운전자의 사고에서 상대적으로 높은 심각도가 나타났다. 이는 상대적으로 운전 경력이 짧은 젊은 운전층의 과속이나 주의분산 등의 운전행태가 반영된 결과로 해석된다. 차량 유형별로는, 화물차(β=0.587, p<0.01), 특수차(β=0.560, p<0.01), 승합차(β=0.766, p<0.01) 모두 승용차보다 높은 사고 심각도를 보였다. 이는 상

대적으로 대형차량의 경우 충돌 시 피해 규모가 확대되기 쉬워, 동일한 조건에서도 상대적으로 중상 또는 사망사고로 이어질 가능성이 높기 때문으로 사료된다. 도로 구조 및 환경 측면에서는 커브구간(β=0.071, p<0.05)에서 직선구간에 비해 사고 심각도가 높게 나타났고, 반대로 종단경사 구간(β=-0.113, p<0.01)은 낮은 심각도를 보였다. 이는 곡선부의 시야 제한과 조향 제어력 저하가 위험을 높이는 반면, 경사로 구간에서는 운전자의 감속운전 행동이 작용한 결과로 해석된다. 또한, 진출입부(β=1.397, p<0.01)와 갓길부(β=0.433, p<0.01), 터널 구간(β=0.127, p<0.05) 등은 본선 구간에 비해 높은 사고 심각도를 보였다. 특히, 진출입부는 차로 병합과 감속, 정차 등 다양한 운전행동이 집중되는 구간으로 사고 시 더 높은 심각도를 보였다. 반면, 공사 등 작업 구간의 경우, 제한속도, 경고표지, 안전요원 배치 등의 관리적 개입으로 인해 상대적으로 사고 심각도가 낮게 나타났다(β=-0.732, p<0.01). 마지막으로, 날씨 관련 요인인 눈(β=0.833, p<0.01), 비(β=0.453, p<0.01) 등의 악천후는 인명피해 가능성을 높이는 것으로 확인되었다.

앞선 전체 모형 분석 결과, 사고원인이 교통사고 심각도에 가장 유의한 영향을 미치는 주요 요인으로 확인되었다. 이에 따라, 사고원인별로 특성을 구체적으로 규명하기 위해 사고원인을 중심으로 운전자요인, 차량요인, 도로요인으로 구분하여 추가적인 분석을 수행하고 각 모형의 추정계수와 유의성을 비교함으로써, 사고유형별 심각도 발생에 대한 영향 요인 간 차이를 분석하였다. 본 연구에서는 먼저 모든 변수를 포함한 기준 모형(이하 '통합모형')의 추정 결과를 바탕으로, 각 요인군(Factor group)에 속하는 변수들과 모형의 안정적 추정을 위한 제어변수(Control variables)를 선별하였다. 이후 이 변수를 활용하여 운전자요인, 차량요인, 도로요인별 하위 모형을 각각 구축하였다(Table 4-6 참고). 사고원인을 중심으로 하위 요인별 순서형 로지스틱 회귀분석을 수행한 결과, 세 하위모형 모두 통계적으로 유의하게 나타났으며 McFadden's pseudo R^2는 0.05~0.09 수준으로 비교적 양호한 설명력을 보였다.

사고원인별 하위모형에서는 모형 간 차이가 나타났으며, 이는 각 요인군이 사고 심각도에 미치는 영향의 강도와 차이가 다르기 때문으로 해석된다. 분석 결과를 구체적으로 살펴보면, 연령과 성별이 사고 심각도에 유의한 영향을 미쳤다. 특히, 20대(β=0.192, p<0.01)와 30대(β=0.168, p<0.01) 운전자의 사고에서 높은 심각도가 나타났으며, 여성 운전자(β=0.119, p<0.01)가 남성보다 다소 높은 심각도를 보였다. 기상 요인에서도 눈(β=0.852, p< 0.01)과 비(β=0.453, p< 0.01)가 사고 심각도를 높이는 방향으로 작용했다. 다음으로, 차량요인 모형에서는 승합차(β=-0.795, p<0.01)에서만 유의한 영향이 확인되었으며, 전체적으로 유의한 수준의 모형 적합도를 보였으나, 다른 모형에 비해 상대적으로 낮은 설명력을 보였다. 마지막으로 도로요인 모형에서는 공간적 요인과 관리적 개입 수준에 따라 사고 심각도의 차이가 뚜렷하게 나타났다. 특히 진출입부(β=1.395, p<0.01), 갓길부(β=1.730, p<0.01) 등 차량 흐름이 교차하고 변화하는 구간에서 사고 심각도가 높았다. 이는 복합적인 운전행동이 집중되는 공간적 특성 때문으로 해석된다. 따라서 이러한 구간은 2차 사고 발생 위험이 높은 취약지점으로 분류될 수 있다.

Table 3. Results of the ordered logistic regression model

Variable	Description	Coefficient	Std. Error	p-value
Accident cause	Vehicle	1.428**	0.054	0.000
	Road	2.214**	0.113	0.000
	Other	0.325**	0.067	0.000
	Driver	Criteria		
Driver age	Under 20	0.085	0.059	0.148
	20~29	0.206**	0.052	0.000
	30~39	0.168**	0.050	0.001
	40~49	0.072	0.048	0.136
	50~59	0.002	0.049	0.972
	60 and above	Criteria		
Driver gender	Female	0.067	0.039	0.086
	Unknown	-0.089	0.158	0.576
	Male	Criteria		
Vehicle type	Truck	0.587**	0.030	0.000
	Van/Bus	0.766**	0.049	0.000
	Special vehicle	0.560**	0.055	0.000
	Other vehicles	0.821**	0.203	0.000
	Passenger car	Criteria		
Lighting facility	Lighting installed	0.008	0.039	0.846
	No lighting	0.061	0.038	0.107
	Daytime	Criteria		
Road alignment	Curved section	0.071*	0.031	0.020
	Straight section	Criteria		
Longitudinal slope	Steep gradient	-0.113**	0.028	0.000
	Flat gradient	Criteria		
Work zone classification	Non-construction	-0.732**	0.081	0.000
	Other section	-1.255**	0.198	0.000
	Construction	Criteria		
Accident location	Ramp	1.397**	0.049	0.000
	Shoulder	0.433**	0.100	0.000
	Tunnel	0.127*	0.062	0.040
	Other locations	2.192**	0.080	0.000
	Mainline	Criteria		
Day of week	Weekend	0.053	0.028	0.053
	Weekday	Criteria		
Weather	Cloudy	0.013	0.036	0.724
	Rainy	0.453**	0.075	0.000
	Snowy	0.833**	0.105	0.000
	Foggy	0.295	0.168	0.078
	Other weather	0.289	0.486	0.553
	Clear	Criteria		

Notes: Figures are significant at *** 99.9%, ** 99%, * 95%

Table 4. Results of the ordered logistic regression model: driver-related factors

Variable	Description	Coefficient	Std. Error	p-value
Driver age	Under 20	0.027	0.063	0.671
	20~29	0.192**	0.054	0.000
	30~39	0.168**	0.053	0.002
	40~49	0.076	0.051	0.140
	50~59	0.000	0.052	0.996
	60 and above	Criteria		
Driver gender	Female	0.119**	0.041	0.004
	Unknown	-0.133	0.168	0.429
	Male	Criteria		
Day of week	Weekend	0.065*	0.029	0.026
	Weekday	Criteria		
Weather	Cloudy	0.023	0.039	0.558
	Rainy	0.453**	0.078	0.000
	Snowy	0.852**	0.109	0.000
	Foggy	0.262	0.178	0.142
	Other weather	0.404	0.240	0.160
	Clear	Criteria		

Notes: Figures are significant at *** 99.9%, ** 99%, * 95%

Table 5. Results of the ordered logistic regression model: vehicle-related factors

Variable	Description	Coefficient	Std. Error	p-value
Vehicle type	Truck	0.249	0.132	0.060
	Van/Bus	0.795**	0.169	0.000
	Special vehicle	0.050	0.227	0.824
	Other vehicles	-1.029	0.774	0.183
	Passenger car	Criteria		
Day of week	Weekend	-0.056	0.117	0.633
	Weekday	Criteria		
Weather	Cloudy	0.087	0.140	0.534
	Rainy	0.207	0.465	0.656
	Snowy	0.327	0.685	0.632
	Foggy	0.117	0.845	0.911
	Other weather	1.600**	0.911	0.000
	Clear	Criteria		

Notes: Figures are significant at *** 99.9%, ** 99%, * 95%

Table 6. Results of the ordered logistic regression model: roadway-related factors

Variable	Description	Coefficient	Std. Error	p-value
Lighting facility	Lighting installed	0.304	0.396	0.443
	No lighting	0.031	0.356	0.930
	Daytime	Criteria		
Road alignment	Curved section	0.102	0.269	0.706
	Straight section	Criteria		
Longitudinal slope	Steep gradient	-0.115	0.245	0.638
	Flat gradient	Criteria		
Work zone classification	Non-construction	-1.393**	0.080	0.000
	Other section	-1.939	1.122	0.084
	Construction	Criteria		
Accident location	Ramp	1.395**	0.121	0.000
	Shoulder	1.730**	0.180	0.000
	Tunnel	0.561	0.578	0.332
	Other locations	1.912**	0.198	0.000
	Mainline	Criteria		
Day of week	Weekend	0.094	0.268	0.726
	Weekday	Criteria		
Weather	Cloudy	0.161	0.297	0.588
	Rainy	0.227	0.736	0.758
	Snowy	0.350	0.984	0.722
	Foggy	1.893*	0.845	0.025
	Other weather	2.069*	1.241	0.014
	Clear	Criteria		

Notes: Figures are significant at *** 99.9%, ** 99%, * 95%

4.2. 랜덤 포레스트 모형 기반 분석 결과

다음으로, 랜덤 포레스트 모형을 적용하여 사고 심각도에 대한 예측 기반 분석을 수행하였다. 본 모형은 통계적 유의성 검증 중심의 회귀모형과 달리, 다양한 요인들이 복합적으로 작용하는 실제 사고 상황을 보다 유연하게 반영할 수 있다는 점에서 해석적 보완의 의미를 가진다. 특히 변수 간 비선형 관계와 상호작용 효과를 동시에 고려함으로써, 단순한 선형 추정이 어려운 복합적 사고구조를 예측적으로 분석할 수 있다. 이를 위해 전체 데이터의 70%를 학습용, 30%를 검증용으로 분할하여 모델을 학습하였으며, 분할 과정에서는 사고 심각도(사망-부상-물적 피해)의 범주 비율이 원본 데이터와 동일하게 유지되도록 층화표본(Stratified sampling) 방식을 적용하였다. 다음으로, 모형의 안정적 수렴과 분류정확도 향상을 위해 트리 수를 1,000개로 생성하고 평균 예측오차를 최소화하도록 설정하였으며, 과적합을 방지하기 위해 트리의 최대 깊이는 10으로 제한하여 일반성을 확보하였다(Breiman, 2001).

변수중요도는 지니 불순도 감소량(Mean Decrease in Gini)을 기준으로 모델에서 해당 변수가 차지하는 중요도를 비율로 산출하였다. 이는 트리 분할 과정에서 변수의 기여도를 불순도 감소량으로 누적하여 평가하는 방식으로, 연속형과 범주형 변수가 혼재된 변수체계에 적합하며, 순서형 범주를 포함한 분류 문제에서도 안정적인 측정값을 제공한다.

통합모형에 대한 상위 10개 변수의 중요도 분석 결과, Figure 1과 같이 발생지점, 사고원인, 운전자 연령, 차종, 날씨 변수가 순서대로 사고 심각도 예측에 가장 큰 영향을 미치는 것으로 나타났다. 이는 공간적 요인과 운전자 행태가 사고 결과의 심각도를 결정짓는 핵심 요인임을 시사한다. 구체적으로, Figure 2에서 제시된 사고원인별로 세분화된 하위 모형의 상위 변수에 대한 중요도 결과를 살펴보면, 각 요인군에 따라 사고 심각도에 영향을 미치는 주요 요인이 다양하게 나타났다. 먼저, 운전자요인 모형에서는 운전자 연령과 날씨가 가장 높은 비중을 보였으며, 차량요인 모형에서는 차종, 날씨 순으로 중요도가 높게 나타나, 악천우와 같은 외부적 요인이 사고 심각도를 높이는 것을 확인할 수 있었다. 마지막으로, 도로요인 모형에서는 발생지점, 날씨, 조명시설 등이 주요 변수로 도출되었다. 이러한 결과는 사고 심각도가 사고원인별로 다양한 복합적 요인에 의해 결정되며, 향후 사고 관리 정책은 개별 요인에 대한 대응에서 나아가, 사고유형별 주요 영향요인을 통합적으로 고려한 맞춤형 전략 수립이 필요함을 시사한다.

Figure 1. Variable importance

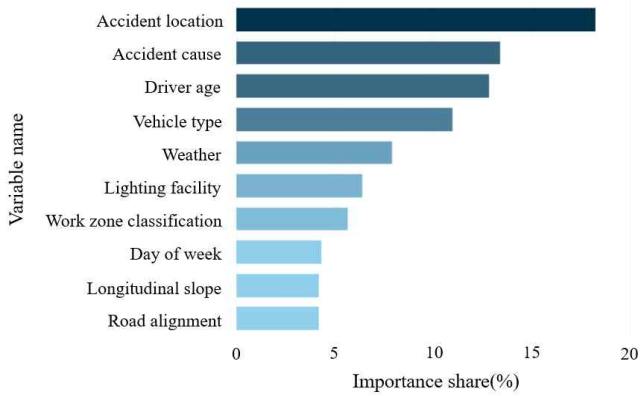
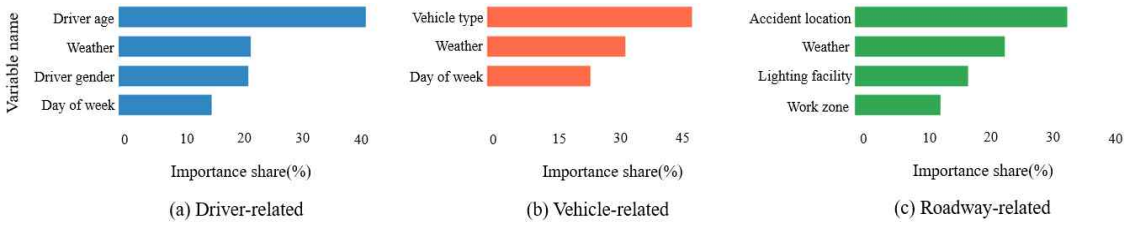


Figure 2. Variable importance by sub-model type(driver, vehicle, and roadway factors)



4.3. 혼동 행렬 기반 분석 결과

모델 간 예측 성능 비교는 실제 값과 예측값의 일치 여부를 교차표 형태로 나타내는 혼동 행렬을 기반으로 수행하였으며, 이를 통해 각 사고 심각도 수준(사망, 부상, 물적 피해)에 대한 분류 정확도와 오분류 패턴을 직관적으로 파악하였다. 모형의 예측 성능은 전체 데이터 중 검증용 데이터(18,382건)을 이용하여 평가하였다. 분석 결과, 순서형 로지스틱 회귀모형(통합모델)의 전체 분류 정확도는 약 0.65로 나타났다. 반면, 동일한 자료를 이용한 사고원인별 세분화 모형(운전자요인, 차량요인, 도로요인)에서는 모형별 정확도가 0.67~0.70 수준으로 일부 향상되었다. 이에 비해, 랜덤 포레스트 모형은 비선형 관계와 변수 간 상호작용을 반영함으로써 전체모형의 정분류 정확도가 약 0.74로 나타나, 회귀모형 대비 예측력이 뚜렷하게 개

선되었다. 또한, 사고원인별 하위 랜덤 포레스트 모형의 정확도는 0.76~0.79 범위로, 복합적인 요인 구조를 반영함으로써 모든 모형 중 가장 우수한 예측 성능을 보였다(Table 7 참고).

Table 7. Comparison of model prediction accuracy based on confusion matrices

Category	Ordinal logistic regression model	Random forest model	Accuracy Difference
Combined model	64.8% (11,915 cases)	73.9% (13,576 cases)	+9.1% (1,661 cases)
Driver-related model	70.1% (12,880 cases)	79.2% (14,552 cases)	+10.8% (1,969 cases)
Vehicle-related model	67.6% (12,418 cases)	76.8% (14,134 cases)	+9.2% (1,716 cases)
Roadway-related model	68.4% (12,583 cases)	78.5% (14,433 cases)	+8.4% (1,553 cases)

Ⅴ. 결 론

본 연구는 고속도로 교통사고의 심각도에 영향을 미치는 주요 요인을 규명하고 사고 결과를 예측하기 위한 통계적 및 기계학습 기반 예측모형을 구축하는 것을 목적으로 하였다. 이를 위해 2010년부터 2019년까지 총 10년 동안의 고속도로 교통사고 데이터를 통합 및 정제하여 총 61,272건의 사고 사례를 구축하였으며, 사고 심각도 수준을 사망, 부상, 물적 피해의 세 단계 순서형 범주로 정의하였다. 분석 방법으로는 순서형 로지스틱 회귀모형을 적용하여 요인별 영향 방향과 유의성을 검토하고, 랜덤 포레스트 기법을 병행하여 변수 간 비선형 관계와 상대적 중요도를 평가하였다.

분석 결과, 교통사고 심각도는 다양한 요인의 복합적 영향에 의해 결정되는 것으로 나타났다. 특히, 도로 구조적 요인과 대형차량의 사고는 높은 심각도를 유발하였으며, 20~30대 운전자의 사고에서도 중대사고 비율이 높게 나타났다. 또한, 눈, 비 등 악천후 조건과 복합 교통흐름 구간에서 사고 심각도가 유의하게 증가하였다. 랜덤 포레스트 모형 분석에서도 발생지점, 사고원인, 운전자 연령, 차종, 날씨가 주요 예측변수로 확인되었으며, 비선형 관계를 반영한 본 모형은 회귀모형보다 높은 예측 성능을 보였다.

본 연구는 고속도로라는 특수한 교통 환경을 대상으로 사고 심각도를 다층적으로 분석함으로써 고속도로의 구조적, 운행적 특성을 반영하여 사고 심각도의 결정요인을 실증적으로 규명하였다는 점에서 의미가 있다. 아울러, 통계적 모형과 기계학습 기반 모형을 병행 적용하여 두 접근법의 예측력과 설명력을 비교하고 검증함으로써, 고속도로 사고 심각도 예측을 위한 실증적 분석 체계를 제시하였다. 이를 통해 기존 연구에서 상대적으로 제한적으로 다루어졌던 심각도에 대한 해석과 비선형적 패턴 탐색을 통합적으로 고려할 수 있는 분석 관점을 제공한다는 점에서 의의가 있다.

이러한 연구적 성과는 이론적 의의에 그치지 않고, 실제 교통안전 정책의 수립과 실행에도 중요한 시사점을 제공한다. 첫째, 고속도로 사고 예방정책은 사고의 발생 자체보다 사고 발생 시 피해의 심각도를 완화하는 방향으로 전환될 필요가 있다. 특히, 본 연구에서 확인된 바와 같이 진출입부, 갓길부, 커브구간 등 공간적 위험요인은 높은 사고 심각도와 밀접하게 관련되어 있으므로, 해당 구간에 대한 물리적 시설 개선과 속도관리 강화가 필요하다. 둘째, 20~30대 운전자층의 사고가 높은 심각도를 보인 점은 상대적으로 운전 경력이 짧은 젊은 운전자들에 대한 운전 교육과 관리 강화의 필요성을 시사한다. 이에 따라 청년층을 대상으로 한 고속도로 특화 안전교육, 위험상황 시뮬레이션 기반 훈련, 졸음·주의분산 경고 시스템 연계 프로그램 등이 검토될 필요가 있다. 셋째, 화물차, 특수차, 승합차 등 대형차량의 사고가 인명피해로 이어질 가능성이 높게 나타난 만큼, 대형차량의 안전관리 및 주행행태 모니터링 체계 강화와 같은 구조적인 관

리 전략이 요구된다. 마지막으로, 악천후 조건에서 사고 심각도가 증가한 결과는 기상 변화가 사고의 2차 위험요인으로 작용함을 의미한다. 이에 악천후 시에는 운전자의 주의를 유도할 수 있는 기상연동형 교통안전 대응체계 도입이 효과적일 것으로 판단된다.

결론적으로, 본 연구는 고속도로 사고 심각도를 통계적 접근과 기계학습 기반 예측을 결합하여 다층적으로 분석함으로써, 기존 연구에서 간과되었던 요인 간 복합적 영향 구조를 정량적으로 규명하였다. 제시된 분석 체계는 고속도로 사고 심각도 예측뿐 아니라 고위험 구간 관리 및 맞춤형 안전정책 수립을 위한 실증적 근거로 활용될 수 있을 것으로 기대된다. 그러나, 본 연구의 종속변수인 사고 심각도는 사망, 부상, 물적피해로 구성하였으나, 부상 내부의 중상과 경상 구분이 불가능한 자료 구조의 한계로 인해 더 세분화된 분석을 수행하지 못하였다는 한계가 있다. 이러한 범주 단순화는 심각도 간 경계가 모호해지는 문제를 초래할 수 있어, 향후에는 외부 자료의 보완을 통해 보다 정교한 심각도 변수 구축이 필요하다. 또한, 본 연구에서 활용한 랜덤포레스트 모형의 변수 중요도는 Gini 계수를 기반으로 산출되기 때문에, 변수의 스케일이나 범주 수에 따라 중요도가 편향적으로 높게 평가될 가능성이 존재한다. 비록 본 연구의 변수 구성상 이러한 편향의 영향은 상대적으로 크지 않을 것으로 판단되나, 향후 연구에서는 순열 중요도(Permutation importance) 또는 SHAP 기반 해석을 병행하여 변수 기여도의 신뢰성을 강화하고, 사고 심각도 결정요인에 대한 보다 정교한 설명력을 확보할 필요가 있다. 아울러, 본 연구는 영향요인 해석을 위해 원자료 분포를 유지하여 분석을 수행하였으나, 향후 연구에서는 데이터 불균형이 예측 성능에 미치는 영향을 보다 정교하게 반영하기 위해 SMOTE나 가중치 조정 등 불균형 자료 보정 기법을 적용할 필요가 있다. 이러한 방향성을 통해 연구는 사고 심각도 분석의 정밀도를 높이는 동시에 보다 실질적인 정책 지원 체계 마련에 더욱 기여할 수 있을 것으로 사료된다.

참 고 문 헌

1. 국외문헌

Asare, I.O., & Mensah, A.C. (2020). Crash severity modelling using ordinal logistic regression approach. International Journal of Injury Control and Safety Promotion, 27(4), 412-419.

Bekelcho, T., Olani, A.B., Woldemeskel, A., Alemayehu, M., & Guta, G. (2023). Identification of determinant factors for crash severity levels occurred in Addis Ababa City, Ethiopia, from 2017 to 2020: Using ordinal logistic regression model approach. BMC Public Health, 23(1), 1884.

Blockeel, H., Devos, L., Frénay, B., Nanfack, G., & Nijssen, S. (2023). Decision trees: From efficient prediction to responsible AI. Frontiers in Artificial Intelligence, 6.

Brant, R. (1990). Assessing proportionality in the proportional odds model for ordinal logistic regression. Biometrics, 46(4), 1171-1178.

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5-32.

Christoforou, Z., Cohen, S., & Karlaftis, M. (2010). Vehicle occupant injury severity on highways: An empirical investigation. Accident Analysis & Prevention, 42, 1606-1620.

Cox J. D. & Pilcher G. (1970). Thermochemistry of Organic and Organometallic Compounds, Academic Press, Cambridge, MA, USA.

Eboli, C., Forciniti, C., & Mazzulla, G. (2020). Factors influencing accident severity: An analysis by road accident type. Transportation Research Procedia, 47, 449-456.

Fullerton, A. S. (2009). A conceptual framework for ordered logistic regression models. Sociological Methods & Research, 38(2), 306-347.

Gabauer, D.J. (2010). Secondary collisions following a traffic barrier impact: Frequency, factors, and occupant risk. Annals of Advances in Automotive Medicine, 54, 223-232.

Halabaku, E., & Bytyçi, E. (2024). Overfitting in machine learning: A comparative analysis of decision trees and random forests. Intelligent Automation & Soft Computing, 39(6), 987-1006.

Høye, A.K., & Hesjevoll, I.S. (2020). Traffic volume and crashes and how crash and road characteristics affect their relationship – A meta-analysis. Accident Analysis & Prevention, 145, Article 105668.

Huang, H., Ding, X., Yuan, C., Liu, X., & Tang, J. (2023). Jointly analyzing freeway primary and secondary crash severity using a copula-based approach. Accident Analysis & Prevention, 180, Article 106911.

Jeong, H. (2018a). Study on prediction of severities of rental car traffic accidents using ordinal logit model and naive Bayes classifier. Master's thesis, Ajou University.

Jeong, H., Jang, Y., Bowman, P.J., & Masoud, N. (2018b). Classification of motor vehicle crash injury severity: A hybrid approach for imbalanced data. Accident Analysis & Prevention, 120, 250-261.

Jeong, H., Kim, I., Han, K., & Kim, J. (2022). Comprehensive analysis of traffic accidents in Seoul: Major factors and types affecting injury severity. Applied Sciences, 12(4), 1790.

Ko, E., Kim, H., & Lee, J. (2021). Survey data analysis on intention to use shared mobility services. Journal of Advanced Transportation. 2021, Article 5585542.

Lee, H., Kum, K., & Son, S. (2011). A study on the factor analysis by grade for highway traffic accident. International journal of highway engineering, 13(3), 157-165.

Lee, H., Jeon, G., & Jang, J. (2020). Predicting of the Severity of Car Traffic Accidents on a Highway Using Light Gradient Boosting Model. The Journal of the Korea Institute of Electronic Communication Sciences, 15(6), 1123-1130.

Lee, S., Sun, K., Park, C., & Kim, T. (2021). Characteristics of traffic accidents on highways: An analysis based on patients treated at a regional trauma center. Journal of Trauma and Injury, 34(4), 263-269.

McFadden, D. (1980). Econometric models for probabilistic choice among products. Journal of Business, 53(3), S13-S29.

Mienye, I.D., & Jere, N. (2024). A survey of decision trees: Concepts, algorithms, and applications. IEEE Access, 12, 86716-86727.

Musa, M.F., Hassan, S.A., & Mashros, N. (2020). The impact of roadway conditions towards accident severity on federal roads in Malaysia. PLoS One, 15(7), e0235564.

Park, J., Yun, D., & Sung, J. (2013). Analysis on Factors Affecting Traffic Accident Severity - Case Study : Arterial Included Curve Section - . Journal of the Korean Society of Safety, 28(6), 84-89.

Pińskwar, I., Choryński, A., & Graczyk, D. (2024). Good weather for a ride (or not?): How weather conditions impact road accidents — A case study from Wielkopolska (Poland). International Journal of Biometeorology, 68(2), 317-331.

Riuttanen, A., Karjalainen, E., Jokihaara, J., Huttunen, T.T., & Mattila, V.M. (2024). Cumulative costs of severe traffic injuries in Finland: A 2-year retrospective observational study of 252 patients. Scientific Reports, 14, Article 11078.

Salman, H.A., Kalakech, A., & Steiti, A. (2024). Random forest algorithm overview. Babylonian Journal of Machine Learning, 2024, 69-79.

Talekar, B., & Agrawal, S. (2020). A detailed review on decision tree and random forest. Bioscience Biotechnology Research Communications, 13(14SI), 245-248.

Townsend, J.T. (1971). Theoretical analysis of an alphabetic confusion matrix. Perception &

Psychophysics, 9(1), 40-50.
Wang, J., Lu, H., Sun, Z., & Wang, T. (2020). Exploring factors influencing injury severity of vehicle at-fault accidents: A comparative analysis of passenger and freight vehicles. International Journal of Environmental Research and Public Health, 17, 1146.
Yang, Z., Zhang, C., Li, G., & Xu, H. (2025). Analysis of the impact of different road conditions on accident severity at highway-rail grade crossings based on explainable machine learning. Symmetry, 17, 147.

저 자 소 개

고 은 정 (Ko Eun Jeong) **주 저 자**



- KAIST 교통공학박사(2024)
- 한남대학교 교수(1년)

장 기 태 (Jang Ki Tae) **교신저자**



- University of California at Berkeley 토목환경공학박사(2011)
- KAIST 교수(12년)