creative commons
COMMONS DEED

저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 이용허락규약(Legal Code)을 이해하기 쉽게 요약한 것입니다.

Disclaimer

dCollection

머신러닝을 활용한 고속도로 교통사고 심각도 분석 및 영향요인에 관한 연구 2023 이선민

석사학위논문

머신러닝을 활용한 고속도로 교통사고 심각도 분석 및 영향요인에 관한 연구

A Study on the Analysis of Highway Traffic Accident Severity and Influencing Factors Using Machine Learning

인천대학교 대학원

도시건설공학과

이 선 민

2024년 02월

석사학위논문

머신러닝을 활용한 고속도로 교통사고 심각도 분석 및 영향요인에 관한 연구

A Study on the Analysis of Highway Traffic Accident Severity and Influencing Factors Using Machine Learning

인천대학교 대학원

도시건설공학과

이 선 민

2024년 02월

석사학위청구논문

머신러닝을 활용한 고속도로 교통사고 심각도 분석 및 영향요인에 관한 연구

A Study on the Analysis of Highway Traffic Accident Severity and Influencing Factors Using Machine Learning

지도교수 윤 병 조

이 논문을 석사학위논문으로 제출함

2023년 12월

인천대학교 대학원

도시건설공학과

이 선 민

석사학위청구논문

이 논문을 이선민의 도시건설공학
석사학위 논문으로 인준함

2023년 12월

심사위원장 박 승 진 (인)

심사위원 서 종 국 (인)

심사위원 윤 병 조 (인)

국문초록

머신러닝을 활용한 고속도로 교통사고 심각도 분석 및 영향요인에 관한 연구

국내의 전체 교통사고 발생 건수는 감소추세이며 이는 정부 및 관련 기관에서 교통사고의 심각성을 무겁게 인식하고 교통안전의 체계적인 계획과 개선대책을 수립하는 등 다각적인 노력을 추진함에 따른 긍정적인 결과로 판단된다. 그러나 우리나라 도로 교통망의 중요한 축(軸)을 이루며 주요 도시를 연결하는 고속도로의 교통사고는 사고추세의 증감을 반복하고 있고, 도로 종류 중 고속도로에서의 교통사고 치사율은 최고치를 나타내고 있다.

2021년 기준, OECD 국가별 교통사고 건수 부문에서 우리나라는 OECD 평균보다 약 2.5배 많은 사고가 발생했고 OECD 국가별 인구 10만 명당 교통사고 건수는 회원국 평균 27.0건인데 비해 우리나라의 수치는 74.2건으로 OECD 회원국 평균보다 약 2.8배 많은 교통사고가 발생하고 있어 현재까지도 높은 수치를 나타내고 있음을 알 수 있다. 따라서 국내 고속도로의 사고 감소를 위한 개선의 여지가 분명히 남아있으며 국가의 교통안전 정책을 우선으로 검토하고 국내의 실정을 반영한 다양한 개선대책 수립에 대한 고민이 필요하다.

본 연구에서는 전국 고속도로 노선 중 사고 다발 10개의 노선을 채택하여 고속도로 교통사고 심각도와 사고 심각도에 영향을 미치는 요인을 분석하였다. 이때, 빅 데이터 분석 기법인 머신러닝을 활용하여 기존의 전통적 통계 방법으로는 분석이 곤란했던 영역을 분석하여 분석의 정밀도를 높일 수 있도록 하였다.

또한, 교통사고 자료뿐 아니라 고속도로의 주요 분석단위인 콘 존과 도로의 기하구조 요소를 결합한 자료를 활용하였으며, 머신러닝의 PyCaret 라이브러리로 사고 심각도 모형분석에 가장 최적한 모델을 선정해 고속도로 교통사고 심각도

를 분석하고 이에 미치는 영향요인을 규명하고자 하였다.

그리하여 2019년부터 2021년까지 전국 10개 노선에서 발생한 고속도로 교통사고를 분석한 결과 RandomForestRegressor 기법의 성능이 가장 좋았다. 따라서, 해당 기법을 채택하여 고속도로 교통사고 심각도 분석 및 사고 심각도에 미치는 영향요인을 도출하였다.

SHAP 패키지를 활용해 상위 10개의 변수 중요도를 분석한 결과, 고속도로에서 발생한 교통사고 중 사고 심각도에 높은 영향을 미치는 변수는 가해자의 연령대가 20세 이상 39세 미만, 시간대가 주간(06:00-18:00)일 경우, 주말(토~일)의 경우, 계절이 여름과 겨울인 경우, 기상 상태가 흐림일 경우, 가해 운전자 차종이 승합차일 경우, 법규위반이 안전운전 불이행일 경우, 도로 형태가 터널일 경우, 기하구조상 차로 수가 많고 제한속도가 높은 경우로 총 10개의 독립변수에서 고속도로 교통사고 심각도와 양(+)의 상관관계를 가지는 것으로 나타났다.

본 연구는 전통적인 통계기법이 아닌 머신러닝을 기법을 이용하여 고속도로 교통사고 심각도 모형을 분석하였다는 점에 의의가 있다. 또한, 고속도로에서의 교통사고는 매우 다양한 요인들의 복합적인 작용으로 인해 발생하기 때문에 사고를 정확히 예측하는 데에는 많은 어려움이 따른다. 하지만 분석된 결과를 토대로 본 연구에서 채택한 고속도로 사고 다발 10개의 노선이 아닌 전국의 고속도로 노선의 사고 심각도 분석으로 연구의 범위를 넓혀 고속도로 사고 심각도에 영향을 미치는 요인을 분석하고 개선방안을 제시한다면 향후 고속도로 교통사고 감소를 위한 기초적인 자료로써 활용이 가능할 것으로 기대한다.

주제어 : 고속도로, 고속도로 교통사고, 사고 심각도, 머신러닝, 변수 중요도

목 차

국문초록 ····· i

목 차 ····· iii

표 목 차 ····· vi

그림목차 ····· viii

제 1 장 서 론 ····· 1

1.1 연구배경 및 목적 ····· 1

1.2 연구범위 및 절차 ····· 3

1.2.1 연구의 범위 ····· 3

1.2.2 연구의 절차 ····· 4

제 2 장 이론 및 선행연구 고찰 ····· 6

2.1 전통적 통계분석방법 이론적 고찰 ····· 6

2.1.1 안전성능함수(Safety Performance Function) ····· 6

2.1.2 포아송 회귀모형(Poisson Regression Model) ····· 7

2.1.3 음이항 회귀모형(Negative binomial Regression Model) ····· 9

2.2 머신러닝 이론적 고찰 ····· 11

2.2.1 머신러닝의 정의 ····· 11

2.2.2 랜덤 포레스트(Random Forest) ····· 12

2.2.3 변수 중요도(Feature Importance) ····· 14

2.3 선행연구 고찰 ····· 20

2.3.1 전통적인 통계기법을 활용한 사고 심각도 연구 ····· 20

2.3.2 머신러닝을 활용한 연구 ····· 27
2.4 본 연구의 차별성 ····· 33

제 3 장 자료수집 및 기술통계분석 ····· 35
3.1 분석 개요 ····· 35
3.2 분석자료 수집 ····· 38
3.2.1 전국 고속도로 교통사고 중 사고 다발 10위 노선 지정 ····· 38
3.2.2 공간 연산을 통한 데이터 가공 ····· 41
3.2.3 콘 존(Conzone) 데이터 가공 ····· 44
3.3 전국 고속도로 현황 및 기술통계분석 ····· 46
3.3.1 고속도로 연도별 연평균일교통량 ····· 47
3.3.2 전국 고속도로 교통사고 현황 ····· 49
3.3.3 고속도로 교통사고 일반현황 ····· 55
3.4 변수 선정 ····· 64
3.4.1 종속변수 선정 ····· 64
3.4.2 독립변수 선정 ····· 64
3.4.3 변수 전처리 ····· 66
3.5 기술통계분석 ····· 70
3.5.1 인적요인 기술통계분석 ····· 70
3.5.2 시간・환경요인 기술통계분석 ····· 72
3.5.3 사고요인별 기술통계분석 ····· 75
3.5.4 기하구조 요인별 기술통계분석 ····· 78
3.6 가설 설정 및 검증 ····· 80
3.6.1 독립표본 t-검정(Independent Samples t-test) ····· 81
3.6.2 일원 배치 분산분석(One-way ANOVA) ····· 83

제 4 장 고속도로 교통사고 심각도 및 영향요인 분석 ····· 87
4.1 분석 개요 ····· 87
4.2 자료 구분 ····· 89
4.2.1 데이터 스케일링(Data Scaling) ····· 90
4.3 모형 성능평가 지표 선정 ····· 92
4.4 머신러닝을 활용한 고속도로 교통사고 심각도 분석 ····· 93
4.4.1 분석 개요 ····· 93
4.4.2 파이캐럿을 활용한 회귀모델 비교 ····· 94
4.5 머신러닝을 활용한 변수 중요도 평가 ····· 96
4.5.1 모형 선택 ····· 96
4.5.2 랜덤 포레스트 하이퍼 파라미터 성능평가 ····· 98
4.5.3 고속도로 10개 노선의 Feature Importance ····· 101
4.5.4 SHAP 패키지를 활용한 Feature Importance ····· 106

제 5 장 결론 및 향후 연구과제 ····· 110
5.1 결 론 ····· 110
5.2 한계점 및 향후 연구과제 ····· 113

참고문헌 ····· 114
ABSTRACT ····· 119

표 목 차

표 2.1 전통적인 통계기법을 활용한 사고 심각도 관련 국내 연구 ····· 23
표 2.2 전통적인 통계기법을 활용한 사고 심각도 관련 국외 연구 ····· 26
표 2.3 머신러닝을 활용한 국내 연구 ····· 29
표 2.4 머신러닝을 활용한 국외 연구 ····· 32
표 3.1 2019-2021년 전국 고속도로 교통사고 발생 건수 ····· 39
표 3.2 2019-2021년 고속도로 교통사고 연평균일교통량 ····· 48
표 3.3 전국 고속도로 교통사고 연도별 발생 건수, 사망자 수 및 부상자 수 ··· 50
표 3.4 시·도별 고속도로 교통사고 현황 ····· 52
표 3.5 연도별 고속도로 사고 위치별 현황 ····· 56
표 3.6 고속도로 사고 위치별 부상자 현황 ····· 57
표 3.7 고속도로 사고 위치별 사망자 현황 ····· 57
표 3.8 고속도로 사고 위치별 치사율 현황 ····· 58
표 3.9 2019-2021년 고속도로 교통사고 차종별 현황 ····· 60
표 3.10 2019년 고속도로 가해자 법규위반 현황 ····· 62
표 3.11 2020년 고속도로 가해자 법규위반 현황 ····· 63
표 3.12 2021년 고속도로 가해자 법규위반 현황 ····· 63
표 3.13 수집 변수 선정 및 변수 표기법 ····· 66
표 3.14 인적요인변수 기술통계분석표 ····· 71
표 3.15 시간·환경요인 기술통계분석표 ····· 73
표 3.16 사고요인별 기술통계분석표 ····· 76
표 3.17 기하구조 요인별 기술통계분석표 ····· 79

표 3.18 독립표본 t-test 가설 설정 ····· 81
표 3.19 독립표본 t-test 검증 결과 ····· 82
표 3.20 일원 배치 분산분석 가설 설정 ····· 84
표 3.21 일원 배치 분산분석 검증 결과 ····· 86
표 4.1 파이캐럿을 활용한 회귀모델 결과 비교 ····· 94
표 4.2 Random Forest 하이퍼 파라미터 의미 ····· 97
표 4.3 Random Forest 설정 하이퍼 파라미터 ····· 99
표 4.4 Random Forest 하이퍼 파라미터 튜닝 상위 10위 결과 ····· 99
표 4.5 Random Forest 모형 결과 ····· 100
표 4.6 고속도로 10개 노선의 Feature Importance ····· 103

그 림 목 차

그림 1.1 연구의 범위 ····· 3
그림 1.2 연구의 수행절차 및 흐름도 ····· 5
그림 2.1 Random Forest Regression Model ····· 13
그림 2.2 Shap Value를 활용한 시각화 예시 ····· 17
그림 2.3 Tree Ensemble Model 예시 ····· 18
그림 3.1 TAAS 경부고속도로 교통사고 분석 예시 화면 ····· 36
그림 3.2 자료수집 및 기술통계분석 개요 ····· 37
그림 3.2 Q-GIS를 활용한 고속도로 교통사고 결합 예시 ····· 42
그림 3.3 고속도로 교통사고 개별 데이터 예시 ····· 43
그림 3.4 콘 존(Conzone) 데이터 예시 ····· 44
그림 3.5 고속도로 교통사고 개별 데이터 예시 ····· 45
그림 3.6 콘 존 마스터 테이블을 활용한 고속도로 교통사고 데이터 예시 ····· 48
그림 3.7 전국 고속도로 교통사고 추세 분석 ····· 50
그림 3.8 시도별 고속도로 사고건수 및 지역별 증감률 현황 ····· 53
그림 3.9 시도별 고속도로 사망자수 및 지역별 증감률 현황 ····· 53
그림 3.10 시도별 고속도로 부상자수 및 지역별 증감률 현황 ····· 54
그림 3.11 2019-2021년 고속도로 교통사고 위치별 현황 ····· 56
그림 3.12 2019-2021년 고속도로 교통사고 차종별 사고건수 및 사망자 구성비 60
그림 3.13 2019-2021년 고속도로 가해자 법규위반사항 현황 ····· 62
그림 3.14 인적요인 변수 비율 그래프 ····· 71
그림 3.15 시간・환경요인 사고비율 그래프 ····· 74
그림 3.16 사고요인별 사고비율 그래프 ····· 76

그림 3.17 기하구조별 사고비율 그래프 ····· 79
그림 4.1 모형 분석 절차 ····· 88
그림 4.2 구축 데이터 샘플 ····· 89
그림 4.3 수치형 변수 데이터 분포 ····· 91
그림 4.4 StandardScaler 기법을 활용한 데이터 샘플 ····· 91
그림 4.5 파이캐럿을 활용한 모델 성능 비교 예시 ····· 93
그림 4.6 고속도로 Feature Importance ····· 105
그림 4.7 SHAP Feature Importance ····· 106
그림 4.8 SHAP Summary Plot ····· 107

제 1 장 서 론

1.1 연구배경 및 목적

현재 국내의 전체 교통사고 발생 건수는 지속적인 감소추세로 나타나고 있으며, 이는 정부 및 관련 기관에서의 교통사고 심각성을 무겁게 인식하고 교통안전의 체계적인 계획과 개선대책을 수립하고 시행하는 등 다각적인 노력을 추진함에 따른 긍정적인 결과로 판단된다. 우리나라의 도로 교통망의 중요한 축(軸)을 이루며 주요 도시를 연결하는 도로인 고속도로 역시도 감소추세를 나타내고는 있지만, 여전히 증감을 반복하고 있으며 도로의 종류 중 고속도로에서의 교통사고 치사율[1]은 최고치를 나타내고 있다.

2021년 기준, 고속도로 노선은 총연장 4,866km에 이르고 연간 1,698,097 천 대[2]가 고속도로를 이용한 것으로 나타났다. 2021년 한 해 동안 전국의 고속도로에서는 총 4,883건의 교통사고가 발생하였고 그로 인한 사망자 수는 총 191명, 부상자 수는 총 9,708명이다(한국도로공사, 2022). 2021년도 사고 건수는 전년 대비 20.9%, 부상자 수는 15.7% 증가한 수치로 고속도로 교통사고 감소를 위한 대책이 필요하다.

국내 교통사고는 다른 국가와 비교하여도 높은 수준으로 발생하고 있다. OECD 국가별 교통사고 건수를 살펴보면 우리나라는 OECD 평균인 162.6건에 비해 약 2.5배 많은 404.5건이 발생하였고, 자료가 확인된 OECD 33개국 중 우리나라가 가장 많은 33위를 차지하였다. OECD 국가별 인구 10만 명당 교통사고 건수는 회원국 평균 27.0건인데 비해 우리나라의 수치는 74.2건으로 OECD 회원국 평균보다 약 2.8배 많은 교통사고가 발생해 현재까지도 여전히 높은 수치를 나타내고 있다.

---

1) 2021년 기준 도로별 치사율(명/100건) : 고속도로 3.9 > 군도 3.0 > 일반국도 2.8 > 지방도 2.4
2) 영업소 출구 이용 차량을 기준으로 하고 연계운행이 불가능한 민자노선 이용 차량은 제외함.

이는 국내 교통사고 감소를 위한 개선의 여지가 분명히 남아있다고 판단되며 특히 고속도로의 사고 발생 시 가장 높은 치사율을 나타내고 있는 만큼 고속도로 사고 감소를 위한 심각도 영향요인에 대한 정확한 분석과 국내의 실정을 반영한 여러 가지 고민이 필요하다.

기존의 교통사고 자료 분석은 전통적인 통계 방법인 포아송 회귀모형 또는 음이항 회귀모형 등을 기반으로 실시하였으나 최근 머신러닝 및 딥러닝과 같은 빅 데이터 분석 기법을 활용한 새로운 방법들이 주목을 받기 시작하였다.

교통사고와 관련된 다양한 인적, 환경적, 기하 구조적인 인과관계를 찾고 사고빈도를 예측해 정해져 있는 분포나 가정에 따라 분석모형을 설정하기 때문에 현실의 사건을 적용하기에는 무리한 가정이 필요할 수 있는 전통적 통계분석 방법과는 달리, 빅 데이터 분석 기법은 예측의 성공률을 높이는 방향에 중점을 두고 있어 이종(異種)의 대량 자료를 활용한 교통사고와 관련된 요인을 분석하는 데에 장점을 보이며, 이미 다양한 분야에서 활발히 적용되어 우리의 일상을 변화시키고 있다. 이러한 빅 데이터 분석 기법을 활용하여 기존의 전통적 통계분석 방법으로는 분석이 곤란했던 영역을 분석하고, 분석의 정밀도를 높이기 위한 노력이 필요하다.

따라서 본 연구는 고속도로 노선 중 사고 다발 10개의 노선을 채택하여 사고심각도를 분석하고 이에 영향을 미치는 요인을 도출하고자 한다. 이때, 고속도로 교통사고 자료와 고속도로의 주요 분석단위인 콘 존(Congestion Zone, Conzone)을 결합한 자료를 활용해 분석을 진행하였으며 머신러닝의 PyCaret을 활용해 채택된 모델을 활용했다.

또한, 분석 결과를 토대로 본 연구에서 채택한 고속도로 사고 다발 10개의 노선이 아닌 전국의 고속도로 노선으로 연구의 범위를 넓힌다면 고속도로 교통사고 심각도에 영향을 미치는 요인을 분석하고 이를 개선하기 위한 방안을 제시함에 있어 향후 국내의 고속도로 교통사고 감소를 위한 기초적인 자료로 활용이 가능할 것으로 기대한다.

1.2 연구범위 및 절차

1.2.1 연구의 범위

본 연구의 공간적 범위는 전국의 고속도로 중 많은 사고 건수와 다양한 사고 정보를 수집하여 일관성 있고 사고의 신뢰성을 확보할 수 있는 상위 10개의 노선을 선정하여 연구를 수행하였으며, 선정된 고속도로 노선은 아래 그림 1.1과 같다.

시간적 범위는 2019년부터 2021년까지로 TAAS에서 구득할 수 있는 자료의 시간적 범위를 고려하여 선정하였다.

공간적 범위	· 고속도로 노선 중 교통사고 다발 구간 10개 노선 (경부선, 영동선, 서해안선, 남해선, 수도권제1순환선, 중부선, 중부내륙선, 중앙선, 호남선, 서울양양선)

시간적 범위	2019년부터 2021년(3개년)

그림 1.1 연구의 범위

1.2.2 연구의 절차

본 절에서는 대한민국의 고속도로 노선 중 사고 다발 10개 노선이 사고심각도에 미치는 영향요인을 도출하고자 하였으며 다음 그림 1.2와 같이 연구의 범위 및 연구의 절차를 수립하였다.

2장에서 전통적 통계분석 방법 및 빅 데이터를 활용한 분석 기법 등 관련 이론 및 선행연구를 고찰하여 연구에서 활용할 사고심각도 영향요인 분석 방법을 선정하였다.

3장에서는 고속도로 교통사고 심각도 분석을 위한 현황분석을 진행하고 사고분석을 위한 자료수집을 하였다. 이때 수집된 자료는 TAAS의 고속도로 교통사고 데이터와 한국도로공사에서 제공하는 고속도로 콘 존 데이터이며, 이를 Q-GIS로 분석에 활용할 수 있도록 가공하였다. 또한, 가공된 자료는 SPSS를 활용해 사고요인별 기술통계분석을 진행하였으며 전통적 통계분석 방법을 활용한 가설 설정 및 검증을 진행하였다.

4장에서는 분석에 적합한 머신러닝 기법을 선정하고 모형의 분석과 변수 중요도 평가를 진행하여 고속도로 교통사고 심각도에 영향을 미치는 요인을 도출하고자 하였다.

5장에서는 결론을 도출하고 한계점 및 향후 연구 방향에 대해 제시하였다.

제 1 장 서 론	1.1 연구배경 및 목적
	1.2 연구범위 및 절차

⇩

제 2 장 이론 및 선행연구고찰	2.1 전통적 통계분석방법 이론적 고찰
	2.2 머신러닝 이론적 고찰
	2.3 선행연구고찰
	2.4 본 연구의 차별성

⇩

제 3 장 자료수집 및 기술통계분석	3.1 분석 개요
	3.2 분석자료 수집
	3.3 전국 고속도로 현황 및 기초통계분석
	3.4 변수 선정
	3.5 기술통계분석
	3.6 가설 설정 및 검증

⇩

제 4 장 고속도로 교통사고 예측모형 구축	4.1 분석 개요
	4.2 자료 구분
	4.3 모형 성능평가지표 선정
	4.4 머신러닝을 활용한 고속도로 교통사고 심각도 분석
	4.5 머신러닝을 활용한 변수 중요도 평가

⇩

제 5 장 결론 및 향후 연구과제	5.1 결 론
	5.2 한계점 및 향후 연구과제

그림 1.2 연구 수행절차 및 흐름도

제 2 장 이론 및 선행연구 고찰

2.1 전통적 통계분석방법 이론적 고찰

2.1.1 안전성능함수(Safety Performance Function)

안전성능함수(Safety Performance Function, SPF)[3]는 교통사고 예측을 위한 모형 중 미국의 도로안전편람(Highway Safety Manual, HSM)[4]에서 제시하고 있는 모형으로 가장 보편적으로 사용되고 있다.

HSM에서는 안전성능함수(SPF)와 사고보정계수(Crash Modification Factor, CMF)[5] 및 지역보정계수(C)를 이용해 특정 도로에서 발생 될 것으로 예상하는 사고 빈도수, 도로안전등급 평가, 교통안전 시설물 설치 효과 등을 예측 및 추정할 수 있다.

또한, 변수에 따른 해당 지역의 평균 사고 건수 추정을 위해 종속변수는 교통사고 빈도수 또는 교통사고 심각도를 사용하고 독립변수로는 연평균일교통량(AADT), 구간길이, 차로 폭, 조명시설의 존재 여부, 도로의 기하구조 등을 사용해 이들 간의 수학적 관계를 나타낸다(AASHTO, 2010).

안전성능함수는 독립변수의 종류에 따라 단순 안전성능함수(Simple SPF)와 통합 안전성능함수(Inclusive SPF)로 구분된다. Simple SPF는 모형의 설명변수로 AADT 또는 구간길이를 적용하고 Inclusive SPF의 경우 AADT와 구간길이 이외에 기하구조 정보, 도로운영 정보, 교통량 정보 등 다양한 변수를 적용한다.

---

3) 안전성능함수 (Safety Performance Function, SPF)는 기하구조 등 다른 위험 요소가 없다고 가정하고 구간길이와 교통량만을 고려하였을 때 기본적으로 발생이 예상되는 사고 건수로 안전 성능 함수식으로 계산.

4) 미국 도로안전편람 (Highway Safety Manual, HSM) : 교통정책 결정 과정을 지원하기 위해 1990년대 초부터 개발하여 2010년부터 운영되고 있는 기법임.

5) 사고보정계수 (Crash Modification Factor, CMF) : 도로 조건에 따른 사고 영향계수

2.1.2 포아송 회귀모형(Poisson Regression Model)

포아송 회귀모형(Poisson Regression Model)은 계수 자료에 대한 분석에 흔히 사용되는 모형으로 교통사고 분석을 위해 빈번히 사용되고 있는 확률 분포 중 하나이다. 교통사고는 임의적(random)이고 이산적(discrete)인 특성을 가져 연속확률분포가 아닌 이산확률분포를 따르고 발생 확률이 적은 특성을 고려해 포아송 분포를 가정한 모형을 구축하는 것이 일반적이다.

교통사고 건수(y_i)가 포아송 분포를 따를 때, 도로 구간(i)에서 평균적으로 μ_i건의 교통사고 발생 시, 해당 구간의 교통사고 발생 확률은 식 (2.1)로 나타낸다(Lord and Mannering, 2010).

$$p(y_i = y_i ; X_1, X_2, \cdots, X_k) = \frac{e^{-\mu_i}\mu_i^{y_i}}{y_i!},\ y_i = 0, 1, 2, \cdots \tag{2.1}$$

이를 독립변수($X_1 \sim X_k$)를 활용해 도로 구간 i의 평균 사고 건수(μ_i) 기댓값을 포아송 분포 기반 회귀모형 식으로 나타내면 식 (2.2)와 같이 나타난다(Lord and Mannering, 2010).

$$\log(\mu_i) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k \tag{2.2}$$

위와 같은 포아송 분포의 기댓값인 μ_i의 로그 변환 형태가 독립변수들의 선형결합으로 이루어지고 이때 로그연결함수(log link function)를 사용하는 이유는 포아송 분포는 항상 0보다 크게 나타나기 때문이다.

식 (2.2)를 μ_i에 대하여 다시 표현하면 식 (2.3)과 같이 독립변수들의 지수함수(exponential function)의 형태로 표현할 수 있고 포아송 회귀모형의 회귀계수 $\underline{\beta} = (\beta_0, \beta_1, \cdots, \beta_k)$는 최우추정법(Maximum Likelihood Estimation, MLE)을 사용한 $\underline{\beta}$의 최우 추정량을 구할 수 있다(정재풍, 2014).

$$\begin{aligned} \mu_i &= \exp(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k) \\ &= \exp(\sum_{0}^{k} \beta_k x_k) \end{aligned} \tag{2.3}$$

여기서, β_k : 회귀식의 추정계수
x_k : 사고 관련 기하구조 요소

포아송 회귀모형은 평균과 분산이 같다는 가정하에 적용이 가능하다. 그러나 측정된 교통사고 건수는 분산이 기댓값(평균)보다 큰 과대산포(Over-dispersion) 또는 과분산 문제를 보이는 경우가 빈번해서 예측 성능이 저하될 수 있고 샘플의 수가 적은 데이터에도 부정확한 예측 결과를 산출한다는 한계점이 있다(Lord and Mannering, 2010). 따라서 교통사고 건수에 과분산 현상이 나타날 때는 평균과 분산이 같다는 조건을 완화시킨 음이항 회귀모형을 활용해 교통사고 건수를 추정할 수 있다.

2.1.3 음이항 회귀모형(Negative binomial Regression Model)

음이항 회귀모형(negative binomial regression model)은 평균과 분산이 같다는 포아송 회귀모형의 가정을 일반화한 모형으로, 교통사고 건수와 같은 종속변수가 과분산 현상(Over-dispersion)을 보일 때 사용이 가능하다.

음이항 회귀모형을 이용해 도로 구간 i에서 일어나는 평균 사고 건수(기댓값) μ_i를 추정하면 식 (2.4)와 같다. 이는 감마분포를 따르는 오차항(ϵ_i)을 추가해 포아송 회귀모형에서 해결하지 못하는 사고 자료의 과분산 현상을 해결하고, 이때의 기댓값은 아래의 식 (2.4)와 같이 표현할 수 있다.

$$\begin{aligned}\mu_i &= \exp(\beta_0 X_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \cdots + \beta_k X_k + \epsilon_k) \\ &= \exp(\sum_{0}^{k} \beta_k X_k + e_k)\end{aligned} \tag{2.4}$$

여기서, β_k : 회귀식의 추정계수
X_k : 사고관련 기하구조 요소
ϵ_k : 오차항

식 (2.4)를 바탕으로 음이항 분포를 따르는 Y_i 에 대한 기댓값과 분산의 관계는 식 (2.5)와 같다.

$$Var(y_i) = \mu_i(1+\alpha\mu_i) \tag{2.5}$$

여기서, $Var[Y_i]$: 종속변수(Y_i)의 분산
μ_i : 종속변수의 기댓값(평균)
α : 과분산 계수

식 (2.5)을 통해 알 수 있듯이 과분산 계수(Over Dispersion Parameter)의 α 값이 0일 경우 포아송 분포에 적합하다는 결론이 나올 수 있으나 사고 건수의 경우 α 값이 0이 되는 경우는 거의 없어서 일반적으로 α 값이 0.5 이하일 때 포아송 분포를 사용하고 0.5 이상일 때 음이항 분포를 사용하는 것이 적절한 것으로 알려져 있다(강민욱 외, 2002). 하지만 이러한 적용은 임의적인 구분이므로 우도비 검정을 통한 과분산 여부의 평가가 더욱 타당하다(류종득, 2018).

우도비 검정 통계량(Likelihood Ratio, LR)의 값은 자유도가 1인 x^2 분포를 따르고 유의수준 임계값과 우도비 검정 통계량(LR) 값을 비교하여 과분산 여부를 평가할 수 있다. 우도비 검정 통계량의 값이 유의수준 임계값보다 클 경우 기각역에 해당해 과분산이 발생한 것으로 볼 수 있어 음이항 회귀모형을 사용하는 것이 바람직하다(황경성, 2010).

또한, 모형의 적합성 비교를 위해 사용하는 통계량으로 AIC(Akaike Information Criterion)과 BIC(Bayesian Information Criterion) 가 있다. 이 두 개의 통계량은 동일한 종속변수와 독립변수로 실시한 포아송 및 음이항 회귀모형 중 더 좋은 모형을 평가하며, AIC 및 BIC의 값이 낮은 값을 나타낼수록 더 우수한 회귀모형임을 의미한다(류종득, 2018).

2.2 머신러닝 이론적 고찰

2.2.1 머신러닝의 정의

머신러닝(Machine Learning)은 규칙을 일일이 프로그래밍하지 않아도 자동으로 데이터에서 규칙을 학습할 수 있도록 알고리즘과 기술을 연구하는 분야이다. 인공지능의 하위 분야 중 지능을 구현하기 위한 소프트웨어를 담당하는 핵심 분야라고 할 수 있으며 컴퓨터 과학 분야의 대표적인 머신러닝 라이브러리로는 사이킷런(Scikit-learn)이 있다.

머신러닝 알고리즘은 크게 지도학습(Supervised Learning)과 비지도 학습(Unsupervised Learning)으로 구분할 수 있다. 지도학습은 실제 출력 값과 정확한 출력 값을 비교하고 오류를 검출하며 알고리즘 학습을 하고 과거의 데이터를 기반으로 미래에 있을 사건을 예측하는 데에 보편적으로 사용되고 있다. 비지도 학습 시스템은 정답이 없어 알고리즘을 통해 현재 무엇을 출력하고 있는지 알 수 있어야 한다. 또한, 데이터를 탐색해 내부의 구조를 파악하는 데에 목적이 있어 비지도 학습은 트랜잭션[6](Transaction) 데이터에 특히 효과적이다.

지도학습은 학습결과에 대한 사전 지식이 존재해 이를 통해 분류(Classification)와 회귀(Regression) 작업에 사용한다. 지도학습의 알고리즘에는 랜덤 포레스트(Random Forest), 의사결정나무(Decision Tree), K-최근접이웃법(K-nearest neighbor, KNN), 서포트 벡터 머신(Support Vector Machine, SVM), 로지스틱 회귀분석, 선형 회귀분석, 나이브 베이즈, 신경망 모형 등이 있다.

본 연구는 지도학습 방식의 머신러닝 방법 중에서 앙상블 학습의 대표 주자이자 안정적인 성능 덕분에 널리 사용되고 있는 랜덤 포레스트(Random Forest)를 이용하

6) 트랜잭션(Transaction) : 데이터베이스의 상태를 변화시키는 하나의 논리적 기능을 수행하기 위한 작업 단위

여 고속도로 교통사고 심각도에 미치는 영향 요인 분석과 변수 중요도를 도출하였고, 이때 교통사고 심각도를 EPDO로 환산하였기 때문에 회귀분석[7]을 진행하였다.

2.2.2 랜덤 포레스트(Random Forest)

랜덤 포레스트(Random Forest)는 분류(Classification)와 회귀(Regression)에 사용되는 지도학습 알고리즘으로 여러 개의 의사결정나무(Decision Tree)를 조합한 모델이다. 의사결정나무는 일련의 if-else로 이루어진 나무모형으로써 중간 마디(internal node)와 끝마디(leaf node)로 구성되고 각각의 데이터는 다차원의 특징 공간(feature Space)을 나타내는 벡터 x와 출력변수(label)로 이루어지며 아래 수식 (2.6)과 같다.

$$\begin{aligned} X &= (x_1, x_2, \cdots, x_n) \\ label &= (X, y) \end{aligned} \tag{2.6}$$

랜덤 포레스트는 의사결정나무에 배깅(bootstrap aggregation, bagging)이라는 앙상블 학습(ensemble learning)을 적용한 모델로 분류와 회귀에서 높은 성능을 보여 데이터 분석 시 많이 활용되고 있으며 과대 적합(Over-fitting)을 방지하기 위하여 최적의 기준 변수를 랜덤하게 선택하는 머신러닝 기법이다(Breiman, 2001).

여기서 배깅(Bagging)은 랜덤 포레스트의 전체 집합에서 무작위로 복원 추출하여 여러 부분의 집합을 만드는 부트스트랩(Bootstrap)을 이용한 앙상블 기법[8]으로 조금

---

7) 회귀분석(Regression Analysis) : 목표변수가 종속변수에 의해 어떻게 설명 혹은 예측되는지 알아보기 위해 자료를 적절한 함수식으로 표현하여 분석하는 데이터 분석 기법

8) 앙상블(Ensemble) 기법 : 다수의 기초 알고리즘을 결합해 더 나은 성능의 예측 모델을 형성하는 것으로 사용 목적에 따라 배깅(Bagging), 부스팅(Boosting), 스택킹(Stacking)으로 분류됨.

씩 다른 훈련 데이터에 대해 훈련된 기초 분류기(Base learner)를 결합해 모형의 분류 정확도와 안정성을 높이는 데에 효과가 있으며 편차(variance)를 줄이기 위해 사용한다.

랜덤 포레스트는 과대 적합을 해소하고 분산을 감소시켜 단일 결정 트리보다도 더욱 안정적인 예측 성능을 보이고 정확도가 높다는 장점이 있지만, 계산 비용이 높고 규칙이 많아 추론 로직을 설명하기에 어렵다는 단점이 있다. 그림 2.1은 랜덤 포레스트 모형을 시각화한 예시이다.

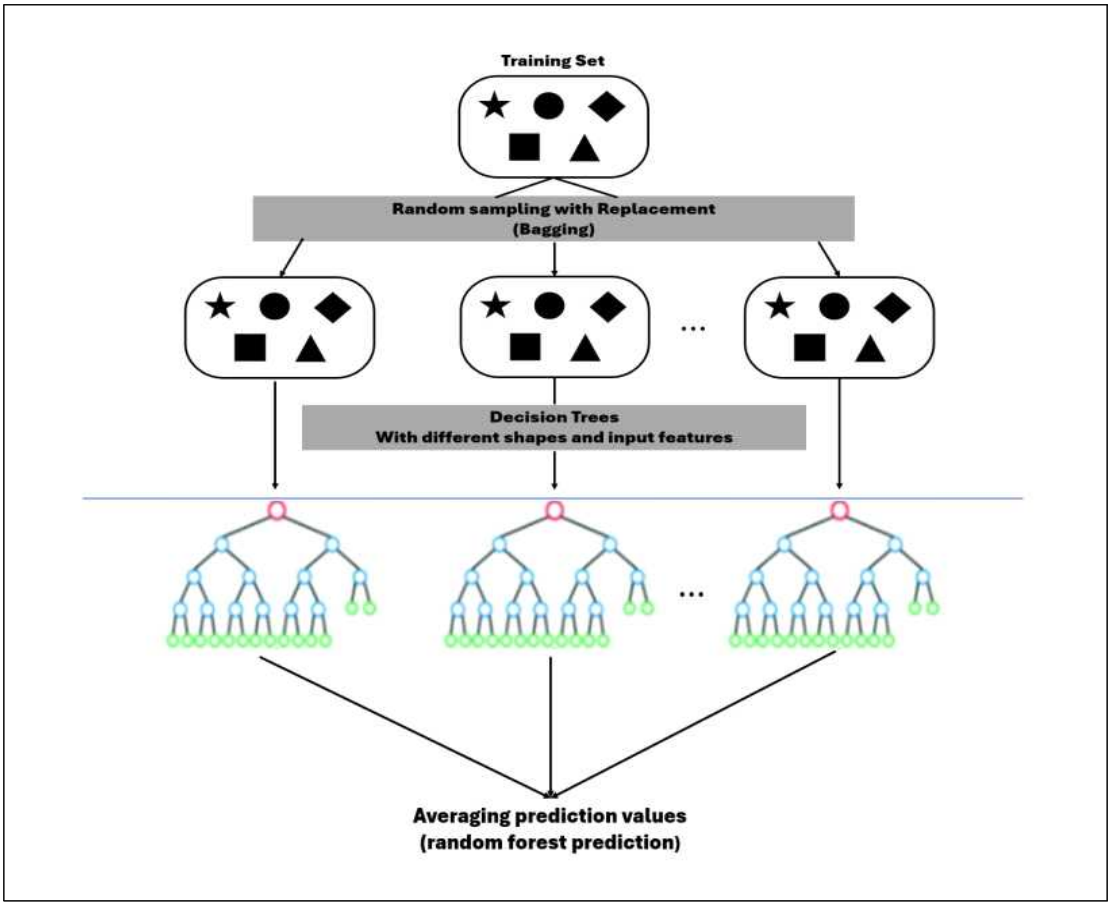


그림 2.1 Random Forest Regression Model

2.2.3 변수 중요도(Feature Importance)

입력변수 중요도는 XGBoost의 자체 모델을 통한 해석 방법과 Skater, SHAP(Shapley Additive Explanations) 등 해석 패키지를 활용한 분석방법이 있으며 앙상블 기법을 활용한 지도학습 모형에는 변수 중요도를 추출할 수 있는 알고리즘이 내장되어 있다.

XGBoost의 중요도 측정은 ‘Weight’, ‘Cover’, ‘Gain’을 기준으로 판단하며 여기서 Weight는 변수별 데이터를 분리하는 데 쓰인 횟수, Cover은 해당 변수로 분리된 데이터의 수, Gain은 Feature를 사용하였을 때 줄어드는 평균적인 training loss를 의미한다. 이를 통해 개발된 모형으로 변수 중요도는 파악할 수 있으나 각 변수가 어떤 방향으로 영향을 미치는지 즉, 각 변수가 양(+)의 상관성을 가지는지 음(-)의 상관성을 가지는지 분석하는 데에는 한계가 있다.

따라서 본 연구에서는 이러한 문제를 보완하기 위해 Shapley value를 통한 변수 중요도를 분석하고자 한다. 이때, SHAP 패키지에서 제공하는 SHAP Feature Importance를 이용한 Shapley value에 의한 입력변수 중요도를 분석하였다.

가. Shapley value

Shapley value는 게임이론(Game Theory)[9]을 바탕으로 game에서 각 player의 기여분을 계산하는 방법으로, 하나의 특성에 대한 중요도를 알기 위해 다양한 특성의 조합을 구성하고 해당 특성의 유무에 따른 평균적인 변화를 통해 다음 수식과 같이 계산한다.

$$\Phi_j(val) = \sum_{S \subseteq 1, \cdots, p/j} \frac{|S|!(p-|S|-1)!}{p!}(val(S \cup j) - val(S)) \qquad (2.7)$$

여기서, Φ_j : j번째 데이터에 대한 Shapley value

p : 모델 입력변수 전체 집합

S : 전체 집합에서 j번째 데이터가 빠진 나머지의 모든 부분집합

$val(S \cup x_j)$: j번째 데이터를 포함한 (=전체)기여도

$val(S)$: j번째 데이터가 빠진 나머지 부분집합의 기여도

수식에서 $(val(S \cup x_j) - val(S))$는 player j가 협력했을 경우 기여하는 크기이고, $\frac{|S|!(p-|S|-1)!}{p!}$ 는 각각 협력하는 조합의 확률에 해당한다. 따라서 식 (2.7)에 따르면, Shapely value는 전체 협력에 각 player j가 기여할 것이라고 예상되는 기여도라고 할 수 있다.

---

[9] 게임이론(Game Theory) : 개인 또는 기업이 어떠한 행위를 했을 때 그 결과가 자신과 다른 참가자의 행동에 의해서도 결정되는 상황에서 자신의 최대 이익에 부합하는 행동을 추구한다는 수학적 이론.

나. SHAP(SHapley Additive exPlanations)

SHAP(SHapley Additive exPlanations)은 머신러닝 모델의 출력을 설명하기 위한 게임이론에 기반한 접근법으로 SHAP value를 기반으로 한 알고리즘을 통해 변수 중요도(feature importance)를 파악할 수 있다. SHAP은 섀플리 값(Shapley values)을 기반으로 하여 머신러닝 모델의 조건부 기댓값 함수를 이용해 구하는 값으로 가능한 모든 feature의 순서쌍에 대해 샘플링을 실시하고 평균값을 계산하며 다음과 같은 수식 (2.8)로 나타낸다.

$$g(z') = \Phi_0 + \sum_{j=1}^{M} \Phi_j z'_j \tag{2.8}$$

여기서, g : 설명 모델, $g(z') \approx f(h_x(z'))$
M : 최대 연합 사이즈
Φ_j : j번째 데이터에 대한 Shapely value
z'_j : 연합벡터 $(z'_k \in 0,1^M (k \in 1, \dots, K))$

여기서, g는 설명 모델을 의미하고, M은 최대 연합 사이즈를 의미하며 총 변수의 개수보다 클 수 없다. Φ_j는 j번째 데이터의 Shapley value를 의미하며 z'_j은 연합벡터, n은 feature의 개수를 의미한다.

변수 중요도(feature importance)는 예측에 가장 큰 영향을 주는 변수의 순서를 교대(permutation)하며 찾는 기법으로 변수 간의 일관성(Consistency)을 간과할 수

있고, 부분 의존성 플롯(Partial Dependence Plot, PDP)은 3차원까지의 관계만 표현이 가능하다는 한계가 있어 4차원 이상의 플롯부터는 표현이 불가하여 결과가 왜곡될 수 있다는 단점이 있다. 반면에 SHAP는 변수 간 일관성(Consistency)까지 고려해 모델의 영향력을 계산할 수 있고 영향에 대한 방향성(Positive or negative)도 분석 가능하다는 장점이 있다.

SHAP Feature Importance를 도출할 때, summary_plot 함수를 이용하면 Shapley value가 양수(+)일 경우 변수의 값이 클수록 예측 값이 커지는 데 영향을 미쳤다는 의미이고, Shapley value가 음수(-)일 경우 변수의 값이 클수록 예측 값이 작아지는 데에 영향을 미쳤다는 의미이다.

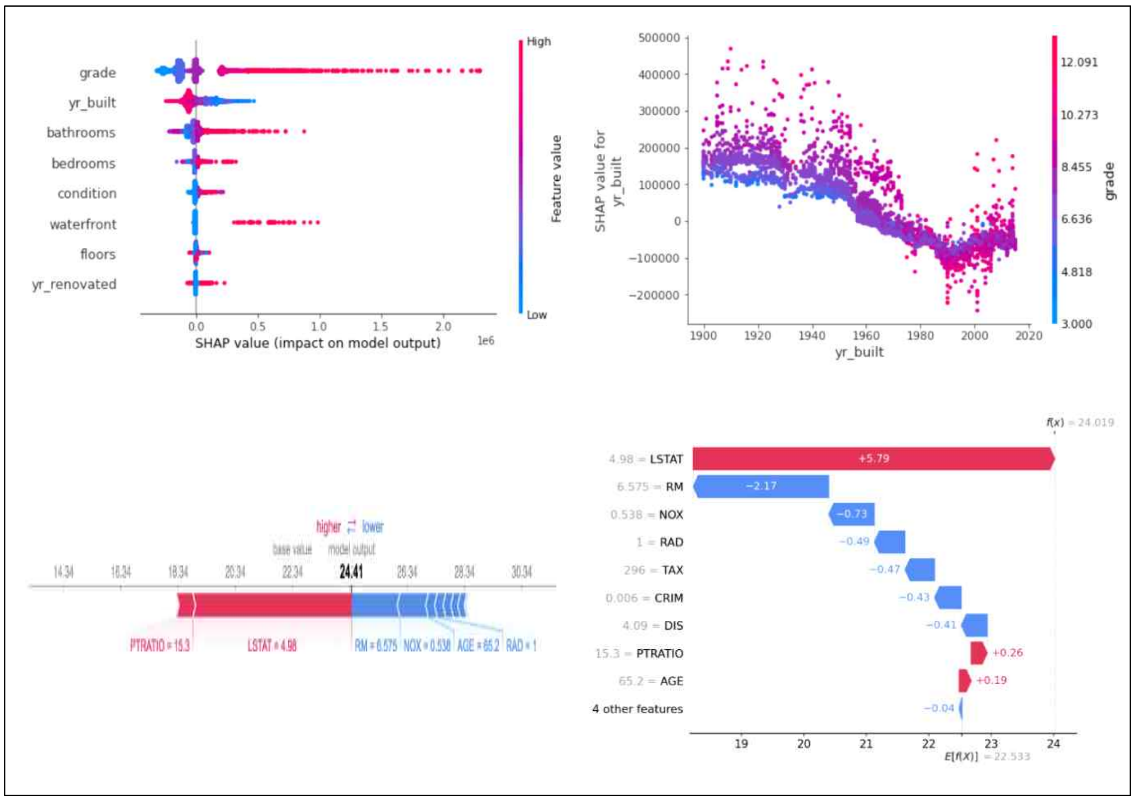
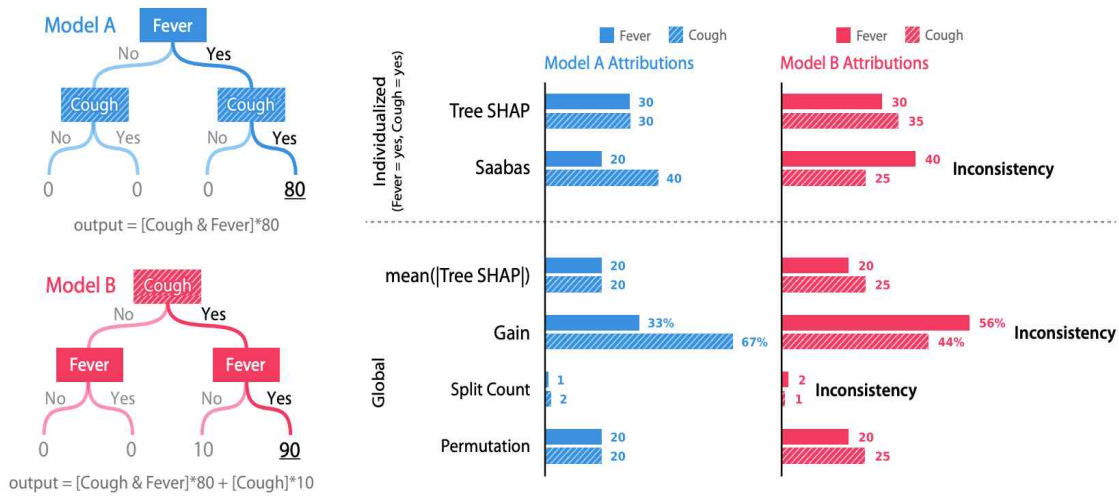


그림 2.2 Shap Value를 활용한 시각화 예시

다. Tree SHAP

SHAP의 종류에는 모든 머신러닝 모델에 적용이 가능한 Kernel SHAP, 딥러닝 모델에 사용하는 Deep SHAP, 트리 앙상블 모델에 적합한 Tree SHAP가 있다(이용건, 2020). 의사결정나무, 랜덤 포레스트, XGBoost와 같이 기본 학습기로 트리 기반 모델을 사용하는 앙상블 모형의 경우 이러한 나무 구조를 활용하여 좀 더 쉽게 SHAP Value를 구할 수 있다.

Tree Ensemble Model의 변수 중요도는 모델마다 산출되는 값이 달라져 일정하지 않다는(inconsistent) 한계가 존재한다. 그림 2.3과 같이 Tree Model A와 B의 변수는 Fever, Cough로 같게 나타나고 있으나 Split의 순서가 다르고, Split 순서에 기반해 계산하는 Gain, Split, Count 등의 산출 값이 달라지는 것을 확인할 수 있다. 즉, 같은 데이터로부터 학습된 모델이지만 각각의 모델마다 변수 중요도가 달라진다.



출처 : https://shap.readthedocs.io/en/latest/index.html

그림 2.3 Tree Ensemble Model 예시

반면, 2018년 Lundberg에 의해 발표된 트리 기반 모델 SHAP의 변형된 버전인 Tree SHAP는 나누어진(split) 순서와는 무관하게 일정한(consistent) 변수 중요도를 계산할 수 있다.

$E[f(x)|x_s]$ = x_s가 속하는 리프노드($\leq af\,node$)의 $score$ 값 × 해당 $node$에 속하는 데이터 비중 (2.9)

Tree SHAP의 계산방법은 식 (2.9)와 같으며, 각각의 트리마다 조건부 평균인 $E[f(x)|x_s]$을 계산하고 모두 더한 값을 최종 값으로 산출한다. 또한, Tree SHAP와 Kernel SHAP의 시간 복잡도의 차이를 나타내는 식은 아래 식 (2.10)과 같다.

Tree SHAP는 Kernel SHAP와 비교해 계산 속도가 더 빠르지만, 이해하기 힘든 특성 기여분을 생성할 수 있다는 한계가 있다.

$$\begin{aligned} Tree\,SHAP &= O(TL2^M) \\ Kernel\,SHAP &= O(TLD^2) \end{aligned} \quad (2.10)$$

여기서, T : 트리의 개수
L : 모든 트리의 최대 leaf 수
D : 모든 트리의 최대 깊이

2.3 선행연구 고찰

2.3.1 전통적인 통계기법을 활용한 사고심각도 연구

가. 국내 연구

윤병조(2017)는 고속도로 교통사고의 사고 건당 심각도(EPDO)를 계산하여 선형 회귀 분석을 통한 사고 심각도와 EPDO에 미치는 요인을 분석하고자 하였다. 분석 결과, 사고유형 중 차대차 사고일 경우 EPDO가 2.006, 사고에 직접적인 영향을 미치는 사고요인 중 역주행 운행일 경우 EPDO가 3.142, 교통사고의 주간 발생보다 야간 발생인 경우의 EPDO는 0.221로 나타났으며 운전자 연령대가 20대 미만이거나 60대 이상일 경우에서 유의확률이 나타났다.

이근희(2015)는 서울, 수도권, 부산광역시의 4지 신호 교차로를 대상으로 도로의 기하구조, 교통 특성 및 환경 특성 등의 다양한 요인을 고려한 교통사고 예측모형을 구축하고 교차로에서 발생하는 사고와의 상호관계를 규명하고자 하였다. 분석 결과 기존의 음이항 모형보다 확률적 음이항 모형의 설명력이 높게 나타났다. 종속변수를 총 교통사고 건수가 아닌, 심각도별로 사고 건수를 적용한다면 각 변수가 단순 사고 발생이 아닌 사고 심각도에 미치는 변수를 파악할 수 있다고 주장하였다.

박정순(2011)은 신호 교차로에서의 보행자 사고 심각성을 인지하고 순서형 프로빗 모형을 이용해 횡단보행자 사고 심각도에 영향을 미치는 요인을 도출하고자 하였다. 분석 결과, 사고 심각도에 영향을 미치는 변수로 보행자 연령대, 토지이용, 시간대, 차종, 제한속도 등으로 유의수준이 0.05 이하로 95%의 신뢰수준에서 통계적 유의성이 존재하는 것으로 나타났다.

강동운(2014)은 안전성능함수 구축 시 변수 간의 상관성 문제를 해결하기 위한 주성분 분석의 활용성을 검토하는 연구를 진행하였다. 2008년부터 2012년의 경부, 영동, 서해안고속도로의 자료를 사용해 종속변수는 사고 건수를, 독립변수로는 AADT, 구간길이, 평면 선형, 종단 선형, 차로 수를 활용해 분석하였다. 분석 결과, AADT와 차로 수의 상관관계가 높았고, 두 변수가 동시에 모형에 적용되었을 때 문제가 발생함을 확인할 수 있었으며 이를 해결하기 위해 음이항 회귀모형을 기반으로 한 안전성능함수를 구축하였다.

강찬모(2018)는 국내 화물차 사고 발생 건수 및 사망률의 지속적인 증가로 인한 사고 심각도 분석을 하였다. 분석에는 순서형 프로빗 모형을 적용하였고 총 10개의 주요 인자를 도출하였다. 분석 결과, 고령의 운전자, 높은 충돌속도, 졸음운전, 사고 후 차량 화재 발생, 사고 후 차량의 전도 혹은 전복, 심야(00~06시)시간대에 발생한 사고일수록 부상 심각도가 증가하는 것으로 나타났다.

강가원(2022)은 연 단위 사고예측모형에 1시간, 30분, 실시간(5분)의 집계단위를 선정해 고속도로의 시간대별 교통 특성을 세부적으로 반영할 수 있는 안전성능함수를 개발하고자 하였다. 각각의 집계단위별 사고 건수를 종속변수로 사용해 포아송 회귀모형 및 음이항 회귀모형의 형태로 개발되었다. 또한, 좀 더 미시적인 단위의 사고 예측을 위해 5분 단위의 실시간 사고 발생 확률예측 모형을 개발하고 종속변수를 사고 발생유무의 이항 형태로 선정하여 로지스틱 회귀모형을 사용해 개발하였다. 분석 결과, 모든 모형에서 균일한 예측 성능을 보인 모형은 30분 단위 및 1시간 단위 모형으로 나타났으며 본 논문에서 제시한 사고예측모형과 방법론을 활용해 고속도로 구간의 사고위험 요인 판단에 활용할 수 있을 것으로 주장했다.

김용현(2022)은 개인형 이동장치 관련 교통사고 위험요인에 대한 순서형 로짓 모형(Ordered Logit Model)을 활용한 분석을 진행했다. 종속변수로는 사고 심각도, 독립변수로는 사고의 위험요인들을 적용했고, 사고 심각도를 부상사고 및 경상사고, 중상사고, 사망사고의 3단계로 구분하여 연구를 진행했다. 분석 결과, 사고 심각도

에 심각한 영향을 미치는 것은 과속인 경우, 차량 단독사고의 경우, 운전자가 고령일 경우, 계절은 봄일 경우에 사고 심각도가 높아졌다. 순서형 로짓 모형분석 결과를 EPDO 평균값과 비교한 결과도 영향요인의 순서가 일치했으나 위험도가 높게 나온 변수들의 빈도수가 다른 변수들의 빈도수에 비해 현저히 적은 경우가 있어 결과 해석에 주의가 필요하다고 주장하였다.

김윤환(2006)은 고속도로 교차점의 기하구조와 교통사고의 관계설정과 모형 분석에 있어 다양한 통계적 모형을 이용해 모형의 적합도 향상을 통해 정확한 모형 구축하고자 하였다. 독립변수는 교차점의 기하구조의 요소인 교차 각, 최대 종단경사, 최소곡선반경, AADT를 활용하였다. 종속변수는 교차점의 평균 사고 건수를 활용하였다. 이 자료를 바탕으로 비선형을 선형으로 전환하는 변수의 변환을 이용한 다중회귀분석과 지시변수를 도입한 다중 회귀분석, 포아송 회귀분석, 능형 회귀분석을 실시한 모형을 구축하였다. 분석 결과, 다중 회귀분석의 결과에서는 AADT와 평균 교통사고 간에만 유의미한 관계를 보였으나 포아송 회귀분석의 경우 최소곡선반경을 포함하는 모형이 구축되어 적절한 모형 결과를 도출하였다고 주장하였다.

서임기(2015)는 고속도로의 노선별 교통량과 구간길이를 설명변수로 선정하고 주요 6개 노선을 대상으로 통합노선 안전성능함수를 구축하여 노선별 보정계수를 산정하는 연구를 수행하였다. IC 및 JCT 구간별 교통사고 분포형태를 분석한 결과, 포아송 분포보다 음이항 분포가 더 적합하다고 분석되어 음이항 분포모형을 이용한 안전성능함수 개발내용을 제시하였다. 종속변수를 교통사고 발생 건수로 설정하고 설명변수를 AADT와 구간 길이로 설정하였으며 연구 결과, 구간길이와 교통량의 부호조건이 정(+)으로 합리적인 결과가 도출되었다.

표 2.1 전통적인 통계기법을 활용한 사고심각도 관련 국내 연구

구 분		참고내용
저 자	문 헌 명	분석방법
윤병조 (2017)	· EPDO에 영향을 미치는 고속도로 교통사고 요인 분석에 관한 연구	· 선형 회귀분석
이근희 (2015)	· 확률 모수를 이용한 교통사고예측모형 개발 - 수도권 및 부산광역시 4지 교차로를 대상으로-	· 확률적 음이항 회귀모형
박정순 (2011)	· 신호교차로의 횡단보행자 사고심각도 분석	· 순서형 프로빗 모형
강동운 (2014)	· 상관성이 있는 변수를 고려한 주성분 분석 기반의 안전성능함수 개발	· 음이항 회귀모형
강찬모 (2018)	· 순서형 프로빗 모형을 적용한 고속도로 화물차 사고 심각도	· 순서형 프로빗 모형
강가원 (2022)	· 동적 교통지표의 시간적 집계 수준을 고려한 고속도로 안전성능함수 개발	· 포아송 회귀모형 · 음이항 회귀모형 · 로지스틱 회귀모형
김용현 (2022)	· 순서형 로짓 모형을 이용한 개인형 이동장치 교통사고 심각도 위험요인 분석	· 순서형 로짓모형
김윤환 (2006)	· 고속도로 교차점의 기하구조와 교통사고의 관계분석 : 다중 회귀분석, 포아송 회귀분석, 능형 회귀분석 모형을 중심으로	· 다중 회귀분석 · 포아송 회귀분석 · 능형 회귀분석
서임기 (2015)	· 고속도로 선형 동질구간 기반의 안전성능함수 개발	· 음이항 회귀모형

나. 국외 연구

Zhong Liande(2009)은 사고의 분포를 포아송(Poisson), 음이항(Negative Binomial, NB), Zero Inflated Poisson(ZIP), Zero Inflated Negative Binomial(ZINB) 분포로 가정하여 각 모형 형태 간의 비교를 했다. 독립변수로는 AADT, 기하구조, 안전시설물의 정보 등을 포함한 안전성능함수를 구축하였다. 분석 결과, 음이항 회귀모형이 가장 좋은 모형으로 선정되었으며 이후의 연구에서는 사고 분포를 모두 음이항 분포로 가정하고 안전성능함수를 구축하였다.

Sung-ra Mun(2012)은 사고 분포를 음이항 분포로 가정하여 고속도로 본선에서의 교통사고 예측모형을 개발했다. 자료 구축이 용이한 변수를 선정해 모형을 쉽게 활용할 수 있도록 했으며, 종속변수로는 사고 건수, 사상자 발생사고 건수로 사고 모형을 구축했고 분석에는 음이항 분포와 포아송 분포를 활용했다. 최우추정법에 의한 추정 결과, 사고 모형의 경우 구간길이, 일 교통량, 버스 비율, 곡선 구간 수가 유의한 변수로 추정되었고 사상자 발생사고 모형에서는 구간길이, 일 교통량, 버스 비율이 유의한 변수로 추정되었다.

Jinyan Lu(2013)은 교통사고의 예측과 위험지역의 위치 검증을 위해 Safety Analyst에서 제공하는 단순 안전성능함수(Simple SPF)와 교통 특성 및 기하구조 자료를 활용한 통합 안전성능함수(Inclusive SPF)를 비교했다. 연구는 미국 플로리다주의 도시부 4차로 고속도로의 2007년부터 2010년간의 자료를 활용했고 HSM을 비롯한 학술연구에서 사용되는 음이항 회귀모형을 이용해 고속도로 교통사고 예측모형을 구축했다. 통합안전성능함수와 단순 안전성능함수의 교통사고 예측력을 비교한 결과, MAD와 Mean Squared Prediction Error(MSPE)를 활용모델로 선정했다. 선정 결과, 두 가지 모형 모두 교통사고 예측과 networking screening에 있어 유사한 성능을 가지고 있다고 분석했다.

Joy M. Koopmans(2015)는 2004년부터 2010년 일리노이주에서 발생한 보행자 대 자동차 사고를 대상으로 연령대별, 연도별 발생률과 사고 특성을 분석하였다. 교통사고 특성에 따른 부상 심각도를 분석하기 위해 다변량 로지스틱 회귀분석을 실시했다. 분석 결과, 전체 보행자 교통사고 발생률은 어린이(100,000명당 146.6)와 성인(100,000명당 117.3)으로 어린이 교통사고 발생률이 더 높았으나 치명률은 어린이 0.7%, 성인 1.7%로 더 낮게 분석되었다.

Shaw-Pin Miaou(1992)은 고속도로의 기하학적 설계 변수와 트럭 사고의 실증적 관계를 확립하기 위해 포아송 회귀모델을 활용하여 분석을 진행했다. 모델 계수 추정을 위한 방법으로 최대 우도 방법을 사용하였으며 최종 모형에서는 차선별 연평균 통행량, 수평 곡률, 수직 경사도가 트럭 사고의 발생률과 유의미한 상관관계가 있는 것으로 나타났고, 갓길의 폭은 상대적으로 낮은 상관관계가 나타났다고 주장했다.

Li-Yen Chang(2005)은 대만의 고속도로 교통사고 위험의 기하학적 특성과 환경 요인에 중점을 두어 연구를 진행했다. 연구에서는 인공신경망(ANN)을 활용해 위험 요인과 교통사고의 관계를 분석할 수 있는지 살펴보고 음이항 회귀모형과 ANN 모델 간의 예측 성능을 평가하고자 했다. 연구의 결과를 활용하여 대만의 교통사고 빈도가 높은 위치를 식별하는 데에 사용될 수 있다고 주장했다.

Augus Eugene Retallack(2020)은 호주의 Adelaide의 120개 교차로에서 발생한 교통사고에 영향을 미치는 요인을 분석하고자 했다. 모형분석 결과, 포아송 일반화 선형모형(Generalized Linear Model, GLM)은 교통량이 적은 교차로에서 발생하는 사고 건수에 적합했고, 포아송 모형은 중간이나 높은 교통량의 교차 지점에서 과분산 되므로 음이항 모델이 적합하다고 분석되었다. 연구 결과, 혼잡 수준이 높을수록 사고의 빈도가 비선형적으로 증가하는 것으로 나타났고 이러한 수준의 혼잡을 피하기 위해서는 교통 체계를 관리하는 것이 사고 발생을 줄이는 데 큰 영향을 미칠 것이라고 주장했다.

표 2.2 전통적인 통계기법을 활용한 사고 심각도 관련 국외 연구

구 분		참고내용
저 자	문 헌 명	분석방법
Zhong Liande (2009)	· Safety Performance Function for Freeways in China	· 음이항 회귀모형
Mun, Sung-Ra (2012)	· Developing a Traffic Accident Prediction Model for Freeways	· 음이항 회귀모형 · 포아송 회귀모형
Jinyan Lu (2013)	· Full versus Simple Safety Performance Functions: A Comparison Based on Urban Four-Lane Freeway Interchange Areas in Florida	· 음이항 회귀모형
Joy M. Koopmans (2015)	· Urban crash-related child pedestrian injury incidence and characteristics associated with injury severity	· 다변량 로지스틱 회귀분석
Shaw-Pin Miaou (1992)	· Relationship Between Truck Accidents and Highway Geometric Design: A Poisson Regression Approach	· 포아송 회귀모형
Li-Yen Chang (2005)	· Analysis of freeway accident frequencies: Negative binomial regression versus artificial neural network	· 음이항 회귀모형
Augus Eugene Reetallack (2020)	· Relationship Between Traffic Volume and Accident Frequency at Intersections	· 음이항 회귀모형

2.3.2 머신러닝을 활용한 연구

가. 국내 연구

강홍식(2022)은 인구 대비 교통사고 사망자 비율이 높은 대전시를 대상 지역으로 설정하고 보행자 교통사고 자료수집 후, 기계학습을 통한 최적 알고리즘과 심각도 분류의 주요 인자를 도출하고자 하였다. 연구 결과, 적용한 9개의 알고리즘 중 앙상블 기반 학습기법인 Ada Boost와 Random Forest 기법이 최적의 성능을 보여주었으며, 대전시 보행자 교통사고 심각도의 주요 인자는 보행자 연령대가 70대 또는 20대인 경우, 사고유형이 횡단사고일 경우 교통사고 심각도에 영향을 주는 것으로 나타남에 따라 대전시 보행자 사고 저감 대책을 위한 고려요인으로 제안하였다.

권철우(2021)는 XGBoost를 활용하여 이륜자동차 교통사고를 활용해 사고 심각도에 영향을 미치는 요인을 도출하고 이륜자동차로 인해 발생하는 심각한 교통사고 예방을 위한 법규 개편방안을 제시했다. 분석 결과, 신호 위반인 경우, 운전자 연령대가 60대 이상일 경우, 이륜자동차 단독사고일 경우, 중앙선 침범 사고일 경우가 이륜자동차 교통사고 심각도에 영향을 주는 변수로 나타났다. 이를 토대로 이륜자동차의 법규위반을 줄이기 위한 노력과 이륜자동차 안전 교육의 필요성을 강조했다.

손승오(2022)는 데이터마이닝 기법을 통해 도출한 사고 심각도 가중치를 적용하여 환산한 사고 건수를 종속변수로 설정한 도심부 교차로 사고예측모형 개발을 하였다. 교차로 사고 심각도 분석에는 Random Forest와 Extreme Gradient Boosting(XGB) 방법론을 활용했다. 제안된 종속변수는 예측 성능뿐만 아니라 사고 심각도 분석 결과를 반영하고 있어 더 많은 안전성 해석이 가능한 접근 방식이며 연구에서 제시한 모형은 개별 교차로의 안전성 평가 및 정책 설계에 유의미한 자료로 활용될 수 있음을 강조했다.

김승훈(2021)은 기계학습을 기반으로 다양한 알고리즘을 활용해 고령 운전자에 의해 발생하는 보행자 피해사고 심각도에 미치는 요인을 분석하고자 하였다. 각 모형의 학습결과 비교를 위해 훈련 데이터를 대상으로 예측 성능을 분석했다. 분석 결과, 로지스틱 모형과 SVM 모형이 상대적으로 높은 예측력을 보였고 정확도 측면에서는 Random Forest가 뛰어난 것으로 분석되었다. 따라서 보행자의 부상 정도를 정확히 예측하기 위해서는 Random Forest 모형의 이용을 권장한다고 주장했다.

권경주(2021)은 교통사고는 여러 가지 요인이 복합적으로 결합하여 발생하고 있으며 기존의 분석방식은 단순 기초통계를 통한 분석으로 편중된 대책 적용을 유도하고 있다고 주장했다. 연구에서는 의사결정나무, MARS 등 다양한 데이터마이닝 기법을 적용한 사고 심각도 복합 영향요인을 도출하고자 하였다. 또한, 고속도로 교통안전 정책 수립 방향성 제시를 위한 최종 요인을 선정하였으며 이를 토대로 교통안전 정책 수립을 위한 방향성을 제시하고자 하였다.

박장우(2019)는 다양한 머신러닝 기법을 활용하여 자전거 이동 거리를 예측하는 모델을 만들고자 하였다. 분석 결과, 선형 회귀모델을 제외한 Random Forest 모형, XGBoost, 딥러닝 모델의 결과가 거의 비슷하게 나타났으나 딥러닝의 결과가 더 좋은 값을 나타낸 것으로 분석되었다. 대용량 데이터를 이용할 경우 XGBoost와 딥러닝이 GPU에서의 연산이 가능해 하이퍼 파라미터 조정 등에서 유리하다고 주장하였다.

표 2.3 머신러닝을 활용한 국내 연구

구 분		내 용
강홍식 (2022)	문 헌 명	· 앙상블 학습기법을 활용한 보행자 교통사고 심각도 분류 : 대전시 사례를 중심으로
	참고내용	· 4가지 성능지표(총 정확도, 민간도, 특이도, 정밀도)평가에 따라 기존 기계학습보다 앙상블 기법의 Ada Boost와 Random Forest 기법을 최적의 알고리즘으로 선정
권철우 (2021)	문 헌 명	· XGBoost 기법을 활용한 이륜차 교통사고 심각도 비교분석
	참고내용	· 교통사고 심각도를 EPDO로 환산하여 분석하는 방법론 제시
손승오 (2022)	문 헌 명	· 데이터마이닝 기반의 사고 심각도 가중치 적용 예측변수를 활용한 교차로 사고예측모형 개발
	참고내용	· 사고 건수를 종속변수로 설정하였으며 Random Forest와 Extreme Gradient Boosting(XGB) 방법론을 활용하여 분석
김승훈 (2021)	문 헌 명	· 머신러닝 기반의 수도권 지역 고령 운전자 차대 사람사고 심각도 분류 연구
	참고내용	· 높은 예측력의 측면에서는 로지스틱 모형과 SVM 모형이, 정확도의 측면에서는 Random Forest 모형이 뛰어난 것으로 분석됨
권경주 (2021)	문 헌 명	· 빅데이터마이닝 기반 고속도로 심각 사고 복합 영향요인 분석
	참고내용	· 변수 간 상호작용을 파악할 수 있는 의사결정나무, MARS 등의 데이터마이닝 기법을 적용하여 사고 심각도 복합 영향요인을 도출
박장우 (2019)	문 헌 명	· 서울시 공공자전거 운행 거리 예측을 위한 머신러닝 모델의 비교
	참고내용	· 선형 회귀모델, Random Forest, XGBoost, 딥러닝 모델의 예측 성능을 비교한 결과 선형회귀 모델을 제외하고 모두 뛰어난 성능을 보여줌

나. 국외 연구

Rabia Emhamed AlMamlook(2019)는 교통사고는 매년 많은 사망자와 부상자는 물론 경제적 손실을 초래하고 있어 전 세계가 직면한 가장 중요한 문제로 교통사고 심각도를 예측하는 모델은 교통시스템에 중요한 작업이라고 주장했다. 연구에서는 AdaBoost, LR(Logistic Regression), NB(Naive Bayes), RF(Random Forests)의 머신러닝 알고리즘을 활용한 사고 심각도를 분석했다. 분석 결과, Random Forest 모델이 75.5%의 정확도로 나타나 LR(74.5%), NB(73.1%), AdaBoost(74.5%) 모형보다 더 나은 정확도를 보였다고 주장했다.

Farhan Labib(2019)는 교통사고로 인한 사망사고가 세계의 사망원인 9위로 기록됨에 따라 방글라데시에서도 큰 문제임을 언급하며, 연구에서는 방글라데시에서 머신러닝 기법을 활용한 교통사고의 심각도를 보다 심층적으로 파악하고자 했다. 분석을 위해 KNN(K-Nearest Neighbors), Naive Bayes, Ada Boost의 알고리즘을 활용했고 분석 결과, Ada Boost가 가장 나은 성능을 보였다고 주장했다.

Sobhan Sarkar(2018)은 머신러닝을 활용한 산업 안전 영역에서의 사고 예측과 응용을 위한 연구가 필요하다고 주장했다. 연구는 산업재해 데이터를 활용한 부상, 아차 사고, 재산 피해 등의 사고결과 예측을 위해 최적화된 기계학습 알고리즘인 지원 벡터머신(SVM)과 인공 신경망(ANN)을 사용했다. 분석 결과, SVM은 최고 수준의 정확성과 견고성으로 다른 알고리즘보다 뛰어난 성능을 나타냈다고 주장했다.

Jonghak Lee(2019)는 교통사고 데이터를 이용한 노면 상태에 따른 사고 심각도를 추정하기 위한 연구를 진행했다. 분석을 위해 선형회귀, 로지스틱 회귀, 음이항 회귀모델 등의 전통적 통계 방법을 사용했고 전통적 통계 방법의 장단점을 분석하기 위해 Random Forest, 인공 신경망(ANN), 의사결정나무(Decision Tree) 모델을 사용했다. 분석 결과, Random Forest 모델이 가장 정확한 예측을 했고 교통사고와 상

관관계가 있는 변수를 분석한 후 Random Forest 모델을 이용한 사고 예측 모델을 구축했다.

Mireille Megnidio Tchoukouegno(2023)는 교통사고의 발생 요인을 인적요인, 도로, 차량 요소 및 환경적 요인의 네 가지로 분류했다. 연구에서는 Decision Tree, LightGBM 및 XGBoost를 사용해 2020년 영국의 도로 교통사고 심각도를 분석했다. 분석 결과, Decision Tree 모형이 가장 좋은 성능을 나타냈으며 차량 특성에 따른 교통사고 심각도를 줄이기 위해 정기적인 차량 점검, 교통정책 강화가 필요하다고 주장했다.

Imad El Mallahi(2022)는 랜덤 포레스트 모델을 이용한 교통사고 심각도 예측에 중점을 두어 연구를 수행했다. 연구에서는 교통사고 심각도를 분석하기 위해 Random Forest, Support Vector Machine(SVM), 인공 신경망(ANN) 등 기계학습의 알고리즘을 비교했다. 분석 결과, Random Forest는 93%, SVM은 82%, ANN은 87%의 정확도를 나타냈고, 정밀도 재현율 수준에서는 Random Forest는 93.82%, SVM은 82.22%, ANN은 87.88%의 정밀도를 나타내어 종합적으로 보았을 때, Random Forest 모형의 성능이 가장 우수하다고 분석했다.

표 2.4 머신러닝을 활용한 국외 연구

구 분		내 용
Rabia Emhamed AlMamlook (2019)	문헌명	· Comparison of Machine Learning Algorithms for Predicting Traffic Accident Severity
	참고 내용	· 교통사고 심각도 분석 결과 Random Forest 정확도가 75.5%로, LR(74.5%), NB(73.1%), Ada Boost(74.5%)보다 더 나은 성능을 나타냄.
Farhan Labib (2019)	문헌명	· Road Accident Analysis and Prediction of Accident Severity by Using Machine Learning in Bangladesh
	참고 내용	· 방글라데시의 교통사고 심각도 분석을 위해 KNN, NB, Ada Boost 모델을 사용한 결과 Ada Boost가 가장 나은 성능을 나타냄.
Sobhan Sarkar (2018)	문헌명	· Application of Optimized Machine Learning Techniques for Prediction of Occupational Accidents
	참고 내용	· 지원 벡터 머신(SVM)과 인공신경망(ANN)을 이용한 분석을 수행했고, 그 결과 SVM이 최고 수준의 정확성과 견고성을 나타냄.
Jonghak Lee (2019)	문헌명	· Model Evaluation for Forecasting Traffic Accident Severity in Rainy Seasons Using Machine Learning Algorithms: Seoul City Study
	참고 내용	· 교통사고 데이터에 Random Forest, ANN, Decision Tree를 적용한 결과 Random Forest가 가장 정확한 성능을 나타냄.
Mireille Megnidio Tchoukouegno (2023)	문헌명	· Machine Learning for Road Traffic Accident Improvement and Environmental Resource Management in the Transportation Sector
	참고 내용	· Decision Tree, Light GBM, XG Boost 모델 중 Decision Tree의 성능이 가장 좋은 성능을 나타냄.
Imad El Mallahi (2022)	문헌명	· Prediction of Traffic Accidents using Random Forest Model
	참고 내용	· Random Forest, SVM, ANN을 활용한 분석을 수행했고 Random Forest가 정확도(93%), 정밀도 재현율(93.82%)이 가장 우수한 성능을 나타냄.

2.4 본 연구의 차별성

선행연구 고찰결과, 교통사고의 심각성과 그로 인해 발생하는 경제적 손실 등을 무겁게 인식하여 사고심각도 분석과 관련된 다각적인 방면의 연구가 진행되고 있으며 교통안전에 대한 체계적인 계획과 정책을 수립하고 있다는 것을 알 수 있었다.

사고심각도와 관련된 상당수의 국내 연구는 음이항 회귀모형, 순서형 로짓 모형 또는 순서형 프로빗 모형과 같은 전통적인 통계기법을 활용한 분석을 진행하였다. 이와 같은 전통적인 통계기법은 교통사고와 관련된 다양한 인적, 환경적, 기하 구조적인 인과관계를 찾고 교통사고 빈도를 예측해 정해져 있는 분포나 가정에 따라 분석모형을 설정하기 때문에 현실에서의 사건을 적용하기에는 무리한 가정이 필요할 수 있다는 단점이 있다.

하지만 머신러닝과 같은 빅 데이터를 활용한 기법은 예측 성공률을 높이는 방향에 중점을 두고 있어 이종(異種)의 대량 자료를 활용하여 고속도로 교통사고 요인을 분석하는 데에 장점을 보인다. 따라서 머신러닝을 활용한 고속도로 교통사고 심각도에 대한 영향요인 분석이 필요할 것으로 판단되었다.

선행 연구고찰에 따른 본 연구의 차별성은 다음과 같다.

첫째, 본 연구에서는 공간적 범위를 특정한 하나의 고속도로 노선 또는 여러 노선을 각각의 비교군으로 하여 분석을 진행하는 것이 아니라 전국 고속도로 노선 중 교통사고 다발 지역 상위 노선 10개를 지정하여 연구를 진행하였다.

둘째, 교통사고 당사자들의 모든 사고내용을 포함하여 고속도로 사고의 심각도를 분석하고자 대물 피해 환산계수인 EPDO로 환산하여 분석을 진행하였다.

셋째, TAAS에서 제공하고 있는 고속도로 교통사고 자료는 1차 자료(Primary Sources)[10]이면서 범주형 자료[11]로 구성되어 있어 자료의 질적인 측면과 정확도를

[10] 1차 자료(Primary Sources) : 연구를 위해 조사자가 직접 수집 및 작성한 원형 그대로의 자료를 의미함.

높이기 위해 콘 존의 기하구조 정보와 매칭하였다. 따라서, 범주형 자료와 수치형 자료를 함께 분석할 수 있도록 2차 자료(Secondary data)[12]의 형태로 가공하여 분석을 진행하였다.

넷째, 변수에 무리한 가정과 조건이 필요할 수 있는 전통적 통계기법이 아닌 다양한 변수를 포함한 빅 데이터를 분석할 수 있는 머신러닝을 활용한 사고 심각도 분석을 진행하였다.

다섯째, 다수의 선행연구에서는 머신러닝 모델을 사고 데이터의 특성과 모델의 적합성을 비교·분석 후 모델을 선정하여 분석을 진행하는 반면, 본 연구에서는 PyCaret[13]을 활용해 여러 가지 머신러닝 모델 중 최적의 머신러닝 모델을 선정하였고, 선정된 모델을 활용한 고속도로 교통사고 심각도 영향요인 분석을 진행하였다.

---

11) 범주형 자료(Categorical data) : 수치로 측정이 불가한 자료를 의미. 성별, 지역, 혈액형 등이 있음

12) 2차 자료(Secondary data) : 1차 자료를 활용, 이를 수정하고 가공한 자료를 의미함.

13) PyCaret : AutoML을 하게 해주는 라이브러리로 적은 코드로 머신러닝 워크플로우를 자동화해주어 머신러닝 모델 개발 시 코딩, 전처리, 모델선택, 파라미터 튜닝 작업 등을 자동화해주어 높은 생산성의 작업을 가능하게 함.

제 3 장 자료수집 및 기술통계분석

3.1 분석 개요

고속도로 교통사고의 심각도 분석을 위해 다음과 같은 과정을 통해 자료의 수집 및 가공을 하고 기술통계분석을 실시하였다.

첫째, TAAS에서 제공하는 2019년부터 2021년까지의 전국 고속도로 교통사고 자료를 수집했으며 그림 3.1과 같은 전국 고속도로 교통사고 노선 중, 경부고속도로 교통사고에 대한 데이터를 나타낸 자료이다.

TAAS의 자료에는 사고지점의 위치 좌표를 포함하지 않아 Q-GIS를 활용해 전국 고속도로 교통사고 개별 데이터에 위치 좌표를 매칭하였다. 이후 분석을 위해 한국도로공사에서 관리 중인 고속도로와 민자 고속도로를 기준으로 전국 고속도로 노선에서 발생한 교통사고 자료 중 전체의 71.1%를 차지하고 있는 10개 노선을 선정하였다.

둘째, 한국도로공사에서 제공하는 고속도로 안전성능함수 구축 단위인 콘 존(Conzone) 자료와 콘 존 전자지도(Shp) 파일을 수집했고 콘 존 자료 중 분석에 활용할 변수를 선정한 후 가공하여 콘 존 마스터 테이블로 구축하였다. 이때 선정된 연속형 변수는 해당 고속도로의 차로 수, 제한속도, 곡선반경 길이의 평균 및 종단경사 데이터이다.

셋째, 콘 존의 전자지도(Shp) 파일에는 콘 존의 노선별 위치 좌표와 콘 존 ID가 포함되어 있어 Q-GIS를 활용해 TAAS의 고속도로 교통사고 개별 데이터와 콘 존 ID를 매칭하였다.

넷째, 가공된 모든 데이터를 하나의 데이터로 만들기 위해 콘 존 ID를 기준으로 전국 고속도로 교통사고 자료와 콘 존 마스터 테이블을 결합했으며 이렇게 가공된 자료로 고속도로 교통사고 심각도에 영향을 끼치는 요인과 상관관계를 분석하는 데

에 활용하고자 한다.

이후 전국 고속도로 현황을 살펴보고 독립변수와 종속변수를 선정하였다. 독립변수로는 EPDO, 종속변수는 TAAS에서 구득한 범주형 변수와 콘 존 데이터의 수치형 변수로 이루어져 있다. 범주형 변수를 수치형 데이터로 변환하기 위해 원-핫 인코딩 방식(One Hot Encoding)방식을 사용했으며, 사고요인별 기술통계분석은 SPSS 28.0을 활용하였다.

또한, 독립변수가 종속변수인 EPDO에 영향을 미치는 정도에 차이가 있는지에 대한 통계적 확인을 위해 SPSS를 활용해 전통적 통계 분석방법으로 가설 설정과 검증을 하고자 했으며, 검증에는 독립표본 t-검정(Independent Samples t-test)과 일원배치 분산분석(One-way ANOVA)을 사용하였다.

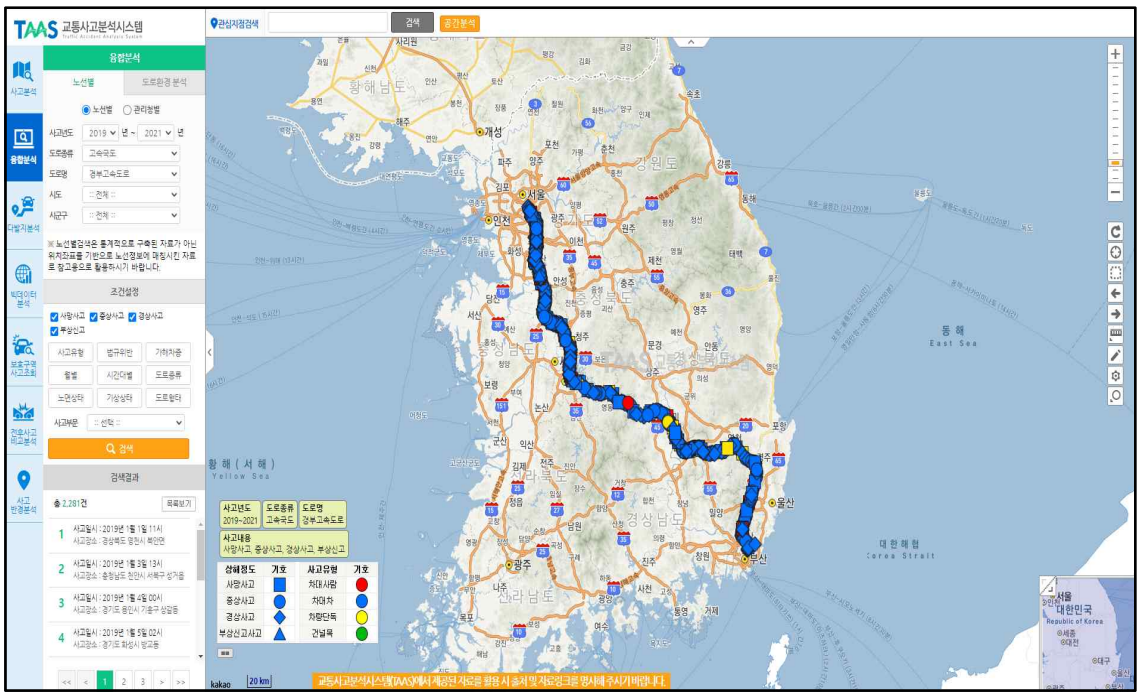


그림 3.1 TAAS 경부고속도로 교통사고 분석 예시 화면

고속도로 사고 자료수집
전국 고속도로 교통사고 중 사고 다발 10위 노선 지정
공간 연산을 통한 자료 가공
콘 존(Conzone) 데이터 가공

⇩

전국 고속도로 기초현황
고속도로 연도별 연평균일교통량
전국 고속도로 교통사고 현황

⇩

변수 선정	
독립변수	종속변수
EPDO	TAAS의 범주형 자료 및 콘 존 데이터의 수치형 자료

⇩

변수 전처리
원-핫 인코딩 방식(One Hot Encoding)

⇩

사고요인별 기술통계분석
SPSS 활용

⇩

가설 설정 및 검증
독립표본 t-검정(Independent Samples t-test)
일원 배치 분산분석(One-way ANOVA)

그림 3.2 자료수집 및 기술통계분석 개요

3.2 분석자료 수집

3.2.1 전국 고속도로 교통사고 중 사고 다발 10위 노선 지정

본 연구는 2021년도 개통이 완료된 전국의 고속도로 노선에서 발생한 교통사고 중 2019년부터 2021년(3개년)의 교통사고 건수가 가장 많은 1위부터 10위까지의 노선을 대상으로 분석을 진행하였다. 이때, 고속도로의 노선은 한국도로공사에서 관리 중인 고속도로와 민자 고속도로를 기준으로 하였다.

표 3.1에서 보이는 바와 같이, 전국 고속도로 교통사고 상위 노선은 경부고속도로 3,149건, 영동고속도로 1,349건, 서해안고속도로 1,028건, 남해고속도로 744건, 수도권제1순환고속도로 663건, 중부고속도로 593건, 중부내륙고속도로 496건, 중앙고속도로 494건, 호남고속도로 420건, 서울양양고속도로 394건으로 10개의 노선에서만 총 9,330건의 교통사고가 발생했으며 이는 3년간 13,130건의 전국의 고속도로 교통사고 중 71.1%를 차지하는 수치이다.

연구에서는 내용 미기입 등과 같은 결측치를 제외하고 최종적으로 9,227건을 모형분석에 활용하였다.

표 3.1 2019-2021년 전국 고속도로 교통사고 발생건수

(건/%)

순 위	노 선 명	사고건수	전체 사고범위
1	**경부고속도로**	3,149	24.0
2	**영동고속도로**	1,349	34.3
3	**서해안고속도로**	1,028	42.1
4	**남해고속도로**	744	47.8
5	**수도권제1순환고속도로**	663	52.8
6	**중부고속도로**	593	57.3
7	**중부내륙고속도로**	496	61.1
8	**중앙고속도로**	494	64.9
9	**호남고속도로**	420	68.1
10	**서울양양고속도로**	394	71.1
11	제2경인고속도로	352	73.8
12	논산천안고속도로	309	76.1
13	평택제천고속도로	267	78.1
14	경인고속도로	240	80.0
15	당진영덕고속도로	224	81.7
16	남해고속도로제2지선	216	83.3
17	용인서울고속도로	205	84.9
18	수도권제2순환고속도로	159	86.1
19	중부내륙고속도로지선	152	87.3
20	동해고속도로	151	88.4
21	남해고속도로제1지선	142	89.5
22	평택시흥고속도로	115	90.4
23	통영대전고속도로	112	91.2
24	새만금포항고속도로	98	92.0
25	광주원주고속도로	90	92.6

[표계속]

(건/%)

순 위	노 선 명	사고건수	전체 사고범위
26	인천국제공항고속도로	87	93.3
27	호남고속도로지선	83	93.9
28	제2중부고속도로	81	94.6
29	상주영천고속도로	80	95.2
30	평택시흥고속도로	80	95.8
31	평택화성고속도로	80	96.4
32	중앙고속도로지선	72	96.9
33	광주대구고속도로	70	97.4
34	순천완주고속도로	65	98.0
35	부산외곽순환고속도로	58	98.4
36	무안광주고속도로	47	98.8
37	울산고속도로	26	99.0
38	대전남부순환고속도로	23	99.1
39	서천공주고속도로	23	99.3
40	고창담양고속도로	22	99.5
41	서울문산고속도로	18	99.6
42	남해고속도로제3지선	16	99.7
43	오산화성고속도로	13	99.8
44	옥산오창고속도로	10	99.9
45	함양울산고속도로	7	100
46	세종포천고속도로	6	100
47	인천대교고속도로	1	100
합 계		13,130	-

3.2.2 공간 연산을 통한 데이터 가공

고속도로 노선의 사고분석을 위해서는 정확한 위치 정보가 필요하나 ‘TAAS’에서 제공하는 데이터에는 위치 좌표를 제공하고 있지 않다. 따라서 TAAS에서 구득한 고속도로 노선의 교통사고 자료를 Q-GIS를 활용하여 사고지점의 X, Y 좌표를 모두 수집하였다.

이후, 그림 3.2와 같이 콘 존의 노선별 위치 좌표와 콘 존 ID가 포함된 전자지도 파일(Shp)[14]을 활용하여 공간 연산을 수행하였다. 고속도로 교통사고 상위 10개 노선의 개별 데이터와 각각의 콘 존 데이터를 모두 결합하여 고속도로 교통사고 심각도에 영향을 줄 수 있는 지표를 마련하고자 하였다.

그림 3.3은 노선별 고속도로 교통사고 발생 지점과 콘 존 전자지도(Shp) 파일을 결합한 데이터 예시이다. 이때, 분석의 정확도를 높이기 위해 10개의 노선을 하나씩 분류하여 데이터 가공을 진행하였다.

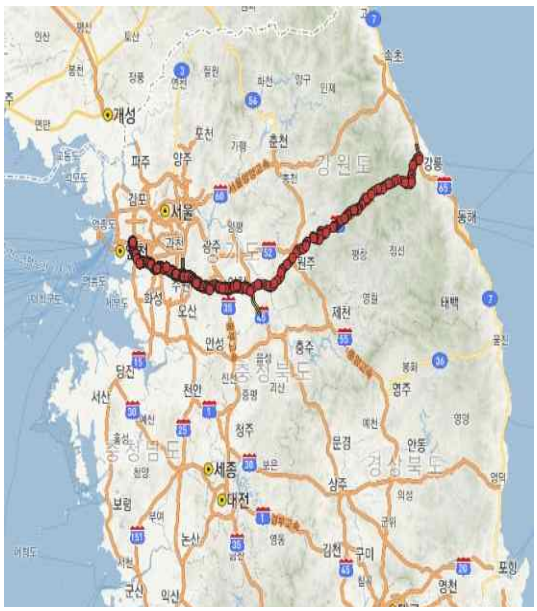
14) 전자지도 파일(Shapefile) : Shp 파일은 지리 정보 시스템(GIS) 소프트웨어를 위한 지리 공간 벡터 데이터 형식으로 점, 선, 다각형과 같은 벡터 기능을 공간적으로 설명할 수 있음



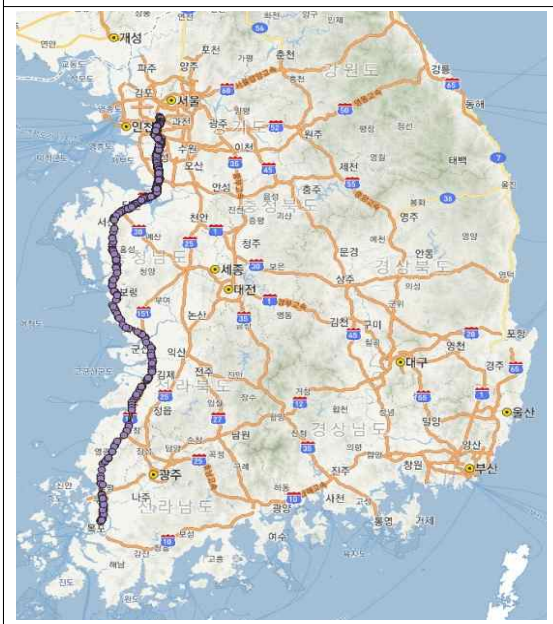
그림 3.2 Q-GIS를 활용한 고속도로 교통사고 결합 예시



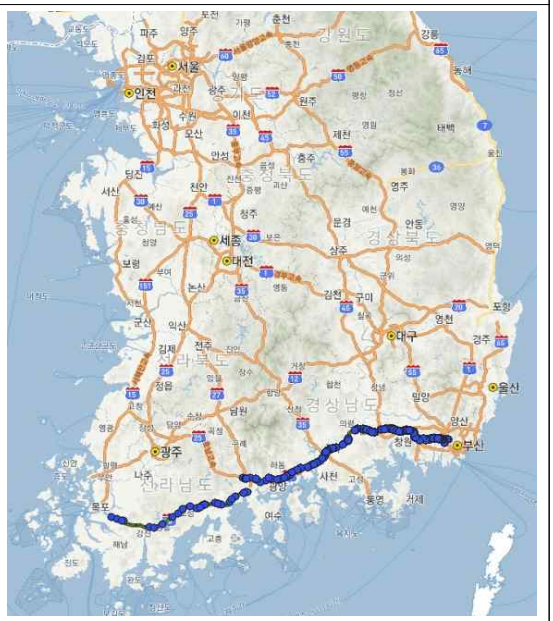
(a) 경부고속도로



(b) 영동고속도로



(c) 서해안고속도로



(d) 남해고속도로

그림 3.3 고속도로 교통사고 개별 데이터 예시

3.2.3 콘 존(Conzone) 데이터 가공

본 연구에서는 기존의 문헌 고찰을 바탕으로 교통사고에 영향을 주는 변수를 선정하여 한국도로공사에서 제공하는 고속도로 공공데이터 포털에서 고속도로 콘 존 데이터를 수집했으며 그림 3.4와 같다.

여기서 사용된 안전성능함수 구축 단위인 '콘 존(Conzone)'은 한국도로공사에서 고속도로 구간을 IC, Jct, TG 등 통행하는 차량의 수가 일정한 고속도로 구간으로 분류한 개념을 의미한다. 수집된 자료들은 콘 존(Conzone) 단위로 되어있는 자료와 그렇지 않은 자료들이 혼재하기 때문에 콘 존(Conzone) 단위로의 가공이 필요하다.

	콘존ID	콘존길이	기점종점방향구분코드	시작노드ID	종료노드ID	차로수	노선번호	제한속도	노선구성순번	콘존명	버스전용차로유무	도로등급구분코드
0	0010CZE005	200.0	E	491	4	3.0	10	100.0	1.0	경부고속국도시점-구서IC	0	101
1	0010CZE010	1820.0	E	4	446	3.0	10	100.0	2.0	구서IC-영락IC	0	101
2	0010CZE011	1990.0	E	446	486	3.0	10	100.0	3.0	영락IC-부산TG	0	101
3	0010CZE020	1070.0	E	486	447	3.0	10	100.0	4.0	부산TG-노포	0	101
4	0010CZE030	7780.0	E	447	669	3.0	10	100.0	5.0	노포IC-노포JC	0	101
...	...	...	...	...	...	...	...	...	...	...	...	...
1569	6000CZS050	1770.0	S	668	667	2.0	6000	100.0	5.0	김해가야Hi-대감JC	0	101
1570	6000CZS060	9920.0	S	669	668	2.0	6000	100.0	4.0	노포JC-김해가야Hi	0	101
1571	6000CZS070	1100.0	S	670	669	2.0	6000	100.0	3.0	금정IC-노포JC	0	101
1572	6000CZS080	4240.0	S	671	670	2.0	6000	100.0	2.0	기장철마IC-금정IC	0	101
1573	6000CZS090	5580.0	S	445	671	2.0	6000	100.0	1.0	기장JC-기장철마IC	0	101

그림 3.4 콘 존(Conzone) 데이터 예시

또한, 본격적인 고속도로 사고분석을 위해 가공된 데이터를 하나의 데이터로 만드는 과정이 필요하다. 이를 콘 존 마스터 테이블로 가공했으며 그림 3.5와 같다.

범주형 변수 이외에 고속도로 교통사고에 영향을 줄 수 있는 연속형 변수로 차로 수, 제한속도, 곡선반경 길이의 평균과 종단경사를 채택했다. 이후, 콘 존 Key 값(콘 존ID와 동일)을 기준으로 개별사고 데이터와 모두 결합하여 사고 심각도를 분석하고자 하였다.

사고번호	사고일시	년	월	일	요일	주중/주말	계절	주/야	사고발생시	...	노면상태2	road_no	route_nm	otn_acdnt_	KEY	NAME	차로수	제한속도	곡선반경길이평균	종단경사
0190130001001 50	2019년 1월 30일	2019	1	30	수요일	주중	겨울	주간	10시	...	건조	1	경부고속도로	20190001411240	0010CZS070	양재JC-서울산IC	3.0	100.0	2770	0.005831
0190713000100090	2019년 7월 13일	2019	7	13	토요일	주말	여름	주간	06시	...	건조	1	경부고속도로	20190009311240	0010CZS070	양재JC-서울산IC	3.0	100.0	2770	0.005831
0190922001002 50	2019년 9월 22일	2019	9	22	일요일	주말	가을	주간	14시	...	젖음/습기	1	경부고속도로	20190014221240	0010CZS070	양재JC-서울산IC	3.0	100.0	2770	0.005831
0191025001004 10	2019년 10월 25일	2019	10	25	금요일	주중	가을	주간	15시	...	건조	1	경부고속도로	20190017601240	0010CZS070	양재JC-서울산IC	3.0	100.0	2770	0.005831
0190324001000 60	2019년 3월 24일	2019	3	24	일요일	주말	봄	야간	02시	...	건조	1	경부고속도로	20190003981240	0010CZE070	서울산IC-양재JC	3.0	100.0	2770	0.5831
0190806001005 40	2019년 8월 6일	2019	8	6	화요일	주중	여름	야간	19시	...	젖음/습기	1	경부고속도로	20190011061240	0010CZE070	서울산IC-양재JC	3.0	100.0	2770	0.5831
0191014001002 90	2019년 10월 14일	2019	10	14	월요일	주중	가을	주간	12시	...	건조	1	경부고속도로	20190015661240	0010CZE070	서울산IC-양재JC	3.0	100.0	2770	0.5831
0191124001003 10	2019년 11월 24일	2019	11	24	일요일	주말	가을	주간	16시	...	건조	1	경부고속도로	20190018631240	0010CZE070	서울산IC-양재JC	3.0	100.0	2770	0.5831
0190628001004 80	2019년 6월 28일	2019	6	28	금요일	주중	여름	주간	17시	...	건조	1	경부고속도로	20190008541240	0010CZS060	서울JC-통도사IC	3.0	100.0	4689.655172	0.073142
0190720001001 10	2019년 7월 5일	2019	7	5	금요일	주중	여름	주간	16시	...	건조	1	경부고속도로	20190009291240	0010CZS060	서울JC-통도사IC	3.0	100.0	4689.655172	0.073142

그림 3.5 콘 존 마스터 테이블을 활용한 고속도로 교통사고 데이터 예시

3.3 전국 고속도로 현황 및 기술통계분석

교통사고의 발생은 운전자 요인, 보행자 요인, 차량 요인, 도로 선형 및 도로·환경적 요인 등의 다양한 요인이 매우 복합적으로 작용하여 발생한다. 따라서 본 절에서는 교통사고의 통계적 비교·분석을 중심으로 고속도로 교통사고의 원인과 특성을 파악하고자 한다.

본 연구의 고속도로별 교통사고 현황, 사고 건수, 사망자 수, 부상자 수 등의 통계자료는 도로교통공단의 교통사고분석시스템(Traffic Accident Analysis System, TAAS)에서 제공하는 자료를 활용하였으며 전국 고속도로 교통사고의 종합적인 분석을 위해 2019년부터 2021년까지 TAAS에서 구득이 가능한 최근 3년간의 전국 고속도로 교통사고 현황 추이를 파악하고자 한다.

3.3.1 고속도로 연도별 연평균일교통량

고속도로에서 발생하는 교통사고를 분석하기 위해 각각의 고속도로 노선의 교통량을 수집하여 고속도로 통행량과 교통사고의 관계를 예측하는 것이 필요하다.

표 3.2는 한국도로공사의 고속도로 공공데이터 포털에서 제공하고 있는 연평균일 교통량(AADT)[15] 자료를 수집하여 2019년부터 2021년의 연평균일교통량을 분석하였으며, 고속도로 노선은 2021년 조사 시점까지 개통이 완료된 노선을 기준으로 분석하였다.

고속도로 사고 다발 노선으로 선정된 10개 노선의 연평균일교통량을 분석한 결과 경부고속도로(416.05km)의 교통량이 가장 많았고, 다음으로 수도권제1순환고속도로(91.7km), 영동고속도로(234.4km), 서해안고속도로(346.1km), 남해안고속도로(340.8km), 중부고속도로(332.5km), 중부내륙고속도로(301.7km), 중앙고속도로(288.8km), 호남고속도로(194.2km), 서울양양고속도로(88.8km)의 순서로 교통량이 많은 것으로 나타났다.

이 중 수도권제1순환고속도로는 노선의 길이가 다른 노선과 비교해 길지 않음에도 불구하고 연평균일교통량이 고속도로 노선 중 두 번째로 많은 것으로 나타나 노선 길이 대비 교통량이 많다는 것을 알 수 있었다.

또한, 수도권제1순환고속도로를 제외한 나머지 노선의 연평균일교통량의 순위와 전국 고속도로 교통사고 다발지역 노선의 순위가 일치하는 것으로 분석되어 고속도로 교통량이 교통사고 발생에 영향을 미치는 것으로 해석되었다.

---

15) 연평균일교통량(Annual Average Daily Traffic, AADT) : 연간 총 교통량을 365로 나눈 값(도철웅, 2014)

표 3.2 2019-2021년 고속도로 연평균일교통량

(단위 : km, 대/일)

구 분		연평균 일교통량		
노 선 명	구간길이	2019년	2020년	2021년
경부고속도로	416.05	5,657,494	5,903,670	6,088,435
영동고속도로	234.4	3,028,224	3,336,403	3,495,972
서해안고속도로	346.1	2,397,168	2,504,289	2,661,224
남해안고속도로	340.8	2,079,554	2,211,642	2,289,173
수도권제1순환고속도로	91.7	4,756,533	4,940,928	5,244,667
중부고속도로	332.5	1,955,027	2,108,507	2,138,605
중부내륙고속도로	301.7	1,167,824	1,247,915	1,261,574
중앙고속도로	288.8	1,156,045	1,252,858	1,243,690
호남고속도로	194.2	1,508,954	1,611,779	1,604,967
서울양양고속도로	88.8	934,955	970,997	1,010,887

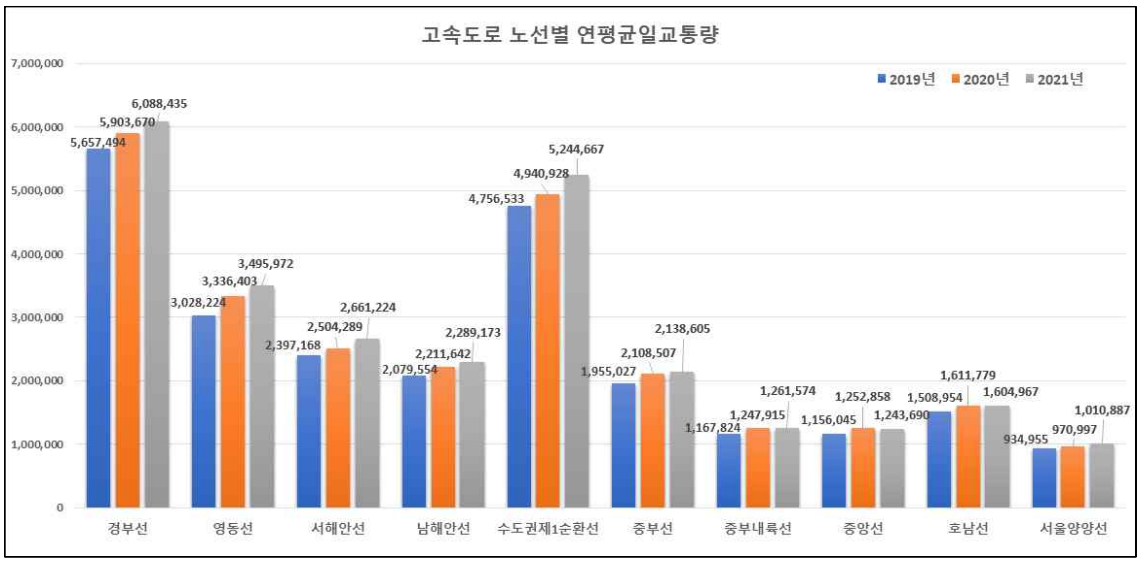


그림 3.6 고속도로 노선별 연평균일교통량 현황

3.3.2 전국 고속도로 교통사고 현황

가. 전국 고속도로 교통사고 추세

본 연구의 시간적 범위인 2019년부터 2021년까지 전국의 고속도로 교통사고 현황은 아래의 표 3.3과 같다. 전국의 고속도로 교통사고는 2019년 4,223건, 2020년 4,039건, 2021년 4,883건으로 3년간 총 13,145건의 교통사고가 발생하였다. 2019년 대비 2020년의 사고 발생 건수는 -4.4% 감소하였는데 2021년의 사고 발생 건수는 2020년과 비교하여 20.9% 대폭 증가한 것으로 나타났다.

부상자 수는 2019년 9,521명, 2020년 8,389명, 2021년 9,708명으로 나타났다. 이는 2020년 기준, 전년 대비 -11.9%로 감소하는 추세를 보였으나, 2021년 기준, 전년 대비 15.7% 증가한 것으로 나타났다.

또한, 교통사고로 인한 사망자는 2019년 206명, 2021년 223명, 2022년 191명으로 분석되었다. 이는 2020년엔 전년 대비 8.3% 증가, 2021년엔 전년 대비 -14.3% 감소한 수치로 나타나 교통사고 건수와 그로 인한 부상자 수는 증가하였지만, 사망자 수는 소폭 감소한 것으로 분석되었다.

표 3.3 전국 고속도로 교통사고 연도별 발생 건수, 사망자 수 및 부상자 수

구 분	사고건수		부상자수		사망자수	
	(건)	전년대비 증감률(%)	(명)	전년대비 증감률(%)	(명)	전년대비 증감률(%)
2019	4,223	3.5	9,521	6.8	206	-18.3
2020	4,039	-4.4	8,389	-11.9	223	8.3
2021	4,883	20.9	9,708	15.7	191	-14.3
평 균	4,382	6.67	9,206	3.5	207	-8.1

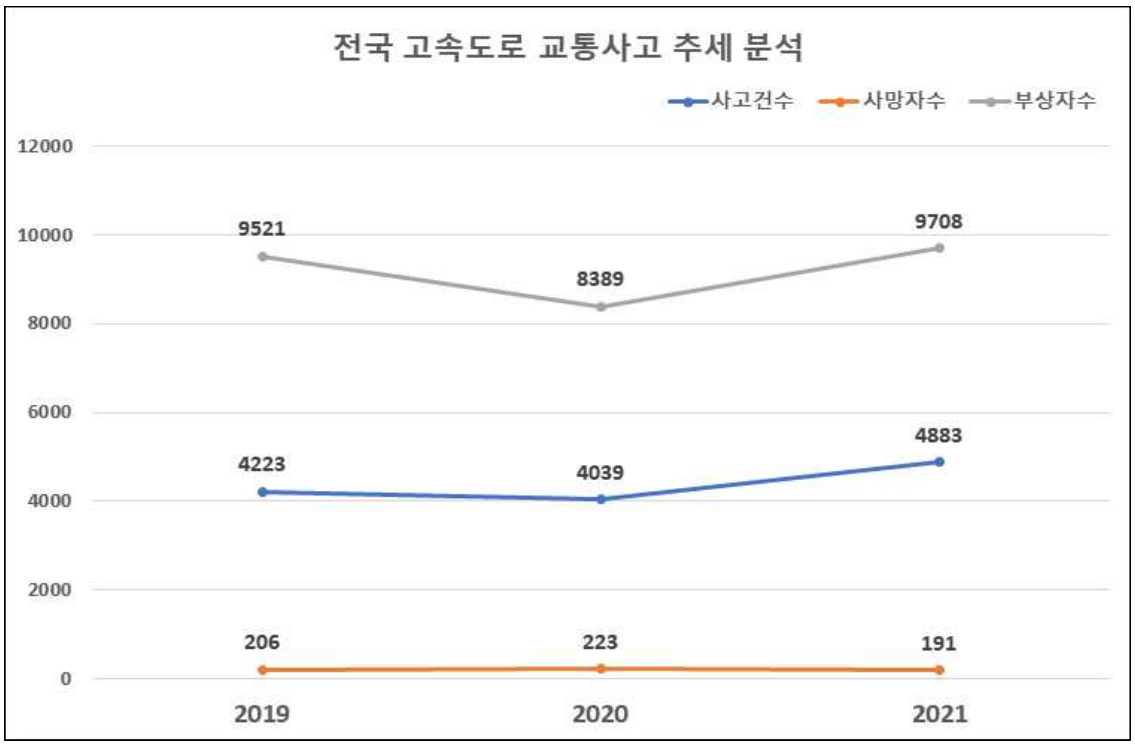


그림 3.7 전국 고속도로 교통사고 추세 분석

나. 시・도별 고속도로 교통사고 추세

2019년부터 2021년까지 전국의 시・도별 고속도로 교통사고 현황을 분석한 자료는 표 3.4와 같다. 시・도별 고속도로 사고 건수는 대부분의 시・도에서 증가하는 추세로 나타났다. 신규 노선의 신설로 교통사고 데이터가 충분치 않은 세종을 제외한 2019년, 2020년 대비 2021년도의 교통사고 건수 증감률은 인천 15.8%, 경북 14.9%, 경기도 13.9%, 서울 13.7%, 대구 11.3%, 부산 11.2%, 강원 8.4%, 충남 0.9% 증가추세를 보였고, 대전 -0.9%, 충북 -7.5%, 경남 -7.9%, 전북 -15.6%, 전남 -18.4%, 울산 -21.1%로 2021년의 교통사고 건수가 2019년, 2020년과 비교해 감소하는 추세를 보이며 그림 3.8에 나타난 바와 같다.

시・도별 고속도로 교통사고 사망자 수는 그림 3.9와 같으며, 광주의 사망자 수는 3년간 1명으로 증감률에 의미가 없다. 세종시 또한 2021년 신설된 노선으로 2019년, 2020년의 사망자 발생이 없었다. 두 노선을 제외한 나머지 노선은 부산 164.6%, 전북 22.5%, 충북 12.4%, 경북 5.6%로 사망자가 증가하는 추세를 보였고 강원 -5.1%, 경기 -8.3%, 충남 -14%, 경남 -15%, 대전 -29.3%, 전남 -34.5%, 대구 -42.3%로 2019년, 2020년 대비 2021년의 사망자 수가 감소하는 추세를 보였다.

시・도별 고속도로 교통사고 부상자 수 현황은 그림 3.10과 같다. 위에 설명한 바와 같이, 2021년 신설된 세종시의 노선은 데이터가 충분치 않아 제외하고 2019년, 2020년과 비교해 2021년의 부상자 수는 대구 11.7%, 경북 10.4%, 부산 9.6%, 인천 8.9%, 강원 8.5%, 경기 6.5%로 증가하는 추세를 보였고, 충남 -3.6%, 서울 -3.9%, 대전 -7.6%, 광주 -7.9%, 충북 -13.8%, 전남 -14.1%, 경남 -14.6%, 울산 -17.7%, 전북 -27.3%로 나타나 감소하는 추세를 보였다.

시・도별 고속도로 교통사고 건수는 대부분 지역에서 증감을 반복하고 있다. 또한, 사고 증감률이나 증감률의 평균 수치는 분석 시점의 기준을 어디에 두는지에 따

라 그 수치가 달라질 수 있다. 따라서 연구자가 설정한 시·공간적 배경에 따라 사고 증감률에 대한 해석이 달라질 수 있음을 고려해야 한다.

교통사고로 인한 사망자 수는 감소하는 추세로 나타나기는 하지만 그 정도가 눈에 띄는 수준이 아니고 전국의 고속도로 교통사고 건수와 그로 인한 부상자 수는 증가하는 추세를 보여 고속도로 교통사고 감소를 위한 개선의 여지가 많이 남아있다는 것을 알 수 있다.

표 3.4 시·도별 고속도로 교통사고 현황

구분	2019			2020			2021		
	사고건수 (건)	사망자수 (명)	부상자수 (명)	사고건수 (건)	사망자수 (명)	부상자수 (명)	사고건수 (건)	사망자수 (명)	부상자수 (명)
계	4,223	206	9,521	4,039	223	8,389	4,883	191	9,708
서울	120	3	323	137	1	279	155	3	298
부산	89	1	179	71	0	120	110	7	215
대구	147	15	310	130	9	253	182	5	387
인천	229	7	394	254	8	402	307	7	467
광주	50	0	99	57	1	130	50	0	84
대전	59	4	110	56	4	107	58	2	94
울산	53	2	99	32	6	49	33	0	67
세종	3	0	3	0	0	0	7	7	12
경기	1,880	63	4,174	1,946	60	4,150	2,440	53	4,732
강원	160	10	416	124	13	242	188	9	490
충북	284	19	783	214	22	573	243	24	582
충남	282	23	653	259	23	613	287	17	607
전북	108	8	291	106	20	243	77	12	154
전남	135	7	275	111	5	232	90	3	203
경북	269	26	585	269	32	471	355	29	713
경남	355	18	827	273	19	525	301	13	603

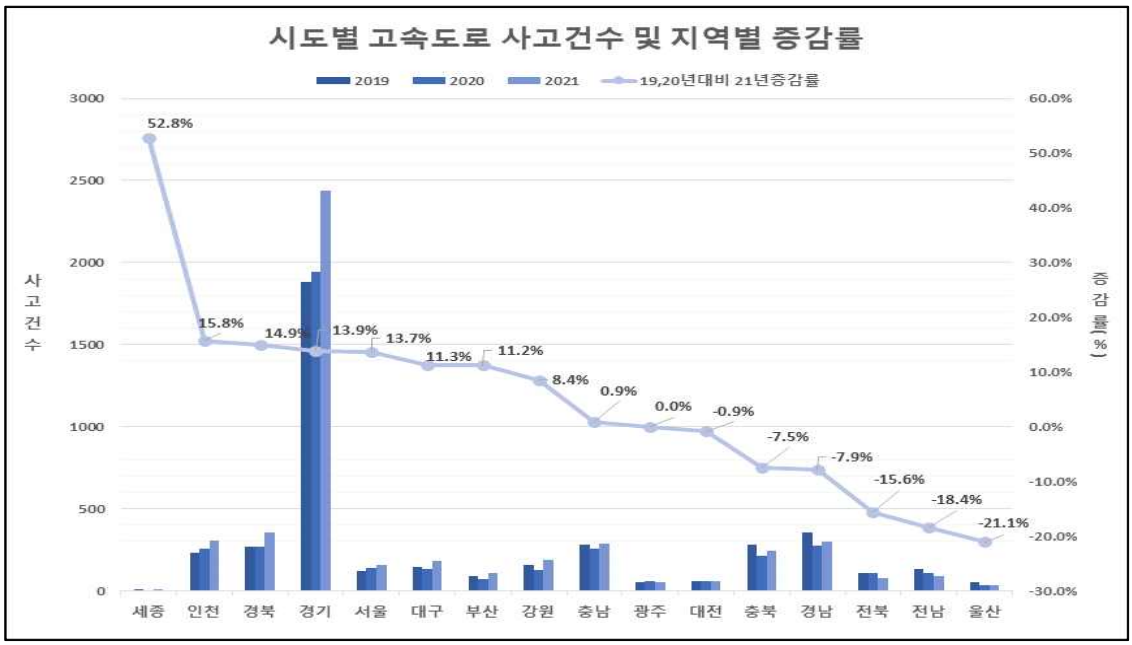


그림 3.8 시도별 고속도로 사고건수 및 지역별 증감률 현황

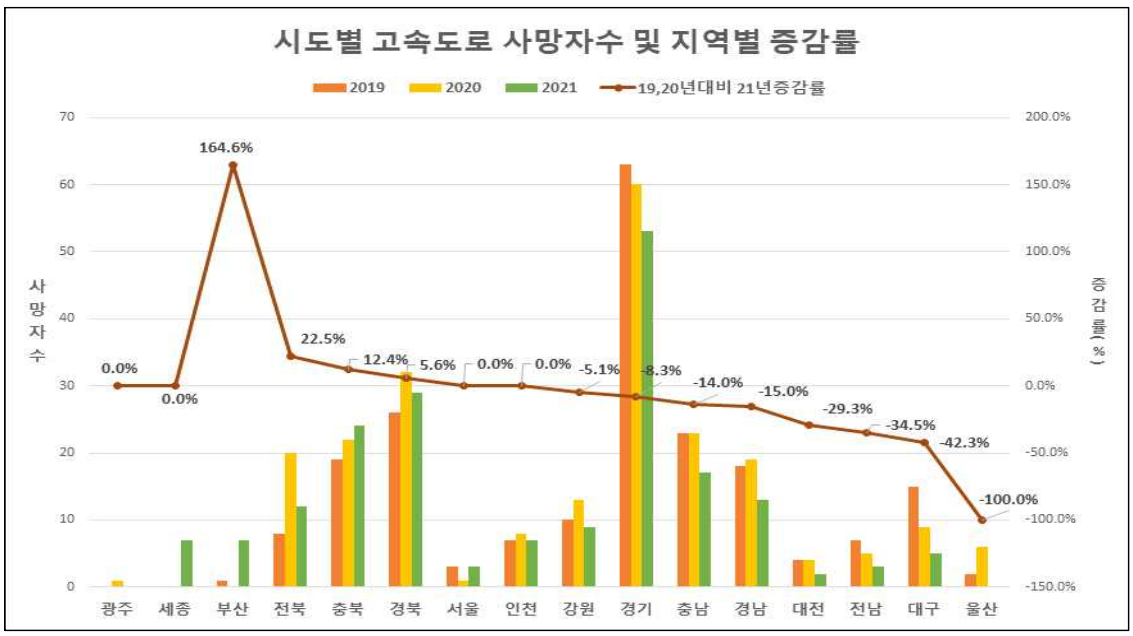


그림 3.9 시도별 고속도로 사망자수 및 지역별 증감률 현황

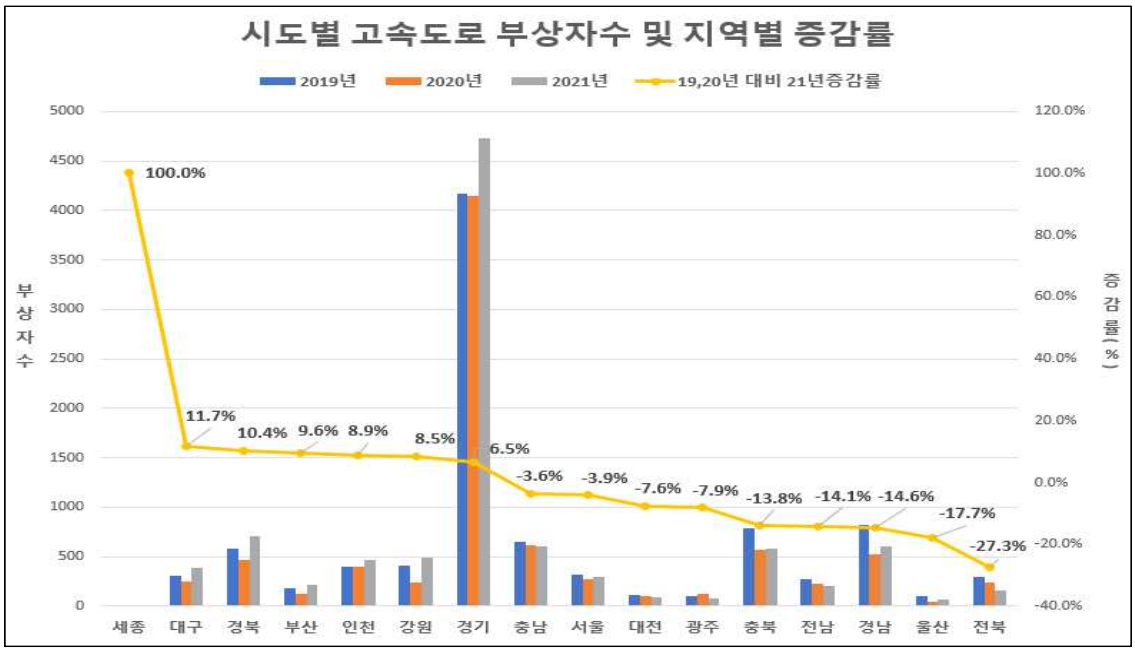


그림 3.10 시도별 고속도로 부상자수 및 지역별 증감률 현황

3.3.3 고속도로 교통사고 일반현황

가. 고속도로 교통사고 위치별 현황

2019년부터 2021년 3년간의 고속도로 교통사고 위치별 현황은 그림 3.11과 같다. 고속도로 교통사고는 도로 특성상 주행차로에서의 사고 발생이 13,145건 중 9,315건으로 가장 많이 발생하고 있는 것으로 나타났으며 앞지르기 차로(1,183건), 톨게이트(TG) 부근(1,064건), 유입/유출로(724건), 휴게소(408건)의 교통사고 발생 건수가 평균보다 높게 나타난 것으로 분석되었다.

표 3.5에서는 연도별 고속도로 사고 위치별 현황을 나타냈다. 3년 평균 주행차로(3,105건), 앞지르기차로(394.3건), 톨게이트(354.7건), 유입/유출로(241.3건)의 순서로 사고 발생이 많이 나타났다. 또한, 고속도로 사고 위치별 사망자 현황은 표 3.7과 같이 주행차로(156.3건)에서 가장 많이 발생했고, 앞지르기차로(20건), 갓길(8.7건), 유입/유출로(7.7건)의 순서로 높게 나타났다.

또한, 표 3.8에서 나타난 것과 같이 갓길에서 발생하는 교통사고의 치사율이 27.9%로 나타나 고속도로 평균 치사율보다 약 6.2배 높게 분석되었다.

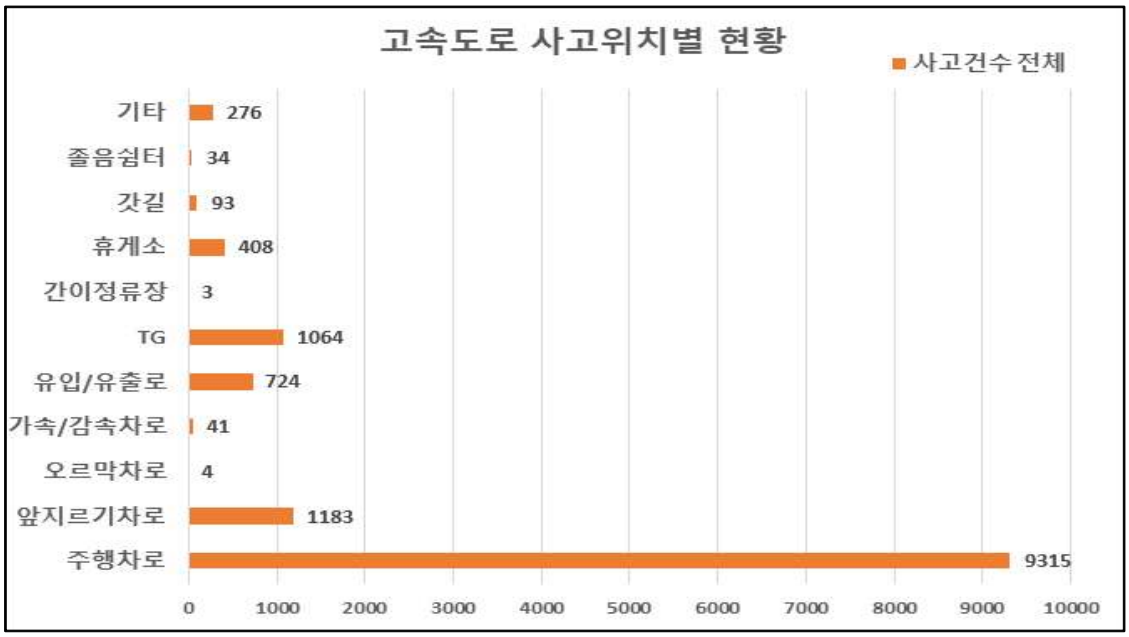


그림 3.11 2019년-2021년 고속도로 교통사고 위치별 현황

표 3.5 연도별 고속도로 사고 위치별 현황 (단위 : 건)

구분	고속도로 교통사고 사고 위치별 현황										
	주행 차로	앞지르 기차로	오르막 차로	가・감 속차로	유입/ 유출로	TG	간이 정류장	휴게소	갓길	졸음 쉼터	기타
2019	3,064	376	0	0	189	316	0	146	41	0	91
2020	2,853	359	0	0	228	346	0	125	21	12	95
2021	3,398	448	4	41	307	402	3	137	31	22	90
평균	3,105	394.3	1.3	13.7	241.3	354.7	1	136	31	11.3	92

표 3.6 고속도로 사고 위치별 부상자 현황 (단위 : 건)

구분	고속도로 교통사고 사고 위치별 부상자 현황										
	주행 차로	앞지르기 차로	오르막 차로	가·감속 차로	유입/ 유출로	TG	간이 정류장	휴게소	갓길	졸음 쉼터	기타
2019	7,125	1,068	0	0	329	519	0	206	79	0	195
2020	6,121	939	0	0	398	550	0	195	39	15	132
2021	6,860	1,182	6	86	465	647	7	224	43	37	151
평균	6,702	1,063	2.0	28.7	397.3	572	2.3	208.3	53.7	17.3	159.3

표 3.7 고속도로 사고 위치별 사망자 현황 (단위 : 건)

구분	고속도로 교통사고 사고 위치별 사망자 현황										
	주행 차로	앞지르기 차로	오르막 차로	가·감속 차로	유입/ 유출로	TG	간이 정류장	휴게소	갓길	졸음 쉼터	기타
2019	156	19	0	0	8	2	0	3	12	0	6
2020	172	26	0	0	6	3	0	2	6	2	6
2021	141	15	0	1	9	5	0	2	8	0	10
평균	156.3	20	0	0.3	7.7	3.3	0	2.3	8.7	0.7	7.3

표 3.8 고속도로 사고 위치별 치사율 현황 (단위 : %)

구분	고속도로 교통사고 사고 위치별 치사율 (사고 100건당 사망자 수)										
	주행 차로	앞지르기 차로	오르막 차로	가・감속 차로	유입/ 유출로	TG	간이 정류장	휴게소	갓길	졸음 쉼터	기타
2019	5.1	5.1	0.0	0.0	4.2	0.6	0.0	2.1	29.3	0.0	6.6
2020	6	7.2	0	0	2.6	0.9	0	1.6	28.6	16.7	6.3
2021	4.1	3.3	0.0	2.4	2.9	1.2	0.0	1.5	25.8	0.0	11.1
평균	5.1	5.2	0.0	0.8	3.2	0.9	0.0	1.7	27.9	5.6	8.0

나. 고속도로 교통사고 차종별 현황

2019년부터 2021년의 고속도로 교통사고 차종별 현황은 다음 표 3.9와 같다. 3년간의 차종별 사고 건수는 승용차 총 8,131건, 화물차 3,340건, 승합차 591건, 특수차 470건, 기타/불명 385건, 건설기계 221건, 이륜차 6건 발생한 것으로 나타났다.

또한, 고속도로 교통사고 중 차종별 사고 건수 및 사망자 구성비는 그림 3.12와 같다. 승용차의 사고 건수 구성비가 61.9%로 가장 높게 분석되었고, 화물차 25.4%, 승합차 4.5%로 승용차와 화물차로 인한 사고 발생이 전체 차종 중 가장 많은 비율을 차지하는 것으로 분석되었다.

사망자 구성비의 경우, 화물차 45.2%, 승용차 41.0%, 특수차 6.8%, 승합차 5.2%의 순서로 나타나 화물차와 승용차 사고로 인한 사망자가 가장 많이 발생한 것으로 분석되었다.

표 3.9 2019-2021년 고속도로 교통사고 차종별 현황

구 분	2019			2020			2021		
	사고건수	사망자수	부상자수	사고건수	사망자수	부상자수	사고건수	사망자수	부상자수
	(건)	(명)	(명)	(건)	(명)	(명)	(건)	(명)	(명)
계	4,223	206	9,521	4,039	223	8,389	4,883	191	9,708
승용차	2,606	86	5,895	2,547	94	5,348	2,978	74	6,000
승합차	258	7	1,062	160	13	660	173	12	479
화물차	1,007	96	1,983	1,005	96	1,826	1,328	88	2,567
특수차	143	12	249	143	16	277	184	14	315
이륜차*	1	0	2	2	0	2	3	0	5
건설기계	68	4	127	60	4	95	93	3	139
기타/불명	140	1	203	121	0	180	124	0	173

*이륜차에는 이륜차 외에 원동기장치자전거, 사륜오토바이(ATV)를 포함.

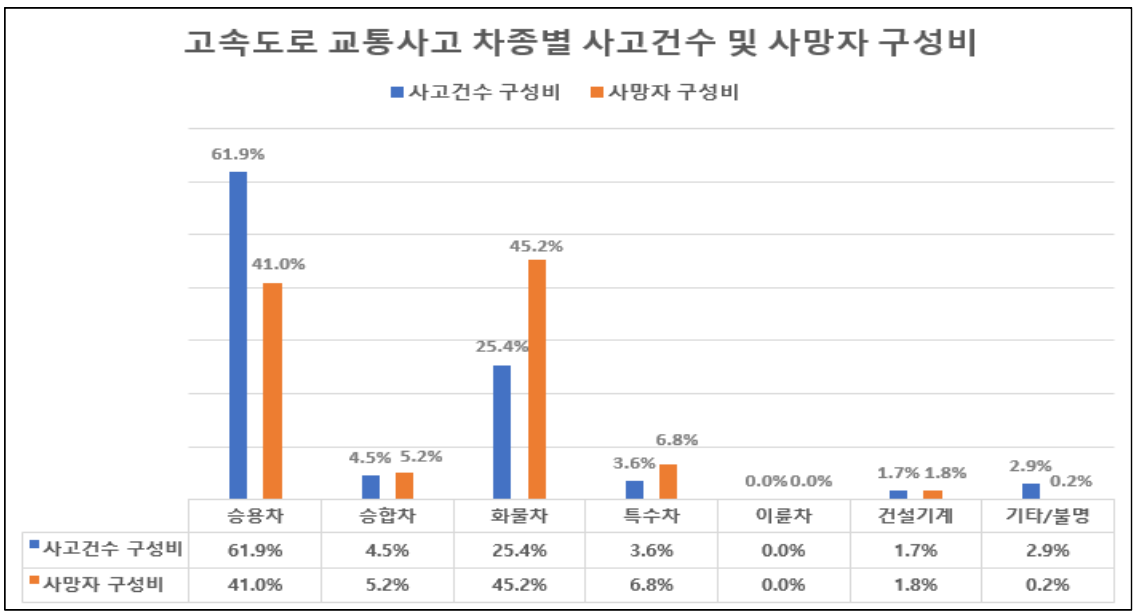


그림 3.12 2019년-2021년 고속도로 교통사고 차종별 사고건수 및 사망자 구성비

다. 고속도로 법규위반별 현황

2019년부터 2021년 가해자의 법규위반으로 인한 교통사고 발생 건수 중 가장 많은 비율을 차지하고 있는 것은 안전운전의무불이행과 안전거리미확보로 나타났으며, 그 수치는 그림 3.13과 같다. 3년간의 법규위반사항으로 안전운전의무불이행이 63.7%, 안전거리미확보가 26.1%를 차지한 것으로 분석되어 고속도로 사고 대부분을 차지하였고 차로위반(3.3%), 기타(2.8%), 신호 위반(2.4%)으로 인한 교통사고가 뒤를 이었다.

각 년도 별 현황은 사고 건수는 안전운전의무불이행이 2019년 2,773건, 2020년 2,586건, 2021년 3,018건으로 가장 높게 나타났고, 다음으로 안전거리미확보가 2019년 1,067건, 2020년 1,083건, 2021년 1,278건으로 나타났다.

이때, 사망자 수와 부상자 수 역시도 사고 발생 건수 비율과 거의 비례한 수치로 나타나는 것을 알 수 있었으나 치사율[16] 현황을 살펴보면 2019년도 과속으로 인한 사망자 수는 11명, 치사율은 21.6%로 나타났고, 2020년도에는 과속으로 인한 사망자가 20명, 치사율은 31.7%로 나타났다. 이는 전체 법규위반 사항 중 가장 높은 치사율을 차지하고 있어 이에 대한 해결방안이 필요한 것으로 분석된다.

16) 치사율 : 교통사고 당 사망자 발생률을 의미. 교통사고 100건당 사망자 수로 나타냄(명/100건).

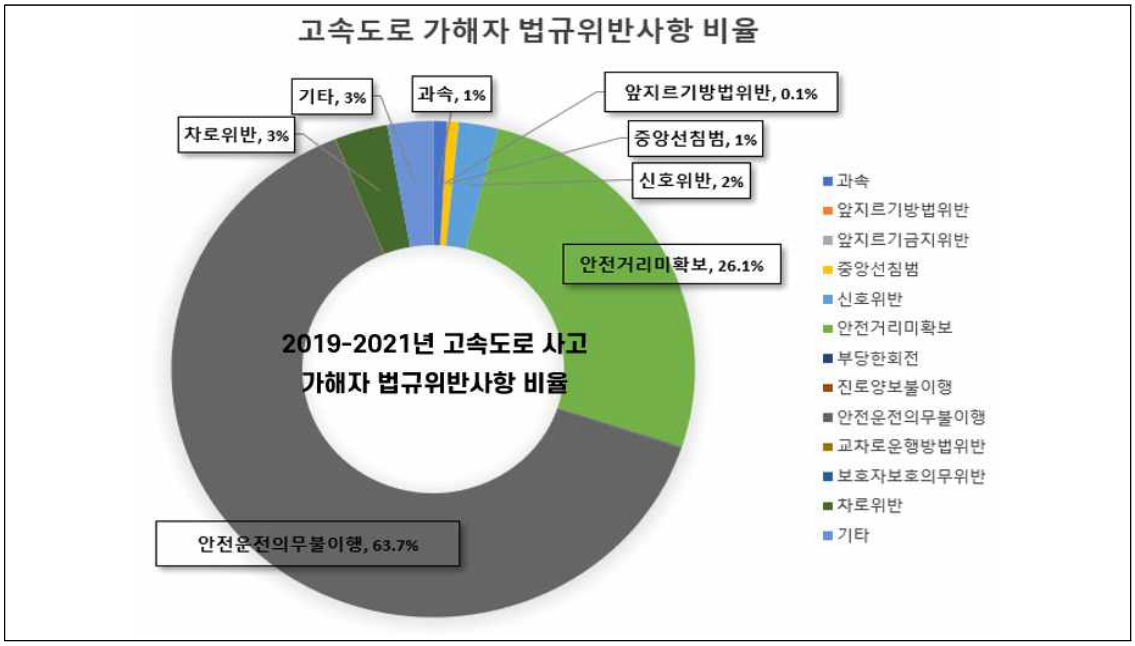


그림 3.13 2019년-2021년 고속도로 가해자 법규위반사항 현황

표 3.10 2019년 고속도로 가해자 법규위반 현황

구 분	2019			
	사고건수	사망자수		부상자수
	(건)	(명)	치사율(%)	(명)
과 속	50	11	21.6	152
앞지르기방법위반	5	0	0	7
앞지르기금지위반	0	0	0	0
중앙선침범	28	5	17.9	72
신호위반	77	1	1.3	147
안전거리미확보	1,067	16	1.5	2,435
부당한회전	0	0	0	0
진로양보불이행	0	0	0	0
안전운전의무불이행	2,773	172	6.2	6,307
교차로운행방법위반	0	0	0	0
보호자보호의무위반	0	0	0	0
차로위반	139	1	0.7	235
기 타	86	0	0	166
합 계	4,222	206	4.9	9,521

표 3.11 2020년 고속도로 가해자 법규위반 현황

구 분	2020			
	사고건수	사망자수		부상자수
	(건)	(명)	치사율(%)	(명)
과 속	60	20	31.7	126
앞지르기방법위반	2	0	0	6
앞지르기금지위반	2	0	0	2
중앙선침범	33	3	9.1	60
신호위반	68	0	0	120
안전거리미확보	1,083	5	0.5	2,108
부당한회전	4	1	25	7
진로양보불이행	1	0	0	2
안전운전의무불이행	2,586	183	7.1	5,610
교차로운행방법위반	2	0	0	8
보호자보호의무위반	0	0	0	0
차로위반	91	1	1.1	160
기 타	104	10	9.6	180
합 계	4,039	223	5.5	8,389

표 3.12 2021년 고속도로 가해자 법규위반 현황

구 분	2021			
	사고건수	사망자수		부상자수
	(건)	(명)	치사율(%)	(명)
과 속	0	0	0	0
앞지르기방법위반	2	0	0	8
앞지르기금지위반	0	0	0	0
중앙선침범	24	2	8.3	43
신호위반	173	0	0	314
안전거리미확보	1,278	8	0.6	2,519
부당한회전	2	0	0	3
진로양보불이행	3	0	0	4
안전운전의무불이행	3,018	156	81.7	6,078
교차로운행방법위반	1	0	0	1
보호자보호의무위반	1	0	0	1
차로위반	201	2	1	345
기 타	180	23	12.8	392
합 계	4,883	191	3.9	9,708

3.4 변수 선정

3.4.1 종속변수 선정

사고의 심각성을 나타내기 위해 각 피해의 종류를 사망, 부상, 재산상의 피해를 따로 비교하지 않고 등가로 환산하여 하나의 피해 단위로 환산해야 한다(도철웅, 2013). 이를 위해 본 연구에서는 대물 피해 환산계수(Equivalent Property Damage Only, EPDO)의 개념을 통해 사고심각도를 나타내고자 하였다.

사고의 내용은 TAAS에서 제공하고 있는 데이터를 활용하였으며, 이때 환산을 위한 가중치는 사망 12, 중상 5 및 경상 3으로 설정하였다.

$$EPDO = \text{사망자수} \times 12 + \text{중상자수} \times 5 + \text{경상자수} \times 3 + \text{부상신고자수}$$

3.4.2 독립변수 선정

독립변수는 선행연구를 참고하여 TAAS에서 수집이 가능한 사고내용 중 사고 발생일시, 발생지역, 사고내용, 사고유형, 위반법규, 기상 상태, 노면 상태, 도로 형태, 가해 운전자 및 피해 운전자의 인적 사항으로 선정하였다. 또한, 콘 존(Conzone) 자료와 결합하여 가공한 고속도로 노선별 차로 수, 제한속도, 곡선반경 길이의 평균, 종단경사 값과 같은 기하구조 요소 또한 독립변수로 선정하여 분석에 활용하였다.

이때, 가해자 연령변수로 미성년자는 19세 이하의 청소년으로 구분하였고, 성년을 20세 이상에서 39세 이하, 40세 이상에서 59세 이하, 60세 이상으로 구분하였다.

피해자 인적요인 중 피해자 연령변수 또한 가해자 연령변수와 마찬가지로 19세

이하의 미성년자, 성년을 20세 이상에서 39세 이하, 40세 이상에서 59세 이하, 60세 이상으로 구분하였다.

시간 요인 변수는 18시를 기준으로 주간과 야간으로 나누어 06시부터 18시까지를 주간, 18시부터 06시까지를 야간으로 구분하였다.

계절 요인 변수는 3월부터 5월까지 봄, 6월부터 8월까지 여름, 9월부터 11월까지 가을, 12월부터 2월을 겨울로 구분하였다.

노면 상태 변수는 포장 여부에 따라 비포장도로와 포장도로로 구분되나 분석 대상 노선인 고속도로의 특성상 100%의 포장률[17]을 나타내고 있어 포장의 구분과 관계없이 노면의 상태만으로 구분해 분석을 진행하였다.

사고유형, 도로 형태 및 위반법규와 같은 사고요인은 TAAS 에서 제공하는 원자료를 토대로 분석에 활용하였다.

콘 존(Conzone) 데이터와 결합하여 가공한 차로 수, 제한속도, 곡선반경 길이의 평균 및 종단경사 같은 경우 수치형 변수로 구성되어 있어 이를 토대로 분석에 활용하였다.

17) 자료 : 국토교통부, 도로 및 보수현황 시스템 “http://www.rsis.kr”, 2022,5.

3.4.3 변수 전처리

종속변수인 사고 심각도 EPDO와 독립변수 중 고속도로의 콘 존 데이터와 결합하여 가공한 차로 수, 제한속도, 곡선반경 길이의 평균 및 종단경사는 수치형 자료로 구성되어 있고 이를 제외한 나머지 변수는 범주형 자료로 구성되어 있다.

따라서, 범주형 자료를 수치형 자료로 변환하기 위해 원-핫 인코딩 방식[18](One Hot Encoding)을 활용한 데이터 변환이 필요하다. 따라서 범주형 자료를 더미 변수로 처리하였으며 최종적으로 표 3.13과 같이 분류하였다.

표 3.13 수집 변수 선정 및 변수 표기법

자 료		변수의 구조		변수의 표시 방법	출처
종속변수		사고 당사자의 사고 심각도		· EPDO	TAAS
독립변수	인적요인	가해자 성 별	여 자	· 여자/남자=1 · otherwise=0	
			남 자		
		가해자 연 령	19세 이하	· 19세 이하/ 20세~39세/40세~59세/60세 이상=1 · otherwise=0	
			20세 이상 39세 이하		
			40세 이상 59세 이하		
			60세 이상		
		피해자 성 별	여 자	· 여자/남자=1 · otherwise=0	
			남 자		
		피해자 연 령	19세 이하	· 19세 이하/ 20세~39세/40세~59세/60세 이상=1 · otherwise=0	
			20세 이상 39세 이하		
			40세 이상 59세 이하		
			60세 이상		

18) 원-핫 인코딩(One-Hot Encoding) : 단어 집합의 크기를 벡터의 차원으로 하고, 표현하고 싶은 단어의 인덱서에 1의 값을 부여하고, 다른 인덱스에는 0을 부여하는 단어의 벡터 표현 방식임.

[표 계속]

자 료		변수의 구조		변수의 표시방법	출 처
독립변수	시간환경요인	주·야간	주 간(06:00~18:00)	· 주간/야간=1 · otherwise=0	TAAS
			야 간(18:00~06:00)		
		요 일	주 중(월~금)	· 주중/주말=1 · otherwise=0	
			주 말(토~일)		
		계 절	봄(3~5월)	· 봄/여름/가을/겨울=1 · otherwise=0	
			여 름(6~8월)		
			가 을(9~11월)		
			겨 울(11~2월)		
		기상상태	맑 음	· 맑음/비/눈/안개/흐림=1 · otherwise=0	
			비		
			눈		
			안 개		
			흐 림		
		노면상태	건 조	· 건조/습기/결빙/적설=1 · otherwise=0	
			습 기		
			결 빙		
			적 설		

[표 계속]

자 료		변수의 구조		변수의 표시방법	출 처
독립변수	사고요인	차 종	승용차	· 승용차/승합차/화물차/특수/건설기계/원동기/보행자=1 · otherwise=0	TAAS
			승합차		
			화물차		
			특수차		
			건설기계		
			원동기		
			보행자		
		유 형	차대차	· 차대차/차량단독/차대사람=1 · otherwise=0	
			차량단독		
			차대사람		
		위반법규	과 속	· 과속/교차로운행방법위반/신호위반/안전거리미확보/안전운전불이행/중앙선침범/차로위반=1 · otherwise=0	
			교차로운행방법위반		
			신호위반		
			안전거리미확보		
			안전운전불이행		
			중앙선침범		
			차로위반		

[표 계속]

자 료		변수의 구조		변수의 표시방법	출 처
독립변수	사고요인	도로형태	교차로부근	· 교차로부근/교차로안/고가도로위/교량/지하차도내/터널/주차장=1 · otherwise=0	TAAS
			교차로안		
			고가도로위		
			교 량		
			지하차도(도로)내		
			터 널		
			주차장		
	기하구조	차로수	2차로	· 콘 존별 수치형 변수를 원자료의 형태로 활용	콘 존 마스터 테이블
			3차로		
			4차로		
			5차로		
			6차로		
		제한속도	80km/h		
			100km/h		
			110km/h		
		곡선반경길이평균			
		종단경사			

3.5 기술통계분석

머신러닝을 활용한 사고 심각도 모형분석에 앞서 수집된 데이터를 토대로 SPSS를 활용하여 기술통계분석을 진행하였다. 분석에 활용한 고속도로 10개 노선(경부선, 영동선, 서해안선, 남해선, 수도권제1순환선, 중부선, 중부내륙선, 중앙선, 호남선, 서울양양선)의 교통사고 표본 수는 총 9,096건이다. 한국도로교통공단에서 제공하는 2019년부터 2021년의 사고 자료를 수집하였으며 본 연구의 기술통계분석은 아래와 같다.

이때, 표에 나타난 count는 변수별 고속도로 교통사고 발생 건수, mean은 고속도로 교통사고 심각도의 평균값을 나타내며, standard deviation은 표준편차를 의미한다.

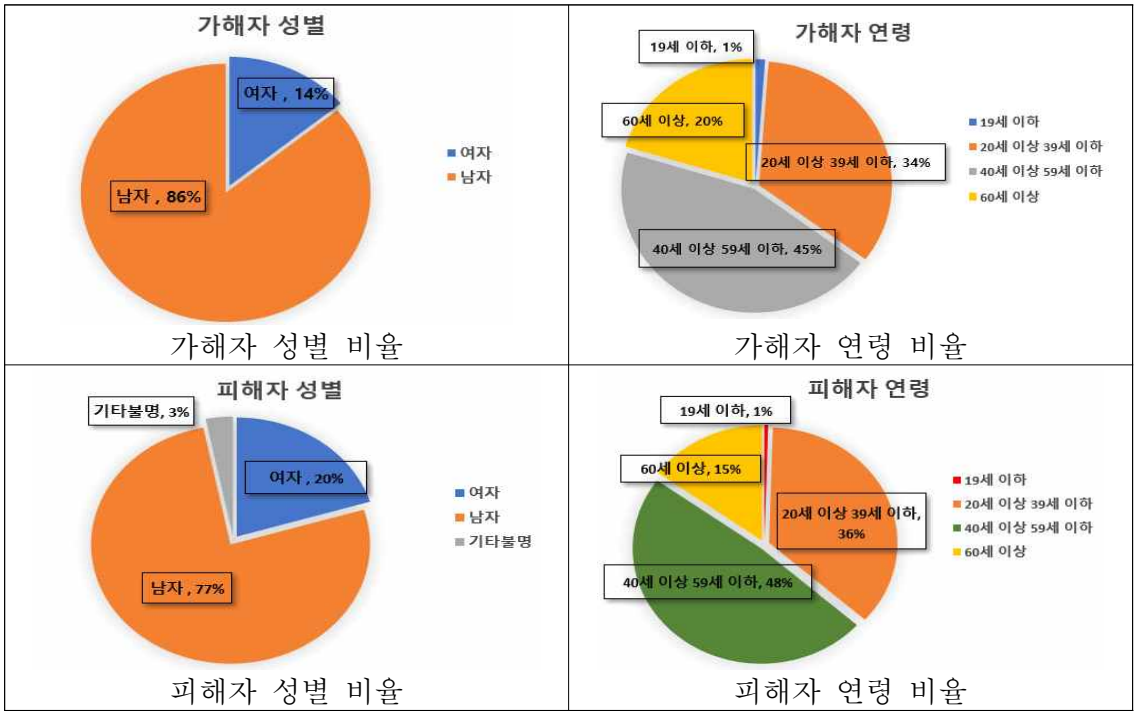
3.5.1 인적요인 기술통계분석

본 연구의 인적요인 기술통계분석은 아래 표 3.14와 같다. 가해자 성별은 남성이 7,825건의 사고를 유발하였고 그림 3.19와 같이 전체 고속도로 교통사고 중 남성의 사고유발 비율이 86%, 여성 비율이 14%로 남성이 여성보다 약 6배 높게 분석되었다.

연령대 부분에서는 가해 운전자가 40세 이상 59세 이하에서 발생한 사고 건수가 4,049건으로 가장 많게 나타났으나 사고 심각도의 평균은 7.81로 나타나 사고 심각도의 평균은 가해 운전자가 60세 이상일 경우가 7.95로 가장 높게 나타났다. 40세 이상 59세 이하일 때 사고 심각도 평균 7.81, 20세 이상 39세 이하일 때 7.73의 순서로 나타났다.

표 3.14 인적요인변수 기술통계분석표

변 수			count	mean	standard deviation
인적 요인	가해자 성 별	여 자	1,271	7.30	0.175
		남 자	7,825	7.87	0.092
	가해자 연 령	19세 이하	105	7.02	3.954
		20세 이상 39세 이하	3,099	7.71	7.869
		40세 이상 59세 이하	4,049	7.81	7.652
		60세 이상	1,843	7.95	8.539
	피해자 성 별	여 자	1,843	6.93	5.720
		남 자	6,968	8.03	8.369
		기타불명	285	7.56	7.802
	피해자 연 령	19세 이하	42	7.90	4.178
		20세 이상 39세 이하	3,181	6.98	6.634
		40세 이상 59세 이하	4,264	8.27	8.783
		60세 이상	1,322	8.26	7.523



가해자 성별 비율 가해자 연령 비율

피해자 성별 비율 피해자 연령 비율

그림 3.14 인적요인 변수 비율 그래프

3.5.2 시간・환경요인 기술통계분석

본 연구의 시간・환경요인을 분석한 내용은 다음과 같다. 시간・환경요인 중 주간(06:00~18:00)에 발생한 고속도로 교통사고는 5,761건, 사고 심각도 평균은 8.17로 분석되어 전체 고속도로 교통사고 중 63%를 차지했다. 이는 야간(18:00~06:00) 발생보다 약 1.7배 많이 발생했으며, 주중(월~금)의 사고 발생비율은 69%로, 주말(토~일)보다 약 2.2배 높게 분석되었다.

계절별 고속도로 교통사고는 봄 2,209건, 여름 2,318건, 가을 2,603건, 겨울 1,966건으로, 겨울철 발생한 교통사고 건수가 가장 적게 나타났으나 사고 심각도 평균은 7.90으로 가장 높게 나타났다.

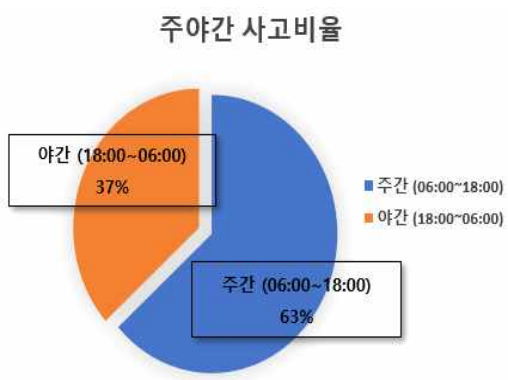
기상 상태의 경우 맑은 날 발생한 교통사고가 7,924건으로 87%를 차지하여 가장 많은 사고 비율을 차지했고 비 797건, 흐림 284건, 눈 65건, 기타 15건, 안개 11건 순으로 나타났다. 이 중 '기타'를 제외한 사고 건수 대비 안개 낀 날의 경우가 사고 심각도 평균이 8.64로 가장 높은 수치를 나타낸 것으로 분석되었다.

노면 상태는 건조할 때가 5,390건으로 전체 고속도로 교통사고의 노면 상태별 사고 비율 중 89%를 차지하였고, 노면 상태가 적설일 경우 사고 발생 건수는 8건이었으나 사고 심각도 평균은 10.50으로 가장 높게 나타났다.

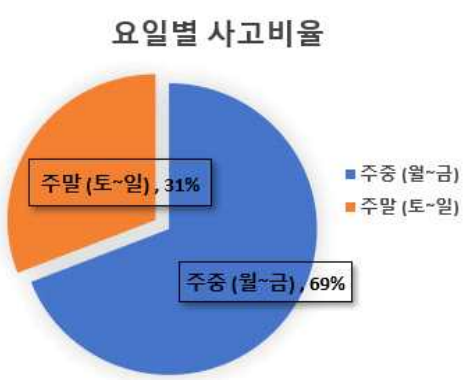
따라서 시간・환경요인 기술통계분석 결과 고속도로 교통사고 심각도에 영향을 미치는 변수는 주간(06:00~18:00) 발생인 경우, 주중(월~금)일 경우, 겨울철 발생한 사고인 경우, 기상 상태가 안개 낀 날인 경우, 노면의 상태가 적설인 경우 사고 심각도가 가장 높게 분석되었다.

표 3.15 시간 · 환경요인 기술통계분석표

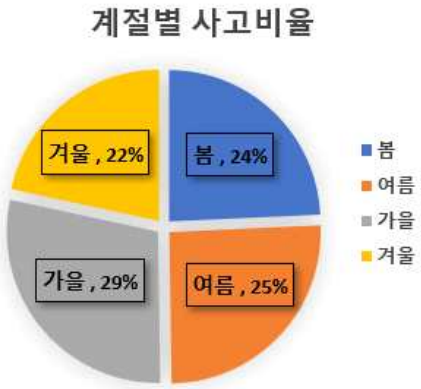
변 수			count	mean	standard deviation
시간 환경 요인	주·야간	주 간(06:00~18:00)	5,761	8.17	8.355
		야 간(18:00~06:00)	3,335	7.15	6.942
	요 일	주 중(월~금)	6,284	7.26	7.445
		주 말(토~일)	2,812	8.98	8.663
	계 절	봄	2,209	7.79	6.930
		여름	2,318	7.74	7.376
		가 을	2,603	7.75	8.393
		겨 울	1,966	7.90	8.724
	기상상태	맑 음	7,924	7.77	7.926
		비	797	7.70	7.417
		눈	65	7.77	7.399
		안 개	11	8.64	7.047
		흐 림	284	8.44	8.137
		기 타	15	8.93	6.563
	노면상태	건 조	5,390	7.99	8.377
		젖음/습기	684	7.88	7.935
		결 빙	16	8.19	10.913
		적 설	8	10.50	5.855
		기 타	5	6.40	7.733



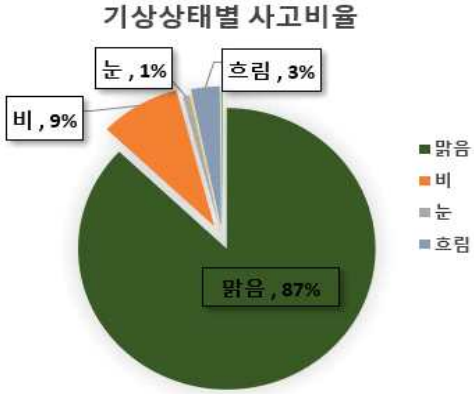
(a) 주 · 야간 사고비율



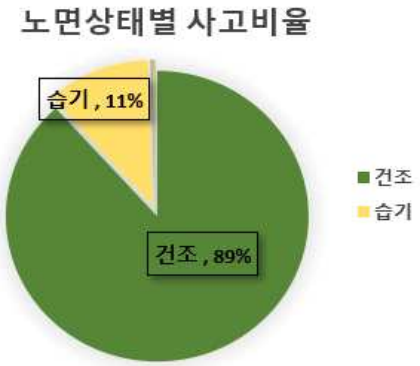
(b) 요일별 사고비율



(c) 계절별 사고비율



(d) 기상상태별 사고비율



(e) 노면상태별 사고비율

그림 3.15 시간 · 환경요인 사고비율 그래프

3.5.3 사고요인별 기술통계분석

본 연구의 고속도로 교통사고의 사고요인을 분석한 표는 아래 표 3.16과 그림 3.16과 같다. 가해 운전자 차종 중 승용차가 5,793건으로 이는 전체 차종별 사고 비율 중 64%로 가장 높은 비율을 차지하고 있고, 화물차가 2,330건으로 26%, 승합차가 504건으로 5%로 분석되었다. 이 중 승합차의 교통사고 심각도 평균이 14.09로 가장 높게 나타났고, 건설기계가 8.50, 화물차가 7.54로 분석되었다.

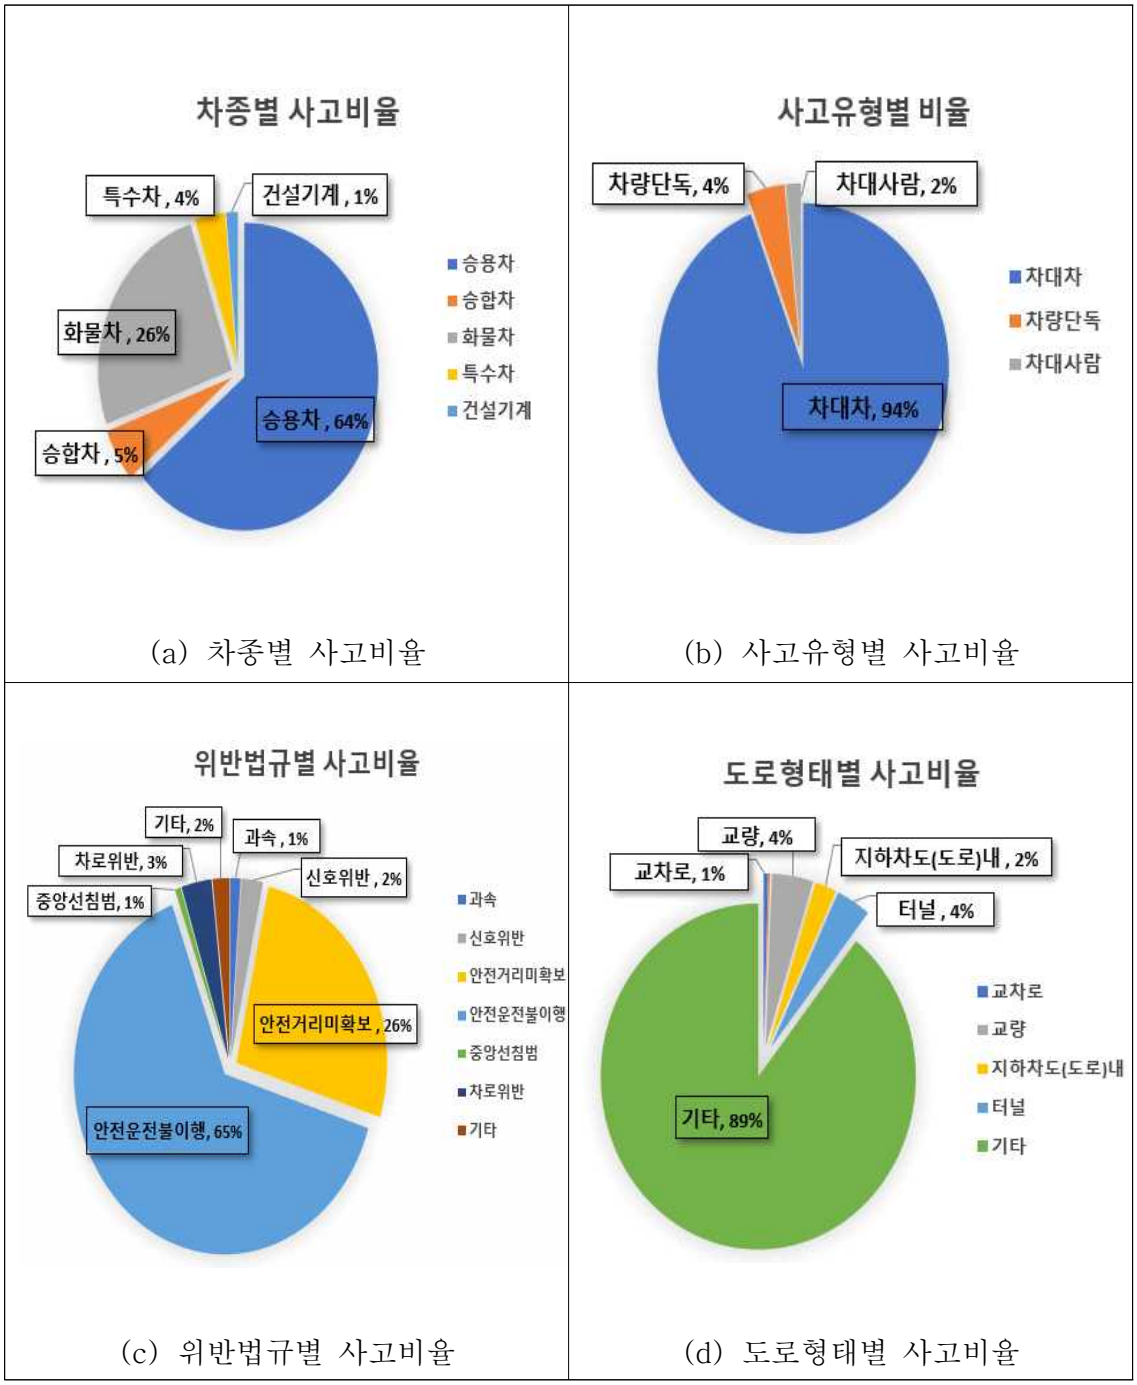
사고요인 중 사고유형은 고속도로 특성상 차대 차 사고가 5,739건으로 94%를 차지하였고, 사고 심각도 평균도 7.81로 가장 높게 나타났다.

사고요인 중 위반법규는 안전운전불이행이 5,864건으로 위반법규 사항 중 65%로 가장 높은 비율을 차지하였다. 또한, 고속도로 교통사고 심각도 평균의 경우, 교차로운행방법위반이 21.0으로 가장 높게 나타났고 과속(10.72), 안전운전불이행(8.22), 중앙선 침범(7.83), 기타(7.80), 안전거리 미확보(6.96), 신호 위반(6.37), 차로위반(5.90)의 순서로 분석되었다.

사고요인 중 도로 형태는 기타의 경우가 8,125건으로 사고 비율은 89%로 나타났는데 이는 고속도로의 주행도로를 기타로 분류했기 때문에 나타난 결과로 해석되어진다. 또한, 도로 형태 중, 사고 심각도 평균이 가장 높게 나타난 곳은 터널이 10.07로 가장 높은 수치를 나타냈고, 지하차도(도로)내 9.78, 기타 7.70, 고가도로 위 7.12, 교량 7.08, 교차로 5.52의 순서로 분석되었다.

표 3.16 사고요인별 기술통계분석표

변 수			count	mean	standard deviation
사고 요인	차 종	승용차	5,793	7.40	6.743
		승합차	504	14.09	17.519
		화물차	2,330	7.54	6.738
		특수차	332	6.54	5.289
		건설기계	128	8.50	8.089
		기타불명	9	7.11	4.314
	유 형	차대차	5,739	7.81	7.899
		차량단독	256	7.50	7.963
		차대사람	101	7.27	5.948
	위반법규	과 속	101	10.72	7.812
		교차로운행방법위반	2	21.0	0
		신호위반	209	6.37	6.526
		안전거리미확보	2,405	6.96	6.589
		안전운전불이행	5,864	8.22	8.460
		중앙선침범	59	7.83	4.658
		차로위반	293	5.90	5.838
		기 타	163	7.80	7.605
	도로형태	교차로	42	5.52	4.312
		고가도로 위	16	7.12	6.365
		교 량	385	7.08	6.450
		지하차도(도로)내	203	9.78	10.290
		터 널	325	10.07	8.876
		기 타	8,125	7.70	7.827



(a) 차종별 사고비율 (b) 사고유형별 사고비율

(c) 위반법규별 사고비율 (d) 도로형태별 사고비율

그림 3.16 사고요인별 사고비율 그래프

3.5.4 기하구조 요인별 기술통계분석

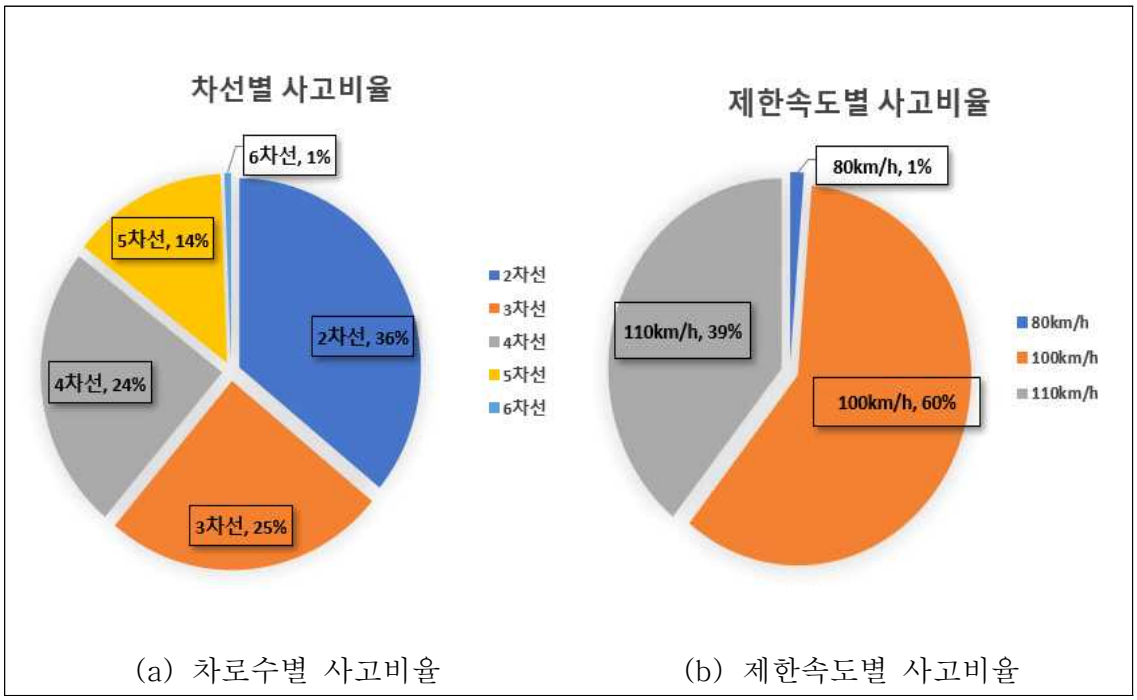
본 연구에서 고속도로 교통사고가 발생한 위치 좌표와 콘 존의 데이터를 결합하여 분석한 기하구조 중 차로 수와 제한속도 변수를 기술 통계 분석한 내용은 아래 표 3.17과 그림 3.17과 같다.

기하구조 요인 중 고속도로 2차선 노선에서 3,202건의 교통사고가 발생해 가장 높은 수치를 차지했고, 3차선(2,245건), 4차선(2,170건), 5차선(1,236건), 6차선(52건)의 순으로 높게 나타나 차선 수가 적을수록 많은 사고가 발생하는 것으로 나타났다. 또한, 교통사고 심각도 평균은 2차선일 때 8.60으로 가장 높게 나타났고 5차선 7.92, 3차선 7.41, 4차선 7.04, 6차선 5.92로 분석되어 고속도로 2차로 노선에서의 교통사고 발생이 사고심각도에 큰 영향을 미치는 것으로 분석되었다.

고속도로 제한속도의 경우 100km/h에서 5,299건의 사고가 발생해 60%의 비율을 차지하였으나 사고심각도 평균은 80km/h일 때 8.36으로 가장 높게 나타났으며 110km/h일 때 8.29, 100km/h일 때 7.48의 순서로 분석되었다.

표 3.17 기하구조 요인별 기술통계분석표

변 수			count	mean	standard deviation
기하구조요인	차로수	2차선	3,202	8.60	8.123
		3차선	2,245	7.41	7.110
		4차선	2,170	7.04	7.284
		5차선	1,236	7.92	9.551
		6차선	52	5.92	4.648
	제한속도	80km/h	114	8.36	6.005
		100km/h	5,299	7.48	6.896
		110km/h	3,492	8.29	9.268



(a) 차로수별 사고비율 (b) 제한속도별 사고비율

그림 3.17 기하구조별 사고비율 그래프

3.6 가설 설정 및 검증

분석에 앞서 본 연구에서는 독립변수가 종속변수인 EPDO에 영향을 미치는 정도의 차이가 있는지에 대하여 통계적으로 확인하고자 SPSS 28.0을 활용한 전통적 통계분석 방법을 실시하였다.

이때, 종속변수가 연속형 데이터이고 독립변수는 콘 존 데이터인 차로 수, 제한속도, 곡선반경의 평균, 종단경사를 제외한 나머지가 범주형인 데이터로 구성되어 있어 독립표본 t-검정(Independent Samples t-test) 및 일원 배치 분산분석(One-way ANOVA)을 실시하였다.

3.6.1 독립표본 t-검정(Independent Samples t-test)

독립표본 t-검정은 두 집단 간의 평균을 비교하고, 그 차이가 유의미한지 검증하는 통계 방법으로 모집단의 분산이나 표준편차를 알지 못할 때 모집단을 대표하는 표본으로부터 추정된 분산이나 표준편차를 가지고 검정하는 통계적 검정방법이다.

이는 모수적 통계 방법으로써 표본이 정규성, 등분산성, 독립성 등을 만족할 경우 적용이 가능하다. 본 논문에서는 분석을 위한 귀무가설(H_0)과 대립가설(H_1)은 다음 표 3.18과 같이 설정하였다.

표 3.18 독립표본 t-test 가설 설정

가설1	H_0	사고 심각도에 대하여 가해자 성별에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 가해자 성별에 따른 유의한 차이가 있을 것이다.
가설2	H_0	사고 심각도에 대하여 주 · 야간에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 주 · 야간에 따른 유의한 차이가 있을 것이다.
가설3	H_0	사고 심각도에 대하여 주중 · 주말에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 주중 · 주말에 따른 유의한 차이가 있을 것이다.

독립표본 t-test 분석 결과는 표 3.19와 같다. 가해자 성별, 주・야간, 주중・주말의 경우 두 집단의 분산 분포 동질성 검정을 통해 유의확률이 0.05보다 작으므로 등분산을 가정하지 않은 상태에서의 검증 결과를 해석하였다.

검증 결과, 등분산을 가정하지 않은 상태에서의 유의확률은 0.05보다 작게 나타나 통계적으로 유의하게 나타나 귀무가설(H_0)을 기각하고 대립가설(H_1)을 채택하여 '가해자 성별, 주・야간, 주중・주말의 변수에 따라 사고 심각도에 차이가 있다'라고 할 수 있다.

따라서, 가해자 성별 중 남자는 평균 7.87, 여자 7.30으로 여자보다 남자가 사고 심각도에 상대적으로 높은 평균 점수를 나타냈으며, 주・야간 중 주간 평균이 8.17, 야간 7.15로 야간보다 주간에 사고 심각도가 상대적으로 높은 평균 점수를 나타냈다. 또한, 주중・주말 중 주간 평균 7.26, 주말 8.98로 나타나 주간보다 주말의 사고 심각도가 상대적으로 높은 평균 점수를 나타낸 것으로 분석되었다.

표 3.19 독립표본 t-test 검증 결과

(*N*=9,096)

구 분		종속변수			*t*(*p*)
		N	평균(M)	표준편차(SD)	
가해자 성별	여 자	1,271	7.30	8.116	2.905(0.004)*
	남 자	7,825	7.87	6.228	
주・야간	주 간	5,761	8.17	8.355	6.243(0.001)*
	야 간	3,335	7.15	6.942	
주중・주말	주 중	6,284	7.26	7.445	−9.088(0.001)*
	주 말	2,812	8.98	8.663	

*p<.05, **p<.01, ***p<.001

3.6.2 일원 배치 분산분석(One-way ANOVA)

일원 배치 분산분석(One-way ANOVA)은 세 개 이상의 집단 간 평균을 비교하는 통계 검정 방법으로 독립변수가 세 개 이상의 집단으로 구성된 범주형 자료, 종속변수가 연속형 자료일 경우에 활용 가능하며, 모형 식은 아래 식 3.1과 같다.

$$X_{ij} = \mu + \alpha_i + \epsilon_{ij} \quad (3.1)$$

여기서, X_{ij} : 각 관측치
μ : 전체 평균
α_i : 전체 평균과 수준 평균과의 차이
ϵ_{ij} : 수준과 개별 관측치 간의 오차

일원 배치 분산분석을 수행하기 위해 아래 세 가지의 가정이 필요하다.

- 모집단의 분산이 정규성(normality)을 가진다.
- 모집단의 분산이 동질성(equality of variances)을 가진다.
- 모집단 간의 오차는 서로 독립성(independency)을 가진다.

본 연구의 분석을 위한 귀무가설(H_0)과 대립가설(H_1)은 다음 표 3.20과 같이 설정하였다.

표 3.20 일원 배치 분산분석 가설 설정

가설1	H_0	사고 심각도에 대하여 피해자 성별에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 피해자 성별에 따른 유의한 차이가 있을 것이다.
가설2	H_0	사고 심각도에 대하여 가해자 연령에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 가해자 연령에 따른 유의한 차이가 있을 것이다.
가설3	H_0	사고 심각도에 대하여 피해자 연령에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 피해자 연령에 따른 유의한 차이가 있을 것이다.
가설4	H_0	사고 심각도에 대하여 계절에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 계절에 따른 유의한 차이가 있을 것이다.
가설5	H_0	사고 심각도에 대하여 기상상태에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 기상상태에 따른 유의한 차이가 있을 것이다.
가설6	H_0	사고 심각도에 대하여 노면상태에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 노면상태에 따른 유의한 차이가 있을 것이다.
가설7	H_0	사고 심각도에 대하여 차종에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 차종에 따른 유의한 차이가 있을 것이다.
가설8	H_0	사고 심각도에 대하여 사고유형에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 사고유형에 따른 유의한 차이가 있을 것이다.
가설9	H_0	사고 심각도에 대하여 위반법규에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 위반법규에 따른 유의한 차이가 있을 것이다.
가설10	H_0	사고 심각도에 대하여 도로형태에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 도로형태에 따른 유의한 차이가 있을 것이다.
가설11	H_0	사고 심각도에 대하여 차로수에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 차로수에 따른 유의한 차이가 있을 것이다.
가설12	H_0	사고 심각도에 대하여 제한속도에 따른 유의한 차이가 없을 것이다.
	H_1	사고 심각도에 대하여 제한속도에 따른 유의한 차이가 있을 것이다.

일원 배치 분산분석(One-way ANOVA) 분석 결과는 다음 표 3.21과 같다. 이때, 일원 배치 분산분석의 수행을 위한 세 가지 조건 중 가해자 연령, 피해자 연령, 계절, 사고유형, 차로 수, 제한속도의 경우 n≥30으로 나타나 중심극한정리에 의해 정규성을 만족하였으나 기상 상태, 노면 상태, 차종, 위반법규, 도로 형태는 정규성을 만족하지 못하여 일원 배치 분산분석을 통한 분석을 진행할 수 없었다.

일원 배치 분산분석을 실시한 결과, 가해자 연령의 경우 F=0.686, p=0.001, 피해자 연령 F=18.062, p=0.001, 계절 F= 0.181, p=0.006, 차로 수 F=15.417, p=0.001, 제한속도 F=11.364, p=0.001로 유의수준 0.05보다 작아 통계적으로 유의하게 나타났다. 따라서 귀무가설(H_0) 기각, 대립가설(H_1)이 채택되어 '해당 집단 간의 사고 심각도에 유의한 차이가 있다' 라고 분석되었다.

반면, 사고유형의 경우 F=0.419, p=0.695로 유의수준 0.05보다 크게 나타났으며 이는 통계적으로 유의하지 않음을 뜻하므로 대립가설(H_1)이 기각, 귀무가설(H_0)이 채택된다. 즉, '사고 심각도에 대하여 사고유형에 따른 유의한 차이가 없다.' 라고 할 수 있다.

이처럼 전통적인 통계분석 방법은 t-분포나 F-분포와 같은 통계학적 이론이나 연구자가 미리 설정한 회귀모형 등의 통계학적 모형에 데이터를 적합시켜 가설 검정 또는 유의성을 추정한다. 따라서 데이터 분석을 위한 무리한 가정이 필요하고 다양한 데이터 중 조건에 유의한 경우에만 분석 데이터로써 구축이 가능해 분석에 상당히 제한적이다.

반면, 머신러닝(기계학습)의 경우 데이터로부터 결과를 추정하는 것이 아니라 데이터로부터 자동화된 학습을 통한 모형, 즉, 알고리즘을 구득하는 것으로 변수 간의 연관성 추정보다는 정확한 결과 예측을 목표로 알고리즘을 구축한다. 특히 비선형 관계나 고차원 자료에서의 변수 간 교호작용들을 탐색하는 데에 효과적이다.

따라서 본 연구에서는 전통적 통계분석 방법보다 데이터의 연관성과 유의성을 고

려할 필요가 적은 머신러닝(기계학습)을 활용하여 고속도로 교통사고 심각도 영향 분석을 실시하고 사고 심각도에 영향을 미치는 요인을 도출하고자 한다.

표 3.21 일원 배치 분산분석 검증 결과

구 분		종속변수				
		n	평균(M)	표준편차(SD)	F	유의확률
가해자 연 령	19세 이하	105	7.02	3.954	0.686	0.001
	20세 이상 39세 이하	3,099	7.71	7.869		
	40세 이상 59세 이하	4,049	7.81	7.652		
	60세 이상	1,843	7.95	8.539		
피해자 연 령	19세 이하	42	7.90	4.178	18.062	0.001
	20세 이상 39세 이하	3,181	6.98	6.634		
	40세 이상 59세 이하	4,264	8.27	8.783		
	60세 이상	1,322	8.26	7.523		
계 절	봄	2,209	7.79	6.930	0.181	0.006
	여 름	2,318	7.74	7.376		
	가 을	2,603	7.75	8.393		
	겨 울	1,966	7.90	8.724		
사고유형	차대차	8,739	7.81	7.899	0.419	0.695
	차량단독	256	7.50	7.963		
	차대사람	101	7.27	5.948		
차로수	2차선	3,202	8.60	8.123	15.417	0.001
	3차선	2,245	7.41	7.110		
	4차선	2,170	7.04	7.284		
	5차선	1,236	7.92	9.551		
	6차선	52	5.92	4.648		
제한속도	80km/h	114	8.36	6.005	11.364	0.001
	100km/h	5,299	7.48	6.896		
	110km/h	3,492	8.29	9.268		

*p<.05, **p<.01, ***p<.001

제 4 장 고속도로 교통사고 심각도 및 영향요인 분석

4.1 분석 개요

본 연구는 빅 데이터 분석이 가능한 Python 3.10과 Scikit-learn을 이용하여 연구를 진행하였다. 고속도로 교통사고 다발 구간으로 선정된 10개 노선의 2019년, 2020년, 2021년의 교통사고 심각도를 분석하기 위해 파이캐럿(Pycaret)을 활용하여 가장 성능이 좋은 머신러닝 기법을 채택하였다.

분석 결과, 랜덤 포레스트 회귀모형(RandomForest Regressor)이 채택되었으며 고속도로 교통사고 심각도 분석에 활용하고자 한다.

선정된 10개 노선의 교통사고 자료를 70%는 훈련용(Train) 데이터, 30%는 테스트(Test) 데이터로 구분하였고, 훈련용 데이터는 3,132건, 테스트 데이터는 1,343건의 데이터로 구분하여 활용한다.

서로 다른 변수의 범위를 일정한 수준으로 맞춰주기 위한 데이터 스케일링 과정이 필요해 표준화(Standardization) 기법의 한 종류인 StandardScaler 기법을 활용하였다. 이후 선정된 머신러닝 모형의 성능 비교를 위해 RMSE(Root Mean Squared Error, 평균제곱근오차) 지표를 사용하여 모형의 성능 비교를 실시하였다.

또한, 머신러닝 모형개발을 위한 최적의 파라미터를 찾는 과정인 Hyper Parameter Tuning을 하였고, RandomizedSearchCV를 활용해 연구자가 임의로 설정한 범위 안에서 랜덤으로 값을 추출하여 가장 좋은 하이퍼 파라미터를 탐색하여 최상의 모델을 찾은 후 훈련용 데이터 전체를 사용해 최종 모델을 훈련하였다.

모형 선정 절차 수립 및 자료 구분
훈련 데이터 / 테스트 데이터 비율 = 7 : 3
훈련 데이터 : 3,132건
테스트 데이터 : 1,343건

⇩

데이터 스케일링 기법 선정
StandardScaler

⇩

모형성능 평가지표 선정
RMSE

⇩

파이캐럿(PyCaret)을 활용한 고속도로 교통사고 심각도 분석모형 채택
랜덤 포레스트(Random Forest)

⇩

랜덤 포레스트를 활용한 고속도로 교통사고 심각도 분석

그림 4.1 모형분석 절차

4.2 자료 구분

앞서 언급한 바와 같이 전체 데이터 중 훈련 데이터는 3,132건, 시험 데이터는 1,343건의 자료를 활용했다. 교통사고는 사고 발생 당시 사고의 내용을 명확하게 구분할 수 없는 경우, 불특정한 성격으로 인해 사고내용을 '기타'로 분류하는 경우가 존재한다.

따라서, 본 연구에서는 사고 심각도에 영향을 미치는 요인을 명확히 알 수 없는 데이터의 열은 활용하지 않고 분석을 진행하였으며 그림 4.2와 같이 총 4,475행×48열의 데이터를 구축하였다.

	법규위반_과속	법규위반_교차로운행방법위반	법규위반_기타	법규위반_신호위반	법규위반_안전거리미확보	법규위반_안전운전불이행	법규위반_중앙선침범	법규위반_차로위반	기상상태_기타	기상상태_눈	...	계절_여름	시간대_야간	시간대_주간	요일_주말	요일_주중	노면상태_건조	노면상태_결빙	노면상태_기타	노면상태_적설	노면상태_젖음/습기
0	0	0	0	0	0	1	0	0	0	0	...	0	0	1	0	1	1	0	0	0	0
1	0	0	0	0	0	1	0	0	0	0	...	1	0	1	1	0	1	0	0	0	0
2	0	0	0	0	1	0	0	0	0	0	...	0	0	1	1	0	0	0	0	0	1
3	0	0	0	0	0	1	0	0	0	0	...	0	0	1	0	1	1	0	0	0	0
4	1	0	0	0	0	0	0	0	0	0	...	0	1	0	1	0	1	0	0	0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
4470	0	0	0	0	0	1	0	0	0	0	...	0	0	1	0	1	1	0	0	0	0
4471	0	0	0	0	0	0	1	0	0	0	...	0	1	0	1	0	1	0	0	0	0
4472	0	0	0	0	0	1	0	0	0	0	...	0	1	0	0	1	1	0	0	0	0
4473	0	0	0	0	1	0	0	0	0	0	...	0	1	0	1	0	0	0	0	0	1
4474	0	0	0	1	0	0	0	0	0	0	...	0	1	0	0	1	0	0	0	0	1

4475 rows × 48 columns

그림 4.2 구축 데이터 샘플

4.2.1 데이터 스케일링(Data Scaling)

고속도로 교통사고 심각도 분석을 위해 사용된 수치형 변수인 곡선반경 길이의 평균과 종단경사 변수는 그림 4.3과 같이 값의 크기가 제각각이다. 이로 인해 머신러닝 모델의 성능을 떨어뜨릴 수 있는 문제가 발생한다. 따라서, 서로 다른 변수의 범위를 일정한 수준으로 맞춰주는 작업이 필요하다.

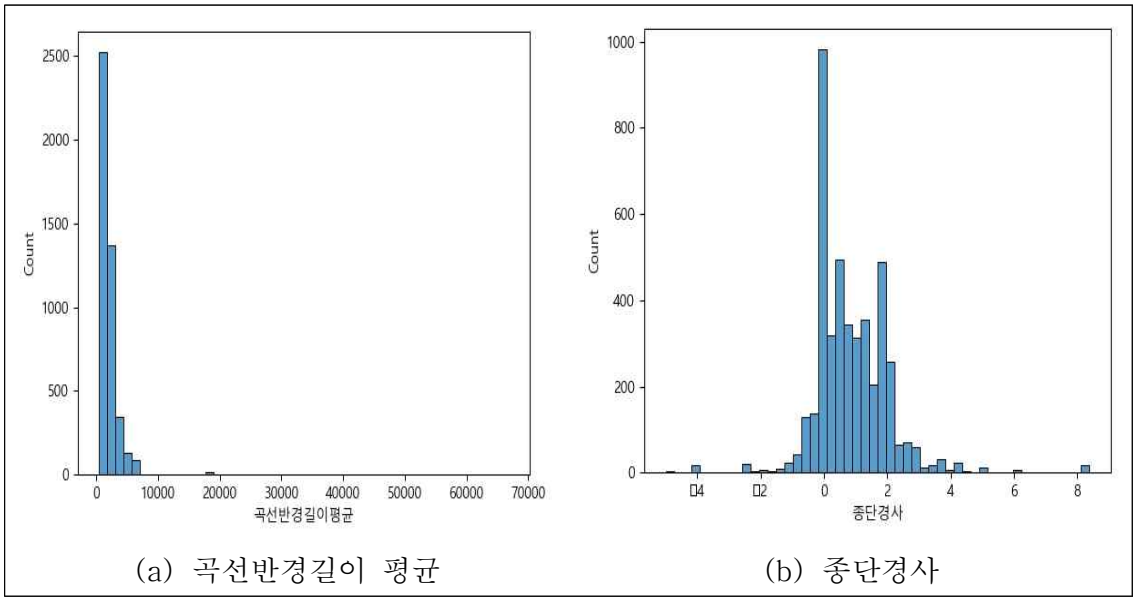
변수의 범위를 일정 수준으로 맞추기 위해 사용한 표준화(Standardization) 기법은 변수 각각의 평균을 0, 분산을 1인 정규분포를 가진 값으로 변환한다. 표준화 기법은 최솟값과 최댓값의 크기를 제한하지 않아 이상치(outlier) 파악에 유리하다. 또한, Z-score를 산출함으로써 데이터가 평균으로부터 얼마나 떨어져 있는지 계산한 후, 특정 범위를 벗어난 데이터는 이상치로 간주해 제거할 수 있다.

이때, 훈련 데이터와 시험 데이터에는 계산된 평균과 표준편차를 그대로 이용하여 표준화를 진행해야 하며 변수의 값을 표준화시키는 수식은 아래 식 4.1과 같다.

본 논문에서는 표준화 기법 중 StandardScaler 기법을 활용하였으며 그림 4.4는 스케일링을 완료한 데이터의 샘플이다.

$$z = \frac{x - \mu}{\sigma} \tag{4.1}$$

여기서, z = 표본의 표준점수 (Z-score)
μ = 평균
σ = 평균으로부터의 표준편차



(a) 곡선반경길이 평균 (b) 종단경사

그림 4.3 수치형 변수 데이터 분포

	법규위반_과속	법규위반_교차로운행방법위반	법규위반_신호위반	법규위반_안전거리미확보	법규위반_안전운전불이행	법규위반_중앙선침범	법규위반_차로위반	기상상태_눈	기상상태_맑음	기상상태_비	...	요일_주말	요일_주중	노면상태_건조	노면상태_결빙	노면상태_기타	노면상태_적설	노면상태_젖음/습기	곡선반경길이평균	종단경사	EPDO
0	-0.10	-0.02	-0.14	-0.60	0.72	-0.09	-0.16	-0.07	0.39	-0.31	...	-0.67	0.67	0.36	-0.06	-0.02	-0.03	-0.35	0.41	-0.73	3
1	-0.10	-0.02	-0.14	-0.60	0.72	-0.09	-0.16	-0.07	0.39	-0.31	...	1.48	-1.48	0.36	-0.06	-0.02	-0.03	-0.35	0.41	-0.73	3
2	-0.10	-0.02	-0.14	1.68	-1.38	-0.09	-0.16	-0.07	-2.56	3.18	...	1.48	-1.48	-2.76	-0.06	-0.02	-0.03	2.83	0.41	-0.73	6
3	-0.10	-0.02	-0.14	-0.60	0.72	-0.09	-0.16	-0.07	0.39	-0.31	...	-0.67	0.67	0.36	-0.06	-0.02	-0.03	-0.35	0.41	-0.73	6
4	10.15	-0.02	-0.14	-0.60	-1.38	-0.09	-0.16	-0.07	0.39	-0.31	...	1.48	-1.48	0.36	-0.06	-0.02	-0.03	-0.35	0.41	-0.24	11
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
6069	-0.10	-0.02	-0.14	-0.60	0.72	-0.09	-0.16	-0.07	0.39	-0.31	...	-0.67	0.67	0.36	-0.06	-0.02	-0.03	-0.35	-0.35	-0.31	10
6070	-0.10	-0.02	-0.14	-0.60	-1.38	10.67	-0.16	-0.07	0.39	-0.31	...	1.48	-1.48	0.36	-0.06	-0.02	-0.03	-0.35	-0.35	-0.31	3
6071	-0.10	-0.02	-0.14	-0.60	0.72	-0.09	-0.16	-0.07	0.39	-0.31	...	-0.67	0.67	0.36	-0.06	-0.02	-0.03	-0.35	-0.35	-0.31	6
6072	-0.10	-0.02	-0.14	1.68	-1.38	-0.09	-0.16	-0.07	-2.56	3.18	...	1.48	-1.48	-2.76	-0.06	-0.02	-0.03	2.83	-0.32	-1.81	6
6073	-0.10	-0.02	7.32	-0.60	-1.38	-0.09	-0.16	-0.07	-2.56	-0.31	...	-0.67	0.67	-2.76	-0.06	-0.02	-0.03	2.83	-0.32	-1.81	3

4475 rows × 47 columns

그림 4.4 StandardScaler 기법을 활용한 데이터 샘플

4.3 모형 성능평가지표 선정

회귀(Regression)의 평가를 위한 지표는 실제 값과 회귀 예측값의 차이를 기반으로 한 지표가 중심으로, 실제 값과 예측값의 차이를 더하면 잔차(Residual)[19]의 합은 0이 되므로 지표로 사용할 수 없다.

회귀모델(Regression Model)에 사용되는 성능 평가지표에는 MAE(Mean Absolute Error, 평균절대오차), MSE(Means Squared Error, 평균제곱오차), RMSE(Root Mean Squared Error, 평균제곱근오차), R2(R-Squared, 결정계수), MAPE(Mean Absolute Percentage Error, 절대평균비율오차) 등이 있다.

이러한 값들은 결국 오차(Error)이기 때문에 그 값이 작을수록 해당 모델의 성능이 좋다는 것을 의미하지만 무조건적으로 낮은 값의 모델을 선택하는 것이 아닌 데이터의 성격과 같이 상호 여러 관계를 고려하여 분석하는 과정이 매우 중요하다.

본 연구에서는 선행연구를 참고하여 예측 모델에서 주로 사용되고 있는 회귀모형 성능 평가지표인 RMSE를 선정하였다. RMSE는 MSE 모형에 루트를 씌운 모형으로 실제 값과 예측값의 차이를 제곱해 평균한 MSE 값은 오류의 제곱을 구하므로 실제 오류의 평균보다 값이 더 커지는 특성이 있다.

따라서, RMSE 모형을 사용하여 오류 지표를 실제 값과 유사한 단위로 다시 변환하여 해석을 보다 쉽게 하고자 하였으며 수식은 식 4.2와 같다. 여기서, n은 데이터의 수를 의미하고, $\hat{y_i}$ 는 예측값, y_i는 실제 값을 의미한다.

$$RMSE = \sqrt{\sum_{i=1}^{n} \frac{(\hat{y_i} - y_i)^2}{n}} \tag{4.2}$$

19) 잔차(Residual) : 회귀식과 관측값 사이에 나타나는 차이를 의미함.

4.4 머신러닝을 활용한 고속도로 교통사고 심각도 분석

4.4.1 분석 개요

파이캐럿(PyCaret)은 scikit-learn 패키지를 기반으로 머신러닝 모델 워크플로우(Workflow)를 자동화해주는 파이썬 라이브러리로 분류(Classification), 회귀(Regression), 군집(Clustering) 등의 분석에서 사용이 가능한 라이브러리이다.

파이캐럿을 활용하면 여러 모델을 동일 환경에서 한 번에 비교, 분석 및 튜닝이 가능하다. 또한, compare_models() 함수를 이용하여 머신러닝 모델들을 자동으로 학습한 결과를 나타내어 각 metric별로 가장 성능이 좋은 위치에 노란색으로 표시해 출력한다. 아래 그림 4.5는 파이캐럿을 활용하여 선정된 모델들의 성능 비교 예시이다.

	Model	MAE	MSE	RMSE	R2	RMSLE	MAPE	TT (Sec)
rf	Random Forest Regressor	4.2897	48.0194	6.8763	0.1920	0.6173	0.8582	0.3540
lightgbm	Light Gradient Boosting Machine	4.6313	50.3225	7.0455	0.1550	0.6405	0.8836	1.1670
gbr	Gradient Boosting Regressor	4.8078	54.4204	7.3206	0.0877	0.6482	0.9353	0.3050
br	Bayesian Ridge	4.8574	56.0309	7.4268	0.0664	0.6539	0.9435	0.0350
ridge	Ridge Regression	4.8746	56.2573	7.4445	0.0606	0.6575	0.9434	0.0230
omp	Orthogonal Matching Pursuit	4.8976	56.8055	7.4809	0.0512	0.6584	0.9548	0.0220
en	Elastic Net	4.9447	57.6769	7.5261	0.0451	0.6622	0.9763	0.0200
llar	Lasso Least Angle Regression	4.9679	58.0690	7.5513	0.0388	0.6652	0.9828	0.0240
lasso	Lasso Regression	4.9679	58.0690	7.5513	0.0388	0.6652	0.9828	0.0200
et	Extra Trees Regressor	4.0918	59.1592	7.6512	-0.0415	0.6492	0.8151	0.2870
dummy	Dummy Regressor	5.0160	60.6834	7.7168	-0.0027	0.6744	0.9918	0.0140
huber	Huber Regressor	4.4289	61.2037	7.7490	-0.0110	0.6196	0.6706	0.0670
knn	K Neighbors Regressor	5.0148	61.1660	7.7745	-0.0331	0.6837	0.9399	0.1060
dt	Decision Tree Regressor	4.6504	76.7264	8.7060	-0.3475	0.7247	0.8651	0.0320
par	Passive Aggressive Regressor	7.3138	112.9857	10.5648	-0.9403	0.9535	1.4034	0.0310
ada	AdaBoost Regressor	11.6414	163.6196	12.7696	-1.9254	1.1689	3.0033	0.2000
lr	Linear Regression	141.3988	29167374.7648	1714.4466	-366584.5136	0.6923	10.5615	0.0250
lar	Least Angle Regression	304.2158	132844808.1455	3678.3185	-1669712.2987	0.8933	23.4213	0.0310

그림 4.5 파이캐럿을 활용한 모델 성능 비교 예시

4.4.2 파이캐럿을 활용한 회귀모델 비교

본 연구에서는 몇 개의 특정 머신러닝 모델들을 선정하여 비교, 분석하는 방법이 아닌 파이캐럿 라이브러리를 활용해 가장 성능이 좋은 머신러닝 기법을 채택하고자 하였다.

RMSE 값을 기준으로 성능이 좋은 5개의 모델을 Top 5 변수로 출력하여 나타냈으며, 그 결과 최종 채택되어 고속도로 교통사고 심각도 분석에 사용된 모형은 RMSE 값이 6.8763인 랜덤 포레스트 회귀모형(RandomForestRegressor)으로 아래 표 4.1과 같다.

표 4.1 파이캐럿을 활용한 회귀모델 결과 비교

Model	MAE	MSE	RMSE	R2	RMSLE	MAPE
Random Forest Regressor	4.2897	**48.0194**	**6.8763**	**0.1920**	**0.6173**	0.8582
Light Gradient Boosting Machine	4.6313	50.3225	7.0455	0.1550	0.6405	0.8836
Gradient Boosting Regressor	4.8078	54.4204	7.3206	0.0877	0.6482	0.9353
Bayesian Ridge	4.8574	56.0309	7.4268	0.0664	0.6539	0.9435
Ridge Regression	4.8746	56.2573	7.4445	0.0606	0.6575	0.9434

[표 계속]

Model	MAE	MSE	RMSE	R2	RMSLE	MAPE
Orthogonal Matching Pursuit	4.8976	56.8055	7.4809	0.0512	0.6584	0.9548
Elastic Net	4.9447	57.6769	7.5261	0.0451	0.6622	0.9763
Lasso Least Angle Regression	4.9679	58.0690	7.5513	0.0388	0.6652	0.9828
Lasso Regression	4.9679	58.0690	7.5513	0.0388	0.6652	0.9828
Extra Trees Regression	4.0918	59.1592	7.6512	−0.0415	0.6492	0.8151
Dummy Regressor	5.0160	60.6834	7.7168	−0.0027	0.6744	0.9918
Huber Regressor	4.4289	61.2037	7.7490	−0.0110	0.6196	0.6706
K Neighbors Regressor	5.0148	61.1660	7.7745	−0.0331	0.6837	0.9399
Decision Tree Regressor	4.6504	76.7264	8.7060	−0.3475	0.7247	0.8651
Passive Aggressive Regressor	7.3138	112.9857	10.5648	−0.9403	0.9535	1.4034
Ada Boost Regressor	11.6414	163.6196	12.7696	−1.9254	1.1689	3.0033
Linear Regression	141.3988	29167374.7648	1714.4466	−366584.5136	0.6923	10.5615
Least Angle Regression	304.2158	132844808.1455	3678.3185	−1669712.2987	0.8933	23.4213

4.5 머신러닝을 활용한 변수 중요도 평가

4.5.1 모형 선택

본 연구에서는 고속도로 교통사고 심각도에 영향을 미치는 요인을 분석하기 위해 머신러닝을 사용하였다. 머신러닝 기법으로는 파이캐럿(Pycaret)을 활용해 선정된 모형인 랜덤 포레스트 모델을 활용하였고 랜덤 포레스트 모델의 성능을 평가하기 전, 모형의 높은 정확도를 얻기 위한 최적의 하이퍼 파라미터(Hyper Parameter) 설정이 필요하다.

하이퍼 파라미터란 모델을 생성할 때 직접 설정해야 하는 변수이다. 모델을 학습시킬 때에 세부적인 규율을 사전에 정하는 것으로, 높은 성능을 낼 수 있는 하이퍼 파라미터의 값은 정확히 알려진 바가 없다. 따라서 데이터마다 최적의 하이퍼 파라미터의 값이 달라질 수 있어 매번 실험을 통해 찾아야 한다. 또한, 하이퍼 파라미터값의 범위가 넓고 조합의 수도 많아서 시간과 계산량을 줄이기 위해서는 최적값을 찾기 위한 실험 계획을 면밀히 세운 후 탐색을 하는 것이 필요하다(이재은 외, 2020).

대표적인 하이퍼 파라미터 최적화 방법으로는 메뉴얼 탐색(Manual Search), 그리드 탐색(Grid Search), 랜덤서치(Random Search), 베이지안 최적화(Bayesian Optimization), Tree Parzen Estimator(TPE) 등이 있다.

본 연구는 주어진 범위 내에서 임의의 조합을 추출하여 최적의 조합을 탐색하는 랜덤서치(Random Search)[20] 방법을 활용하였다. 설정한 하이퍼 파라미터의 정의는 다음 표 4.2와 같다.

---

[20] 랜덤 서치(Random Search) : 연속된 매개변수 값을 탐색할 때 유용한 방법으로 탐색할 값을 직접 나열하는 것이 아닌 탐색 값을 샘플링할 수 있는 확률 분포 객체를 전달함. 지정된 횟수만큼 샘플링하여 교차 검증을 수행하기 때문에 시스템 자원이 허락하는 만큼의 탐색량 조절 가능.

표 4.2 Random Forest 하이퍼 파라미터 의미

구 분	의 미
n_estimators	랜덤 포레스트를 구성하는 결정 트리의 개수
max_depth[21]	결정 트리의 최대 깊이
min_samples_leaf	리프 노드에 있어야 하는 최소 샘플 수
min_samples_split	노드를 분할하기 위한 최소 샘플 데이터 수
bootstrap	· True : 복원 추출하여 데이터 샘플링 · False : 비(非)복원 추출하여 데이터 샘플링
max_features	최적의 분할을 위해 고려할 최대 피처의 수(int) 또는 비율(float) · auto : max_features=n_features · sqrt : max_features=sqrt(n_features)

21) max_depth : 기본값은 none이면 모든 리프(leaf)가 순수해질 때까지 모든 리프(leaf)에 min_samples_split 샘플보다 적은 샘플이 포함될 때까지 노드가 확장됨.

4.5.2 랜덤 포레스트 하이퍼 파라미터 성능 평가

전국 고속도로 중 교통사고 발생률 상위 노선 10개의 사고 심각도를 분석하기 위해 선정된 랜덤 포레스트(Random Forest) 모델은 앙상블 학습(Ensemble learning)[22]의 대표 주자 중 하나로 안정적인 성능 덕분에 널리 사용되고 있다.

랜덤 포레스트를 이용한 사고심각도 모형의 설계 과정은 다음과 같다.

본 연구는 2019년부터 2021년까지 경부고속도로, 영동고속도로, 서해안고속도로, 남해고속도로, 수도권제1순환고속도로, 중부고속도로, 중부내륙고속도로, 중앙고속도로, 호남고속도로, 서울양양고속도로에서 발생한 교통사고 심각도를 분석하기 위해 Scikit-learn의 의사결정트리(Decision Tree) 알고리즘을 구현한 랜덤 포레스트 회귀분석(RandomForestRegressor)을 사용하여 분석을 실시하였다.

랜덤 포레스트의 최적 상태를 설정하여 모델을 이용하기 위해 설정한 하이퍼 파라미터는 다음 표 4.3과 같다. 이외의 나머지 하이퍼 파라미터는 RandomForestRegressor 기본값으로 자동 설정된다.

표 4.3에 대해 훈련 데이터(Train data)를 활용하여 Random Search 방법으로 하이퍼 파라미터를 튜닝한 결과는 다음 표 4.4와 같다.

22) 앙상블 학습(Ensemble learning) : 정형 데이터를 다루는 데에 가장 뛰어난 성과를 내는 알고리즘으로 대부분 결정 트리를 기반으로 구성되어 있음

표 4.3 Random Forest 설정 하이퍼 파라미터

구 분	값
n_estimators	200, 400, 600, 800, 1,000, 1,200, 1,400, 1,600, 1,800, 2,000
max_depth	1, 3, 5, 7, 9, 11, 12, None
min_samples_leaf	1, 2, 4
min_samples_split	2, 5, 10
bootstrap	True, False
max_features	auto, sqrt

표 4.4 Random Forest 하이퍼 파라미터 튜닝 상위 10위 결과

순위	n_estimators	max_depth	bootstrap	min_samples_leaf	min_samples_split	max_features	RMSE
1	1,000	None	True	2	2	auto	7.167
2	200	9	True	2	10	sqrt	7.194
3	1,200	12	True	1	5	auto	7.194
4	1,800	12	True	4	2	sqrt	7.198
5	200	12	True	2	10	auto	7.221
6	1,400	5	True	1	5	sqrt	7.306
7	1,800	3	False	1	5	auro	7.519
8	200	3	True	4	2	sqrt	7.524
9	600	1	False	2	5	auto	7.565
10	2,000	9	False	1	2	auto	8.566

훈련 데이터(Train data)를 활용한 랜덤 포레스트 하이퍼 파라미터를 튜닝한 결과, 파라미터의 값이 ‘n_estimators’는 1000, ‘max_depth’는 None, ‘bootstrap’은 True, ‘min_samples_leaf’는 2, ‘min_samples_split’은 2, ‘max_features’는 auto일 때 RMSE의 성능이 7.167로 가장 최적의 상태로 나타났다.

이러한 파라미터로 선정된 훈련 데이터를 통해 선정된 파라미터를 시험 데이터(Test data)에 적용하여 평가한 RMSE는 8.073으로 분석되었고, 다음 표 4.5와 같다.

표 4.5 Random Forest 모형 결과

구 분	RMSE
훈련 데이터	7.167
평가 데이터	8.073

4.5.3 고속도로 10개 노선의 Feature Importance

본 연구에서는 최적의 파라미터를 적용해 모형을 개발한 후 SHAP 패키지를 활용한 변수 중요도를 수치화하여 분석하였다. Random Forest를 이용한 고속도로 교통사고 다발지역 10개 노선인 경부고속도로, 영동고속도로, 서해안고속도로, 남해고속도로, 수도권제1순환고속도로, 중부고속도로, 중부내륙고속도로, 중앙고속도로, 호남고속도로, 서울양양고속도로에서 발생한 교통사고 심각도에 영향을 미치는 요인의 수치는 다음의 표 4.6과 같다.

인적요인 중 가해자의 성별은 여성보다 남성이 교통사고 가해자일 경우에 교통사고 심각도에 영향을 주는 것으로 분석되었다. 또한, 가해자 연령대가 20세 이상에서 39세 이하일 경우 변수 중요도가 0.05로 가장 높게 나타났고 다음으로 40세 이상 59세 이하 연령대의 변수 중요도는 0.04로 나타나 20세 이상에서 39세 이하의 연령대와 근소한 차이를 보였다.

시간・환경요인 중 주・야간의 경우 주간(06:00-18:00)의 사고 발생이 0.11로 나타나 야간(18:00-06:00)의 사고 발생인 0.10보다 교통사고 심각도에 영향을 주고 있는 것으로 분석된다. 요일의 변수 중요도는 주중(월~금)보다 주말(토~일)에 더 높은 것으로 분석되었으며, 계절의 변수 중요도는 봄 0.01, 여름 0.03, 가을 0.03, 겨울 0.06으로 나타나 겨울의 교통사고 발생이 사고 심각도에 가장 큰 영향을 주고 있다고 분석되었다. 기상 상태의 경우 맑음, 흐림일 때의 변수 중요도가 0.03으로 비, 눈, 안개, 기타 변수보다 심각도에 영향을 큰 영향을 주는 요인으로 분석되었으며, 노면의 상태가 젖어있을 경우 교통사고 심각도에 크게 영향을 미치는 것으로 나타났다.

사고요인 중 가해자의 차종이 승합차일 경우가 0.43으로 고속도로 사고 심각도에 영향을 미치는 모든 요소 중 변수 중요도가 가장 높게 나타났으며 승용차(0.15), 화물차(0.03), 특수차(0.01) 순으로 높게 분석되었다.

사고의 유형은 차량 단독(0.01)으로 발생한 경우가 사고 심각도에 영향을 미치고 있는 것으로 분석되었다. 법규위반의 경우, 안전운전불이행이 0.14로 가장 높게 나타났으며 안전거리미확보(0.06), 과속(0.02), 차로위반(0.01) 순서로 변수 중요도가 높게 분석되었다. 고속도로 교통사고 발생 당시의 도로 형태는 단일로 터널(0.04)에서 발생한 사고일 경우에 사고 심각도에 가장 큰 영향을 미치는 것으로 분석되었고 단일로 지하차도(0.02)가 그 뒤를 이었다.

사고의 요인 중 콘 존 데이터를 가공하여 분석한 고속도로 기하구조가 전체적인 교통사고 심각도에 큰 영향을 미치고 있는 것으로 나타났다. 제한속도의 변수 중요도가 0.24로 가장 높게 나타났으며, 차로 수가 0.15, 곡선반경 길이의 평균값이 0.12, 종단경사 0.09로 나타나 고속도로 교통사고 심각도에 영향을 미치고 있어 사고 심각도를 낮추기 위한 기하구조 요소의 개선방안이 필요하다.

표 4.6 고속도로 10개 노선의 Feature Importance

구 분	Feature	Value	Feature Importance
인적 요인	가해자 성별	여 자	0
		남 자	0.01
	가해자 연령	19세 이하	0
		20세 이상 39세 이하	0.05
		40세 이상 59세 이하	0.04
		60세 이상	0.01
시간 환경 요인	주・야간	주 간(06:00~18:00)	0.11
		야 간(18:00~06:00)	0.10
	요 일	주 중(월~금)	0.20
		주 말(토~일)	0.26
	계 절	봄	0.01
		여 름	0.03
		가 을	0.03
		겨 울	0.06
	기상상태	맑 음	0.03
		비	0.01
		눈	0
		안 개	0
		흐 림	0.03
		기 타	0
	노면상태	건 조	0.01
		젖음/습기	0.02
		결 빙	0
		적 설	0
		기 타	0

[표 계속]

구 분	Feature	Value	Feature Importance
사고 요인	차 종	승용차	0.15
		승합차	0.43
		화물차	0.03
		건설기계	0
		특수차	0.01
		기타불명	0
	사고유형	차대사람	0
		차량단독	0.01
		차대차	0
	법규위반	과 속	0.02
		차로위반	0.01
		교차로운행방법위반	0
		신호위반	0
		안전거리미확보	0.06
		안전운전불이행	0.14
		중앙선침범	0
		기 타	0
	도로형태	교차로	0
		단일로 - 고가도로 위	0
		단일로 - 교량	0
		단일로 - 지하차도	0.02
		단일로 - 터널	0.04
		단일로 - 기타	0.02
	기하구조	차로수	0.15
		제한속도	0.24
		곡선반경길이 평균	0.12
		종단경사	0.09

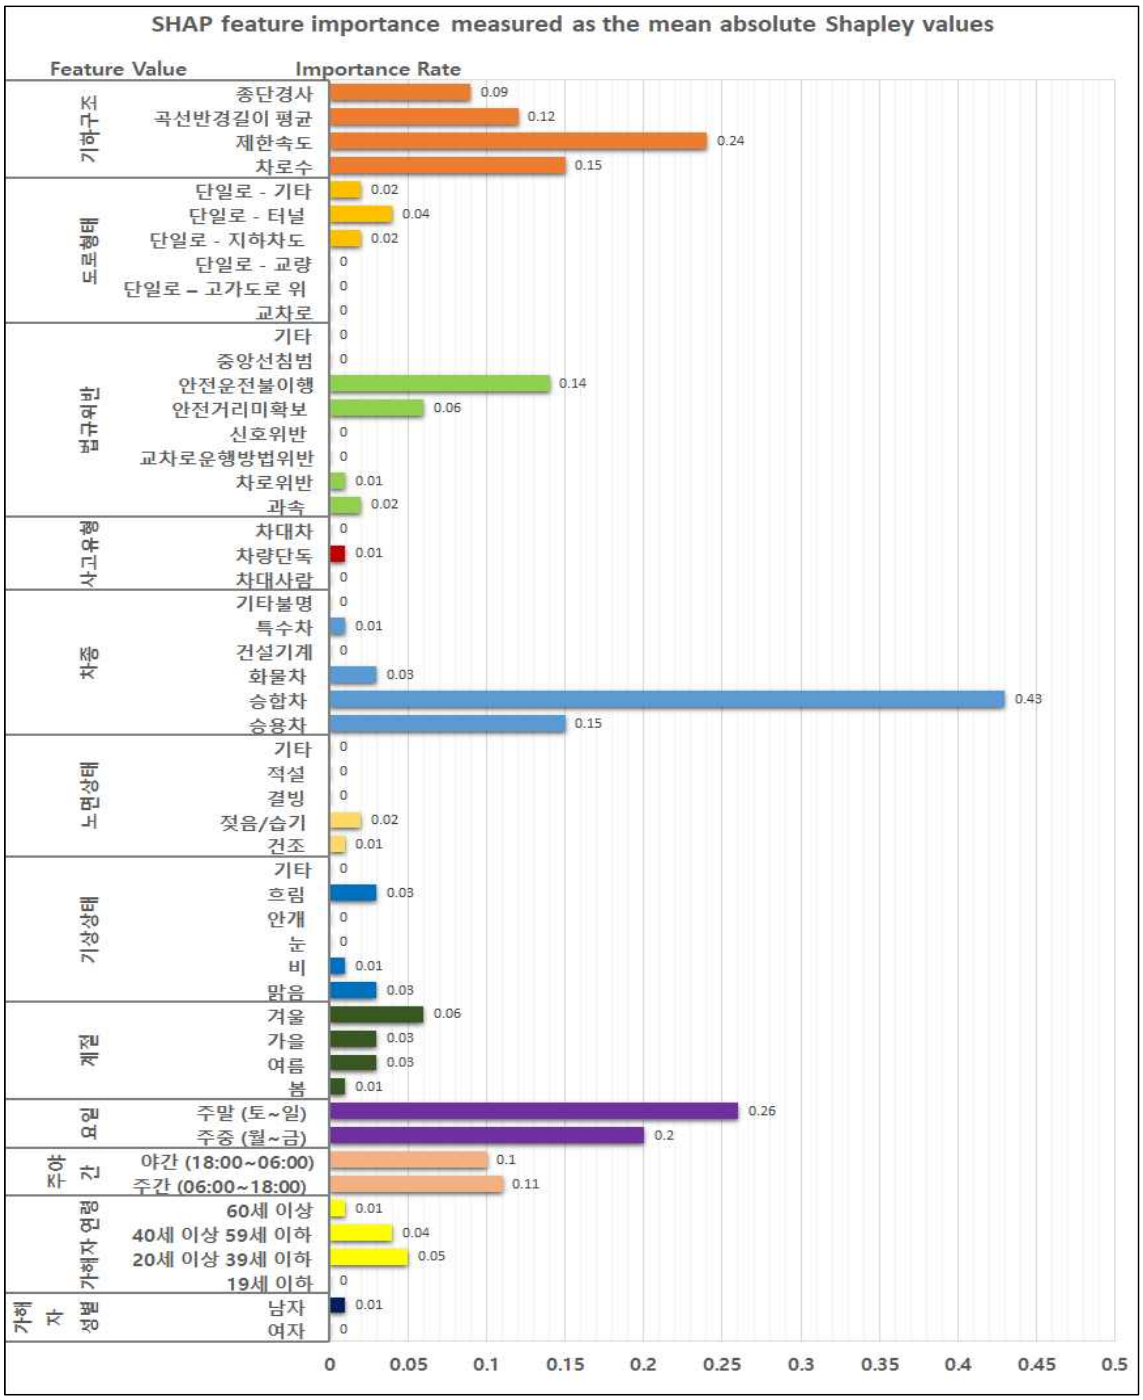


그림 4.6 고속도로 Feature Importance

4.5.4 SHAP 패키지를 활용한 Feature Importance

RandomForestRegressor을 활용하여 분석된 고속도로 교통사고 심각도에 따른 영향 변수 중 중요도 평가를 위해 SHAP 패키지를 활용했다. 먼저 SHAP의 변수 중요도를 통해 어떠한 변수가 고속도로 교통사고 심각도에 영향을 주는지 평가한 결과는 다음 그림 4.7과 같다. 이때, 변수 중요도는 Shapley value의 절대값의 평균으로 정의되기 때문에 각각의 변수가 고속도로 교통사고 심각도에 미치는 절대 영향도라고 할 수 있다.

가해 운전자 차종이 승합차일 경우 가장 큰 영향을 주는 것으로 분석되었으며 주말에 사고가 발생했을 경우가 그다음을 이루었다. 이후 제한속도, 요일_주중, 차로 수, 가해 운전자 차종_승용차, 법규위반_안전운전불이행, 곡선반경길이의 평균이 뒤를 이었다. 다만, 그림 4.7의 SHAP Feature Importance에서 절대 영향도는 각 변수가 교통사고 심각도에 어떠한 방향으로 기여했는지 그 정도를 확인할 수가 없어서 특성값에 따른 고속도로 교통사고 심각도에 미치는 영향력 분석이 필요하다.

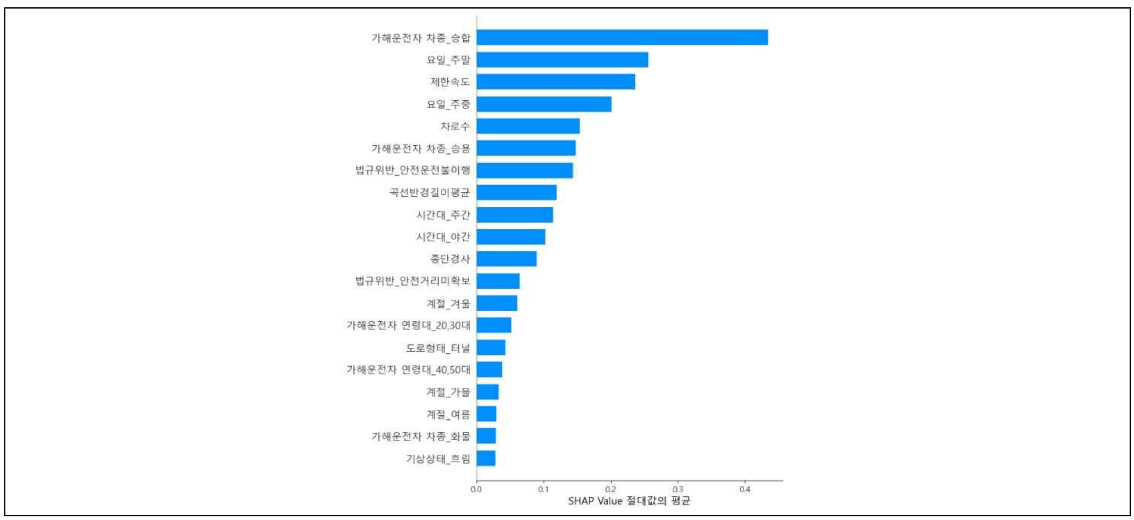


그림 4.7 SHAP Feature Importance

이때 활용한 것이 그림 4.8의 SHAP Summary Plot이다. SHAP Summary Plot은 랜덤 포레스트 회귀모형을 활용하여 나타난 고속도로 교통사고 심각도에 영향을 미치는 변수 중 중요도 평가를 위해 SHAP 패키지를 활용하여 plot으로 시각화한 결과이다.

SHAP Summary Plot은 변수 중요도를 통해 어떤 변수가 고속도로 교통사고 심각도에 얼마나 영향을 주는지 평가할 수 있으며 절대 영향도가 높은 변수가 상단에 위치한다. 그래프에서 x축은 변수 당 Shapley value의 분포를 나타내고 y축은 변수를 나타낸다.

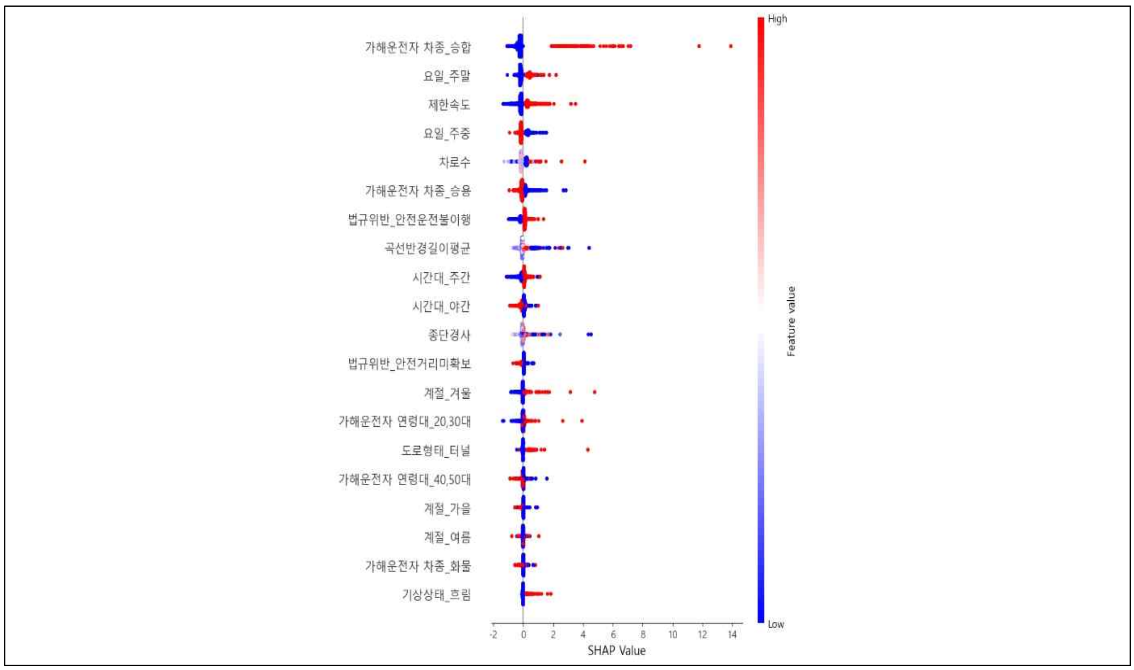


그림 4.8 SHAP Summary Plot

이때, 본 연구에서 feature value에 해당하는 값 중 범주형 변수는 0 또는 1로 구성되어 있다. 따라서 feature의 값이 존재하거나 높은 경우 붉은색으로, feature의 값이 존재하지 않거나 낮으면 파란색으로 표시된다. 또한, feature가 존재하고

Shapley value가 양수(+)일 경우 고속도로 교통사고 심각도가 높은 경향을 보인다는 의미이고 feature가 존재하고 Shapley value가 음수(-)일 경우 고속도로 교통사고 심각도에 낮은 경향을 보인다는 의미다. 단, 인과관계가 아닌 기여 방향의 경향성으로 해석해야 한다.

먼저, 인적요인에서 가해자의 연령대가 20세 이상 39세 미만일 경우 feature value가 1일 때 Shapley value가 양수(+)이므로 사고 심각도가 높은 경향이 있고, 가해자 연령대가 40세 이상 59세 미만일 경우 음수(-)이므로 교통사고 발생 시 심각도가 낮은 경향이 있다.

시간·환경적 요인 중 시간대가 주간(06:00~18:00)일 경우 feature value가 1일 때 Shapley value가 양수(+)로 나타나 사고 심각도가 높은 경향이 있는 반면에, 야간(18:00-06:00)에 발생했을 경우 음수(-)로 나타나 사고 심각도가 낮은 경향이 있다. 또한, 요일이 주말(토~일)의 경우 feature value가 1일 때, Shapley value가 양수(+)로 나타나 사고 심각도가 높은 경향이 있고 주중(월~금)의 경우 음수(-)로 나타나 사고 심각도가 낮은 경향을 보인다. 계절은 여름과 겨울의 경우 feature value가 1일 때 Shapley value가 양수(+)이기 때문에 여름과 겨울에 발생하는 교통사고의 경우 사고 심각도가 높은 경향을 보이고 가을에 발생하는 교통사고의 경우 음수(-)로 나타나 사고 심각도가 낮은 경향을 보이며, 기상 상태가 흐림일 때 Shapley value가 양수(+)로 나타나 교통사고 발생 시 사고 심각도가 높은 경향이 있다.

사고요인 중 가해 운전자의 차종이 승합차인 경우, 해당 feature value가 1일 때 Shapley value가 양수(+)이다. 이는 가해자의 차종인 승합차의 feature가 존재하는 것이 고속도로 교통사고 발생 시 사고 심각도에 높은 영향을 미치는 것으로 분석되고 이와 같은 방법으로 가해 운전자의 차종이 승용차와 화물차일 경우 feature value가 1일 때 음수(-)를 나타내고 있으므로 고속도로 교통사고 발생 시 사고 심각도에 미치는 영향이 낮은 것으로 나타난다.

법규위반은 안전운전불이행일 경우 feature value가 1일 때 Shapley value가 양

수(+)를 나타내고 있어 사고 발생 시 사고 심각도가 높은 경향이 있고, 안전거리미확보의 경우 음수(-)로 사고 심각도가 낮은 경향이 있다. 또한, 도로 형태가 터널일 경우 feature value가 1일 때 Shapley value가 양수(+)이므로 터널에서 발생하는 고속도로 교통사고 경우 사고 심각도가 높은 경향을 보이는 것으로 분석된다.

마지막으로, 고속도로 교통사고 데이터 중 범주형 자료가 아닌 콘 존(Conzone)의 자료를 바탕으로 가공한 수치형 자료인 기하구조에서 차로 수는 feature value가 1일 때 Shapley value가 양수(+)이므로 교통사고 발생 시 차로 수가 사고 심각도에 높은 영향을 끼치는 것으로 분석되었다. 이는 차로 수와 혼잡도의 상관성이 높아 합리적인 결과라고 판단되나 현행 지침에서는 다차로 구간일수록 낮은 사고율을 제시하고 있어 다양한 사례 분석을 통한 검증이 필요하다.

제한속도의 경우 Shapley value가 양수(+)로 나타나 제한속도가 높을수록 교통사고 발생 시 사고 심각도가 높은 경향이 있고, 곡선반경 길이의 평균값과 종단경사는 feature value가 1일 때 Shapley value가 음수(-)로 나타나 분석을 실시한 고속도로 10개 노선에서의 교통사고 발생 시 사고 심각도에 미치는 영향이 낮은 것으로 분석되었다.

제 5 장 결론 및 향후 연구과제

5.1 결론

국민경제의 성장과 함께 자동차 수요 역시도 폭발적으로 증가하였고, 자동차의 증가는 도로의 신설 및 확장, 운전면허취득인구의 증가, 교통사고의 증가 등을 유발했다. 편리한 교통으로부터 얻는 편익이 증가함에 따라, 이로 인해 발생 되는 환경파괴, 교통사고 등의 각종 사회적 문제를 심각히 고려해야 할 시점이다. 특히 교통문제는 국가적 차원에서 그 심각성을 무겁게 인식하고 교통안전을 위한 체계적인 계획을 수립하고 시행하는 등의 노력을 추진하고 있다.

또한, 통계학적 이론이나 연구자가 설정한 회귀모형 등의 통계학적 모형에 데이터를 적용해 데이터 조건 중 유의한 경우에만 분석 데이터로써 가설 검정 또는 유의성을 추정해 분석에 제한적일 수 있는 전통적인 통계분석 방법이 아닌, 머신러닝, 딥러닝과 같은 빅 데이터 분석 기법을 활용한 새로운 방법들이 주목을 받기 시작하였다. 이러한 기법은 대량의 자료를 활용하여 교통사고와 관련된 요인을 분석하는 데에 장점을 보이며 이미 교통 분야뿐 아니라 여러 다른 분야에서도 활발히 적용되어 우리의 일상을 변화시키고 있다. 이에 본 연구에서는 머신러닝을 활용한 고속도로 교통사고의 심각도 모형을 분석하고자 하였다.

연구의 공간적 배경은 전국의 고속도로 노선 중 2021년 개통이 완료되어 한국도로공사에서 관리 중인 고속도로와 민자 고속도로를 기준으로 교통사고 건수가 가장 많은 1위부터 10위까지의 노선을 선정하였고 이는 전국의 고속도로 교통사고 건수 중 71.7%를 차지하는 비율이다. 선정된 노선은 경부고속도로, 영동고속도로, 서해안고속도로, 남해고속도로, 수도권제1순환고속도로, 중부고속도로, 중부내륙고속도로, 중앙고속도로, 호남고속도로, 서울양양고속도로이다. 시간적 배경은 TAAS에서 구득

가능한 자료의 시간적 범위를 고려하여 2019년부터 2021년까지로 설정하였다.

분석을 위해 TAAS의 고속도로 교통사고 데이터를 통해 가해자의 인적요인, 피해자의 인적요인, 가해 운전자의 차량 요인, 시간적 요인, 계절 요인, 노면의 상태, 사고의 유형, 도로의 형태 및 위반법규 데이터를 원자료의 형태로 활용하였고 고속도로 교통사고로 인한 피해의 규모를 수치화하기 위해 사고 당사자들의 모든 피해 내용을 EPDO로 환산하여 분석을 진행하였다.

또한, TAAS의 교통사고 자료에는 사고지점의 위치 좌표를 제공하고 있지 않아 Q-GIS를 활용하여 고속도로에서 발생한 모든 지점의 위치 좌표를 구득하였다. 그렇게 구득한 사고 위치 정보를 콘 존(Conzone)의 Shp파일과 결합하여 해당 콘 존에서 발생한 고속도로 교통사고의 정확한 위치를 알 수 있었다.

이후 결합한 자료를 분석에 활용한 9,227건의 개별 교통사고 데이터에 콘 존 마스터 테이블의 자료를 모두 매칭했다. 이때, 기하구조 자료로는 차로 수, 제한속도, 곡선반경 길이의 평균, 종단경사를 연속형 데이터 형태로 분석에 활용하였다.

최적의 머신러닝 모델을 선정을 위해 머신러닝 워크플로우(workflow)를 자동화해주는 파이캐럿(Pycaret)을 활용하였으며, 가장 성능이 좋은 머신러닝 기법으로 랜덤 포레스트 회귀모형(RandomForestRegressor)이 채택되었다.

또한, StandardScaler 기법으로 서로 다른 변수의 범위를 일정 수준으로 맞추어 주고 랜덤 포레스트 회귀모형의 성능 비교를 위해 RMSE 지표를 활용한 모형의 성능 비교를 실시하였다. 이후 RandomizedSearchCV를 활용해 가장 좋은 하이퍼 파라미터를 설정해 모델을 훈련했으며 최종적으로 고속도로 교통사고 심각도 모형을 분석하기 위해 SHAP 패키지를 활용해 교통사고 심각도에 영향을 미치는 변수 중요도를 분석하였다.

고속도로 교통사고 다발지역 10개 노선에서 발생한 교통사고 심각도 모형의 변수 중요도를 도출한 결과, 가해자의 연령대가 20세 이상 39세 미만인 경우, 시간대가 주간(06:00~18:00)일 경우, 주말(토~일)일 경우, 계절이 여름과 겨울일 경우, 기상

상태가 흐림일 경우, 가해 운전자의 차종이 승합차일 경우, 법규위반이 안전운전 불이행일 경우, 도로 형태가 터널일 경우, 기하구조 상 차로 수가 많고 제한속도가 높은 경우로 총 10개의 독립변수에서 고속도로 교통사고 심각도와 양(+)의 상관관계를 가지는 것으로 분석되었고 이러한 결과는 각 관측변수 간의 기초통계 분석 결과와 전반적으로 일치하는 결과를 보였다.

고속도로에서의 교통사고는 매우 다양한 요인들의 복합적인 작용으로 인해 발생하기 때문에 사고를 정확히 예측하는 데에는 많은 어려움이 있다. 하지만 도로 종류 중 고속도로에서의 교통사고가 치사율이 최고치를 달하는 만큼, 본 연구로 도출된 결과를 활용하여 향후 연구에서는 전국의 고속도로 노선의 사고 심각도 분석으로 범위를 넓혀 사고 심각도에 영향을 주는 요인을 분석하고 좀 더 효율적이고 합리적인 대응책을 수립하기 위한 노력이 필요하다. 특히, 운전자 요인, 시간·환경요인, 사고요인, 기하구조 요인 등의 관측변수를 더욱 다양화 및 세분화하고 머신러닝, 딥러닝과 같은 빅 데이터 분석 기법을 활용한다면 좀 더 신뢰성 있는 사고 예측모형을 개발할 수 있을 것으로 판단된다.

5.2 한계점 및 향후 연구과제

본 연구의 한계점 및 향후 연구과제는 다음과 같다.

첫째, 일반국도, 지방도, 시도, 군도 등 다른 도로 유형과 비교해 상대적으로 고속도로 교통사고 데이터가 많은 편임에도 불구하고 사고 심각도 영향요인을 분석하기 위해 활용할 수 있는 데이터가 부족해 좀 더 다양한 변수들을 모형분석에 포함하지 못한 한계가 있다.

본 논문에서는 이를 보완하기 위해 콘 존의 정보를 결합하여 연속형 데이터를 활용하고자 하였으나 연속형 데이터의 변수를 다양하게 확보하지 못하였다는 한계점이 있었다. 따라서 향후 연구에서는 모형분석에 활용할 입력변수의 종류를 다양화하여 더욱 다각적인 측면에서의 사고 심각도 모형분석을 진행할 필요가 있다.

둘째, 고속도로 교통사고 발생 시 현장의 사고 처리 담당자의 주관에 의존하여 사고 데이터를 작성하기 때문에 사고내용 중 일부 변수는 포괄적이거나 주관적으로 작성되어 사고 정보에 대한 정확도가 떨어지는 한계가 존재한다. 따라서 향후의 모든 사고 자료가 조금 더 세부적인 항목으로 구체화하여 구축된다면 조금 더 신뢰성 있는 결과를 도출할 수 있을 것으로 생각된다.

셋째, 본 논문에서는 고속도로 사고 다발 노선 10개를 선정하여 분석을 진행하였다. 이는 전체 고속도로 사고 중 71.1%를 차지하는 비율이나 고속도로 전체 노선을 대상으로 분석을 진행하지 않았다. 따라서 향후 연구의 범위를 전국 고속도로 노선으로 확대하여 연구를 진행한다면 고속도로 교통사고 감소를 위한 좀 더 신뢰성 있고 효율적인 대응책을 수립하는 데에 도움이 될 것이라고 기대한다.

참고문헌

ⅰ) 학위논문

[1] 윤병조, 2006, “고속도로 인터체인지 연결로 유형에 따른 교통사고 예측모형개발.“, 박사학위논문, 아주대학교

[2] 김나경, 2021, “머신러닝을 활용한 도시부 및 지방부 사고 심각도 요인 분석에 관한 연구“, 석사학위논문, 인천대학교

[3] 류종득, 2018, “딥 러닝을 이용한 고속도로 교통사고 예측모델 개발“, 박사학위논문, 아주대학교

[4] 권경주, 2021, “빅데이터마이닝 기반 고속도로 심각사고 복합 영향요인 분석“, 석사학위논문, 한양대학교

[5] 강가원, 2022, “동적 교통지표의 시간적 집계 수준을 고려한 고속도로 안전성능함수 개발“, 석사학위논문, 한양대학교

[6] 강동운, 2014, “상관성이 있는 변수를 고려한 주성분 분석 기반의 안전성능함수 개발”, 석사학위논문, 서울대학교

ⅱ) 단행본

[7] ASSHTO, 2010, “Highway Safety Manual, 1st Ed.”, Washington, DC.

[8] U.S. Department of Transportation; Federal Highway Administration, 2013, “Safety Performance Function Development Guide : Developing Jurisdiction-Specifics SPFs”

[9] 도철웅, 2014, “교통공학원론”, 정문각

[10] 박해선, 2020, “혼자 공부하는 머신러닝+딥러닝”, 한빛미디어

[11] 김영우, 2022, “Do it! 쉽게 배우는 파이썬 데이터 분석”, 이지스 퍼블리싱

[12] 도로교통공단, 2022, “2022년판 교통사고 통계사고 통계분석(2021년 통계)”
[13] 도로교통공단, 2022, “2022년판 OECD 회원국 교통사고 비교”
[14] 국토교통부, 2023, “도로 주요 통계”
[15] 한국도로공사, 2013, “고속도로 교통안전편람 연구”
[16] 한국도로공사, 2012, “도로안전편람(Highway Safety Manual”
[17] 김준기, 손유진, 2013, “국민 생활안전을 위한 도로안전성 분석방법 도입방안”, 국토연구원, 443.

ⅲ) 학회논문

[18] 윤병조, 이소연, 정소연, 2017, “EPDO에 영향을 미치는 고속도로 교통사고 요인분석에 관한 연구”, 한국재난정보학회 학술대회 자료집, pp.251-252.
[19] 권철우, 장현호, 2021, “XGBoost를 활용한 이륜자동차 교통사고 심각도 비교분석”, 한국ITS학회 논문지, 20(4), pp.1-12.
[20] 정재풍, 최종후, 2014, “교통사고건수에 대한 포아송 회귀와 음이항 회귀모형 적합”, 한국자료분석학회, 16(1), pp.165-172.
[21] 신승범, 조형준, 2021, “랜덤 포레스트를 위한 상관예측변수 중요도“, 한국통계학회, 34(2), pp.177-190.
[22] 유이하, 한경화, 2022, “예측모형의 머신러닝 방법론과 통계학적 방법론의 비교:영상의학 연구에서의 적용“, 대한영상의학회, 86(6), pp.1219-1228.
[23] 강홍식, 노명규, 2022, “앙상블 학습기법을 활용한 보행자 교통사고 심각도 분류 : 대전시 사례를 중심으로“, 디지털융복합연구, 20(5), pp.39-46.
[24] 손승오, 박준영, 2022, “데이터마이닝 기반의 사고 심각도 가중치 적용 예측변수를 활용한 교차로 사고예측모형 개발”, 대한교통학회지, 40(2), pp.190-204.
[25] 박장우, 신창선, 2019, “서울시 공공자전거 운행 거리 예측을 위한 머신러닝 모델의 비교 연구“ 한국지식정보기술학회 논문지, 14(6), pp.625-634.

[26] 이용건, 오재영, 김기백, 2020, “머신러닝 해석 기법을 이용한 전력 수요 예측 모델 해석”, 전기학회논문지, 69(3), pp.480-485.
[27] 이근희, 노정현, 2015, “확률모수를 이용한 교통사고예측모형 개발 - 수도권 및 부산광역시 4지 교차로를 대상으로 -”, 한국ITS학회논문지, 14(6) pp.91-99.
[28] 이재은, 김영봉, 김종남, 2020, “합성곱 신경망에서 이미지 분류를 위한 하이퍼 파라미터 최적화.“, 융합신호처리학회 논문지(JISPS), 21(3), pp.148-153.
[29] 강찬모, 정연식, 장유진, 2019, “순서형 프로빗 모형을 적용한 고속도로 화물차 사고 심각도”, 대한토목학회논문집, pp.391-398.
[30] 김용현, 김영준, 2022, “순서형 로짓모형을 이용한 개인형 이동장치 교통사고 심각도 위험요인 분석”, 대한교통학회, 19(6), pp.28-32.
[31] 김윤환, 박병호, 2006, “고속도로 교차점의 기하구조와 교통사고의 관계분석 : 다중회귀분석, 포아송 회귀분석, 능형회귀분석 모형을 중심으로”, 대한교통학회, 53, pp.321-330.
[32] 황경성, 최재성, 김상엽, 허태영, 조원범, 김용석, 2010, “차량 속도를 이용한 도로 구간분할에 따른 고속도로 사고빈도 모형 개발 연구”, 대한교통학회지, 28(2), pp.151-159.
[33] 박정순, 2011, “신호교차로의 횡단보행자 사고심각도 분석”, 지역정책연구(Regional Policy Review), 22(1), pp.1-12.
[34] 김승훈, 임영빈, 김기정, 2021, “머신러닝 기반의 수도권 지역 고령운전자 차대사람 사고심각도 분류 연구”, 19(4), pp.25-31.
[35] 강민욱, 도철웅, 손봉수, 2002, “고속도로 평면선형상 사고빈도분포 추정을 통한 음이항 회귀모형 개발(기하구조요인을 중심으로)”, 대한교통학회지, 20(7), pp.197-204
[36] 서임기, 강동윤, 박제진, 박신형, 2015, “고속도로 선형 동질구간 기반의 안전성능함수 개발”, 대한토목학회논문집, 35(2), pp.397-405.
[37] Breiman, L., 2001, “Random forests”, Machine Learning, 45, 5-32.
[38] Lord, D., & Mannering, F., 2010, “The statistical analysis of crash-frequency

data: A review and assessment of methodological alternatives", Transportation research part A: policy and practice, 44(5), 291-305.

[39] AASHTO, 2010, "Highway Safety Manual, First Edition", American Association of State and Highway Transportation Officials, Washington DC.

[40] Zeini HA, Al-Jeznawi D, Imran H, Bernardo LFA, Al-Khafaji Z, Ostrowski KA., 2023, "Random Forest Algorithm for the Strength Prediction of Geopolymer Stabilized Clayey Soil", 15(2):1408.

[41] Joy M. Koopmans, Lee Friedman, Soyang Kwon, Karen Sheehan, 2015, "Urban crash-related child pedestrian injury incidence and characteristics associated with injury severity", Accident Analysis & Prevention, 77, pp.127-136.

[42] R. E. AlMamlook, K. M. Kwayu, M. R. Alkasisbeh and A. A. Frefer, 2019, "Comparison of Machine Learning Algorithms for Predicting Traffic Accident Severity", IEEE Jordan International Joint Conference on Electrical Engineering and Information Technology (JEEIT), pp.272-276.

[43] M. F. Labib, A. S. Rifat, M. M. Hossain, A. K. Das and F. Nawrine, 2019, "Road Accident Analysis and Prediction of Accident Severity by Using Machine Learning in Bangladesh," , 7th International Conference on Smart Computing & Communications (ICSCC), Sarawak, Malaysia, pp.1-5.

[44] Sobhan Sarkar, Sammangi Vinay, Rahul Raj, J. Maiti, Pabitra Mitra, 2019, "Application of optimized machine learning techniques for prediction of occupational accidents", Computers & Operations Research, vol.106, pp.210-224.

[45] Lee J, Yoon T, Kwon S, Lee J., 2019, "Model Evaluation for Forecasting Traffic Accident Severity in Rainy Seasons Using Machine Learning Algorithms: Seoul City Study." , Applied Sciences., 10(1):129.

[46] Megnidio-Tchoukouegno, M.; Adedeji, J.A., 2023, "Machine Learning for Road Traffic Accident Improvement and Environmental Resource Management in the Transportation Sector." , multidisciplinary-digital-publishing-institute, 15(3):2014.

[47] I. E. Mallahi, A. Dlia, J. Riffi, M. A. Mahraz and H. Tairi, 2022, “Prediction of Traffic Accidents using Random Forest Model,“ 2022 International Conference on Intelligent Systems and Computer Vision (ISCV), Fez, Morocco, pp.1-7.

[48] Zhong Liande., Sun Xiaoduan., Yulong He., Zhong Xiaoming., Chen Yongsheng., 2009, “Safety Performance Function for Freeways in China“, Transportation Research Board 88th Annual Meeting, pp.19.

[49] Mun, Sung-Ra, Young-Ihn Lee, and Soo-Beom Lee, 2012, “Developing a Traffic Accident Prediction Model for Freeways.”, Journal of Korean Society of Transportation, 30(2), pp.101-106.

[50] Lu, J., Haleem, K., Alluri, P., & Gan, A., 2013, “Full versus Simple Safety Performance Functions: Comparison Based on Urban Four-Lane Freeway Interchange Influence Areas in Florida”, Transportation Research Record, 2398(1), pp.83-92.

[51] Shaw-Pin Miaou, Patricia S. Hu, Tommy Wright, Ajay K. Rathi, Stacy C. Davis, 1992, “Relationship Between Truck Accidents and Highway Geometric Design: A Poisson Regression Approach”, Transportation Research Board, 1376, pp.10-18.

[52] Li-Yen Chang, 2005, “Analysis of freeway accident frequencies: Negative binomial regression versus artificial neural network”, Safety Science, 43(8), pp.541-557.

[53] Angus Eugene Retallack, Bertram Ostendorf, 2020, “Relationship Between Traffic Volume and Accident Frequency at Intersections”, Int. J. Environ. Res. Public Health, 17(4):1393.

ABSTRACT

A Study on the Analysis of Highway Traffic Accident Severity and Influencing Factors Using Machine Learning

Lee, Sun Min

Department of Urban Construction Engineering

Graduate School, Incheon National University

Supervised by Professor Yoon, Byoung-jo

The overall number of traffic accidents in the country is on a decreasing trend. This is considered a positive outcome due to the government and relevant agencies recognizing the seriousness of traffic accidents and actively pursuing multifaceted efforts, such as establishing systematic plans and improvement measures for traffic safety. However, accidents on the expressways, which constitute a crucial part of the domestic road network connecting major cities, continue to show fluctuations in accident trends. The fatality rate in traffic accidents on expressways remains at its highest among various types of roads.

As of 2021, in the sector of traffic accidents per OECD country, South Korea experienced approximately 2.5 times more accidents than the OECD average. The number of traffic accidents per 100,000 people in South Korea stood at 74.2,

significantly higher than the OECD member countries' average of 27.0. This indicates that South Korea continues to have a considerably higher incidence of traffic accidents compared to the OECD average. Therefore, there is evidently room for improvement in reducing accidents on domestic expressways. It is crucial to prioritize a review of the national traffic safety policy and consider various improvement measures that reflect the domestic situation to address this persistently high accident rate.

In this study, we adopted a selection of 10 expressway routes with frequent accidents nationwide and analyzed the factors influencing the severity of expressway traffic accidents. To enhance the precision of the analysis, we utilized machine learning, a big data analysis technique, to investigate areas that were difficult to analyze using traditional statistical methods. This approach aimed to improve the accuracy of the analysis in areas where conventional statistical methods faced challenges.

Additionally, we incorporated data combining not only traffic accident information but also key analytical units of expressways, such as toll booths (Conzone) and geometric structural elements of roads. Using the PyCaret library in machine learning, we selected the most optimal model for analyzing accident severity and aimed to identify the factors influencing expressway traffic accident severity. This approach involved a comprehensive analysis, combining information on accidents with the geometric and structural features of the roads using a machine learning model selected for its effectiveness in analyzing accident severity.

As a result of analyzing highway traffic accidents that occurred on the 10 selected routes nationwide from 2019 to 2021, the performance of the

RandomForestRegressor technique was found to be the most favorable. Therefore, we adopted this technique to derive insights into the analysis of expressway traffic accident severity and the factors influencing accident severity.

Using the SHAP(SHapley Additive exPlanations) package to analyze the importance of the top 10 variables, the results show that the variables with a significant impact on the severity of highway traffic accidents are :

1. Age group of the at-fault driver being 20 years or older and less than 39 years.
2. Daytime hours (06:00-18:00).
3. Weekends (Saturday to Sunday)
4. Seasons of summer and winter.
5. Overcast weather conditions.
6. At-fault driver's vehicle type being a van.
7. Violation of traffic regulations or failure to drive safely.
8. Road type being a tunnel.
9. High lane count
10. speed limit in the geometric structure of the road.

These 10 independent variables exhibit a positive correlation with the severity of highway traffic accidents, indicating that an increase in these factors is associated with an increase in accident severity.

The significance of this study lies in its use of machine learning techniques rather than traditional statistical methods to analyze the severity model of highway traffic accidents. Moreover, highway accidents involve a complex interplay of various factors, making it challenging to accurately predict accidents. However, based on the analyzed results, the study expands its scope beyond the

selected 10 routes with frequent accidents to encompass a nationwide analysis of highway accident severity. By doing so, it aims to identify factors influencing the severity of highway accidents and propose measures for improvement.

The hope is that, with this broader perspective, the findings of the study can serve as foundational data for future efforts to reduce highway traffic accidents. Analyzing accident severity on a national scale allows for a more comprehensive understanding of the factors at play, paving the way for effective strategies to enhance highway safety and reduce accidents in the future.

Key word : Highway, Highway Traffic Accidents, Accident Severity, Machine Learning, Feature Importance